report_001：論文「物体領域検出とカテゴリアノテーションの分離に基づく，WordNet を用いた粒度可変物体アノテーション」の再現実装

1. 概要

`main.pdf` の提案パイプラインを公開済みの学習済みモデルで実装し，論文 4 章の実験（4.2 節〜4.7 節）を 4 つの実験（ex001〜ex004）として再現した．提案手法は学習を伴わないため，すべての実験は推論と評価のみで構成される．主な結論は以下のとおりである．

論文の主張	再現結果
オープンボキャブラリな VLM が必要（ResNet50-IN1k vs CLIP，有意差あり）（4.2 節）	再現できた．全指標で $p < 10^{-11}$ ．CLIP-RN50 と CLIP-ViT-B/32 の差は一部の指標のみ有意という点も一致した
DETR の位置検出精度は OWL-ViT・Grounding DINO と同等（4.3 節）	傾向は再現できた．平均最良 IoU は DETR が最良（0.705 vs 0.517 / 0.546）．ただし選定した 4 画像では全手法の Recall が 1.0 を下回った
パイプライン全体で Top-1 0.647，Top-5 0.907（4.4 節）	最良の設定で Top-1 0.604，Top-5 0.894．論文に記載のない前処理の設定に強く依存する
WordNet 深さ 0 → 1 で確信度が大きく低下（4.5 節）	再現できた（0.642 → 0.442，論文 0.695 → 0.477）．深さごとのインスタンス数も論文とほぼ一致した
COCO 外の語へのアノテーション，灯台での検出失敗，giraffe → okapi の問題（4.6 節，4.7 節）	いずれも再現できた

2. 実装と実験条件

2.1 パイプライン

画像 $\mathbf{X}$ に対し DETR（`facebook/detr-resnet-50`）を 1 回だけ実行し，スコアが閾値以上のボックス $\mathbf{b}_k$ を予測カテゴリを使わずに取得する．ボックスにちょうど合わせたクロップ $\mathbf{X}_k$ を VLM f に入力し，候補語彙集合 $\mathbb{N}$ 上の argmax を推定単語 $\hat{v}_k$ とする（論文の式 (2)）．深さ $d \geq 1$ では，1 つ浅い段階で選ばれた Synset の直接の下位語集合を候補語彙とする（論文の式 (3)）．CLIP のプロンプトは “a photo of a {w}”，スコアは logit scale 付きコサイン類似度のソフトマックスである．詳細なファイル構成は `document.md` を参照されたい．

2.2 論文に記載がないため本実装で決めた設定

項目	本実装の設定
ResNet50-IN1k の重み	torchvision `IMAGENET1K_V1`．候補語は末尾語を WordNet の `morphy` でレンマ化し，小文字化したクラス名と完全一致した場合のみそのクラス確率をスコアとする
タスク B の語彙抽出	spaCy `en_core_web_sm` 3.8.0 で品詞が NOUN / VERB，アルファベットのみ，ストップワード以外のトークンのレンマ
COCO クラスと Synset の対応	`programs/common/wordnet_utils.py` の `COCO_TO_SYNSET`（定義文を確認して手動で決定．例：cow → `cattle.n.01`，stop sign → `street_sign.n.01`）

項目	本実装の設定
下位語の候補語	直接の下位語 Synset（`hyponyms()`）の先頭レンマ名．表記の重複は除く
ex002 の 4 画像	seed=42 の 500 枚の順序で，GT が 2〜3 件の画像の先頭 20 枚から，GT の合計がちょうど 10 件になる最初の 4 枚の組（画像 ID 107554，210299，98520，517687）
OWL-ViT / Grounding DINO の設定	テキストクエリは COCO 80 クラス名．OWL-ViT は閾値 0.1，Grounding DINO（tiny）は box 0.35 / text 0.25（80 クラスを 40 クラスずつ 2 回に分けて入力）．どちらもクラス間 NMS（IoU 0.5）でクラス非依存のボックスとする
ex003 の DETR 閾値	0.5，0.7，0.9，0.97 を比較
ex003 の GT との対応付け	ハンガリアン法で IoU 0.5 以上の 1 対 1 対応
クロップの前処理（ex003）	`center`：クロップをそのまま CLIP の標準前処理（短辺リサイズ＋中央切り出し）に入力する．`pad`：クロップを黒で正方形にパディングしてから入力する．どちらの方式でもボックス外の画像内容は含めない
追加 22 語（ex004）	penguin, helicopter, kangaroo, camel, lighthouse, dolphin, whale, shark, eagle, owl, parrot, flamingo, tiger, lion, monkey, gorilla, panda, deer, fox, rabbit, squirrel, castle
ex004 の画像	Wikimedia Commons の固定のファイル名（`programs/ex004_open_vocab_qualitative/data.py`）．ライセンス情報は `datasets/ex004_open_vocab_qualitative/open_vocab_meta.js` に保存

2.3 実行環境

NVIDIA GeForce RTX 4070 Ti（12GB），Python 3.11，torch 2.7.1+cu128，transformers 4.53.2，open_clip 2.32.0 で実行した．論文の実行環境は RTX 3090 である．各実験は単一プロセスでピーク VRAM 3GB 未満，ピーク RAM 4GB 未満であり，所要時間は ex001 が 40 秒，ex002 が 34 秒，ex003 が全 24 条件で 330 秒，ex004 が約 1 分であった．GPU 推論が律速で，実行時間も短いため，並列数は 1 とした．画像のサンプリングは seed=42 のみで，推論は決定的であるため，seed 間の標準偏差は 0 として扱う．

3. ex001：オープンボキャブラリな VLM の必要性（論文 4.2 節）

`programs/ex001_coco_val500_image_word/`, 結果は `outputs/ex001_coco_val500_image_word/` に保存した．評価対象は 500 枚で，GT カテゴリが空の画像を除くとタスク A は 491 枚になる．$|V_A| = 80$ ，$|V_B| = 1371$ であり，論文の $|V_B| = 1452$ よりやや少ない．

タスク	手法	P@1	R@1	P@5	R@5	論文 P@1	論文 R@1	論文 P@5	論文 R@5
A	ResNet50-IN1k	0.216	0.091	0.069	0.123	0.255	0.095	0.084	0.132

タスク	手法	P@1	R@1	P@5	R@5	論文 P@1	論文 R@1	論文 P@5	論文 R@5
A	CLIP-RN50	0.855	0.431	0.316	0.659	0.838	0.397	0.334	0.649
A	CLIP-ViT-B/32	0.855	0.433	0.328	0.687	0.822	0.385	0.350	0.678
B	ResNet50-IN1k	0.294	0.024	0.100	0.041	0.350	0.027	0.104	0.040
B	CLIP-RN50	0.528	0.045	0.334	0.139	0.454	0.035	0.306	0.118
B	CLIP-ViT-B/32	0.534	0.045	0.352	0.148	0.444	0.035	0.313	0.121

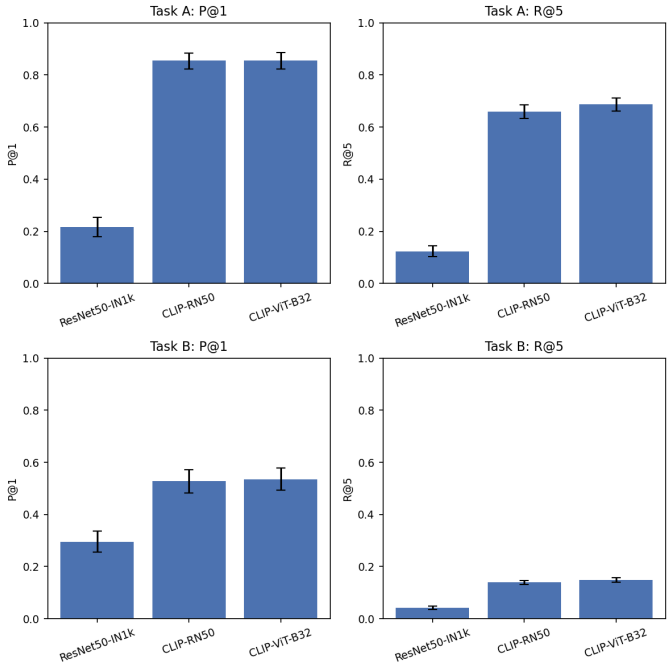


図 1　ex001

上図は論文の図 2 に対応し，誤差棒は画像単位のブートストラップ 95% 信頼区間（$B = 1000$ ）である．タスク A の値は論文と ±0.05 以内で一致した．タスク B では CLIP の P@1 が論文より約 0.08 高く，ResNet50-IN1k は約 0.06 低い．この差は，語彙抽出（spaCy のバージョンやストップワード除去の有無）によって V_B が異なることが原因と考えられる．

Wilcoxon 符号付き順位検定（`table_wilcoxon.csv`）の結果，ResNet50-IN1k と CLIP 系の間ではタスク A・タスク B の全指標で有意差があり，最大の p 値はタスク B の R@1 における 2.2×10^{-12} であった．CLIP-RN50 と CLIP-ViT-B/32 の間では，P@1 と R@1 に有意差はなく（$p \geq 0.53$ ），P@5 と R@5 のみ有意であった（タスク A の P@5 で $p = 0.038$ ，R@5 で $p = 6.3 \times 10^{-4}$ ）．「学習手法・語彙設計の要因がモデル構造の要因より支配的である」という論文の結論は再現された．

4. ex002：物体領域検出モデルの比較（論文 4.3 節）

`programs/ex002_coco_4img_class_agnostic_det/`，結果は `outputs/ex002_coco_4img_class_agnostic_det/` に保存した．

手法	設定	平均提案数	Recall@IoU0.5	平均最良 IoU
DETR	閾値 0.5	2.25	0.800	**0.705**
DETR	閾値 0.7	1.75	0.700	0.669
DETR	閾値 0.9	1.50	0.600	0.583
OWL-ViT	閾値 0.1	1.50	0.500	0.517
Grounding DINO	box 0.35 / text 0.25	1.50	0.500	0.546
（論文）DETR	—	3.0	1.000	0.931
（論文）OWL-ViT	—	5.0	1.000	0.920
（論文）Grounding DINO	—	3.5	1.000	0.903

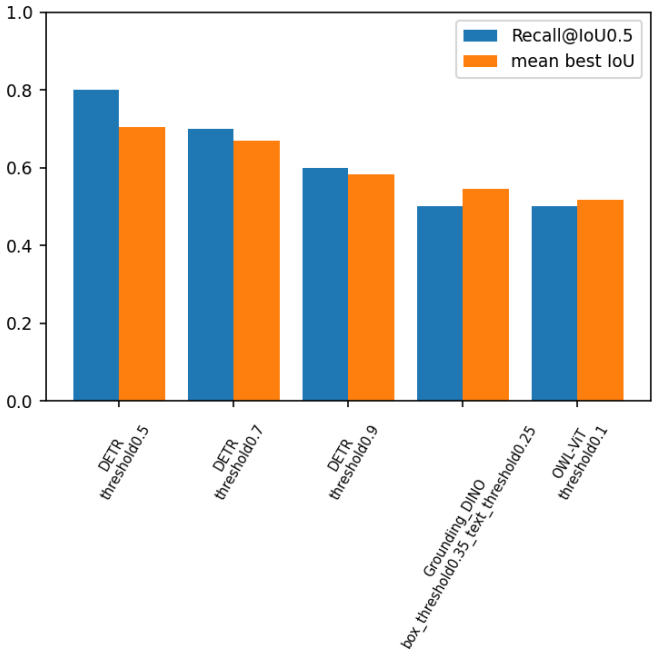


図 2　ex002

平均最良 IoU は DETR（閾値 0.5）が最良であり，「DETR の位置検出精度はオープンボキャブラリ検出器と同等以上である」という論文の結論と矛盾しない．一方，Recall の絶対値は論文より大きく低い．`per_gt.csv` を確認すると，本実装で選んだ 4 画像には画像面積の 0.3% の極小の車（画像 107554）や，画像のほぼ全体を占めるテーブル（画像 517687，面積比 98%）が含まれており，これらは全手法で検出されなかった．論文は 4 画像の選び方を記載していないため，選んだ画像の難しさが差の主因と考えられる．4 画像・10 インスタンスでは統計的な比較ができないため，500 枚規模での比較が今後の課題である．

5. ex003：パイプライン全体の精度と WordNet 階層の確信度（論文 4.4 節，4.5 節）

`programs/ex003_coco_val500_pipeline/`，結果は `outputs/ex003_coco_val500_pipeline/` に保存した．

5.1 カテゴリアノテーションの精度

DETR 閾値	前処理	インスタンス数	CLIP-ViT-B/32 Top-1	CLIP-ViT-B/32 Top-5	CLIP-RN50 Top-1	CLIP-RN50 Top-5	ResNet50-IN1k Top-1	ResNet50-IN1k Top-5
0.5	center	2343	0.481	0.778	0.367	0.649	0.080	0.111
0.7	center	2217	0.488	0.783	0.371	0.655	0.081	0.110
0.9	center	1892	0.506	0.804	0.389	0.681	0.082	0.112
0.97	center	1519	0.525	0.830	0.408	0.709	0.084	0.113
0.5	pad	2343	0.560	0.855	0.460	0.740	0.088	0.113
0.7	pad	2217	0.568	0.858	0.467	0.747	0.088	0.112
0.9	pad	1892	0.587	0.874	0.484	0.776	0.090	0.113
0.97	pad	1519	**0.604**	**0.894**	0.512	0.808	0.091	0.113
（論文）	—	1466	0.647	0.907	—	—	—	—

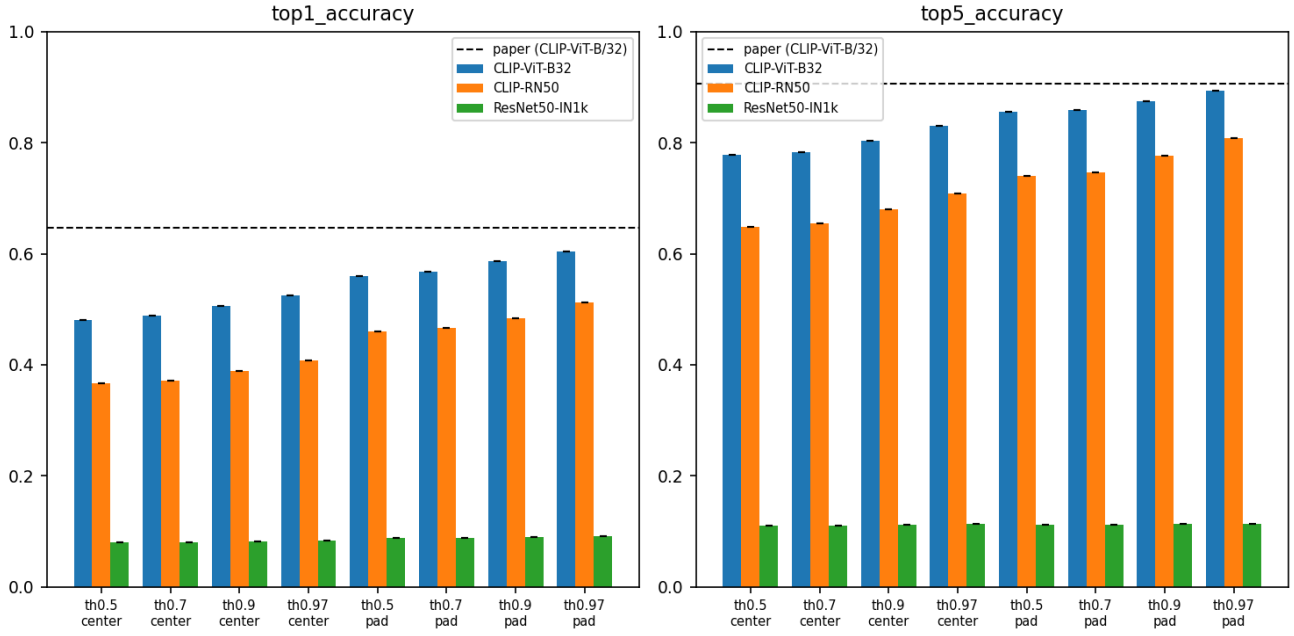


図 3　ex003 accuracy

上図の破線が論文値である．最初に実装した設定（閾値 0.9，前処理 `center`）では Top-1 が 0.506 にとどまった．誤分類を集計すると，person → tie（53 件），baseball glove（23 件），baseball bat（22 件），tennis racket（22 件）など，人物のクロップが身に着けている物や持っている物に分類される誤りが多かった．また，アスペクト比が 3 以上のクロップでは正解率が 0.38 まで下がっていた．CLIP の標準前処理は短辺をリサイズしてから中央を切り出すため，細長いクロップでは物体の一部が失われる．クロップを黒で正方形にパディングすると，ボックス外の内容を加えずに Top-1 が約 0.08 改善した．ただし，その後の分析（report_002）で，改善は人物以外のクラス（閾値 0.9 で 0.560 → 0.677，bottle 0.344 → 0.844，car 0.378 → 0.581 等）によるものであり，人物クラスの正解率はほぼ変わらない（0.395 → 0.402）ことを確認した．person → tie 等の誤りは前処理ではなく，人物が身に着けている物や持っている物に CLIP が反応することが主因である．DETR 閾値を 0.97 にすると，対応インスタンス数（1519 件）が論文の 1466 件に近くなり，Top-1 0.604，Top-5 0.894 となった．Top-5 は論文値との差が 0.013 まで縮まったが，Top-1 にはなお 0.043 の差が残る．残りの差の要因（論文で用いた CLIP の実装・前処理・インスタンスの選別条件）は特定できていない．パイプライン全体での比較でも，ResNet50-IN1k（Top-1 が 0.09 以下）と CLIP の間には大きな差があり，4.2 節の結論と整合する．

5.2 WordNet 階層の深さごとの確信度

以下は，設定「CLIP-ViT-B/32，閾値 0.97，pad」で深さ 0 の推定が正解であった 917 件の結果である．

深さ	インスタンス数	平均候補数	平均確信度	論文 インスタンス数	論文 平均候補数	論文 平均確信度
0	917	80.0	0.642	948	80.0	0.695
1	784	108.8	0.442	854	137.2	0.477
2	328	6.2	0.715	305	6.4	0.723
3	54	14.5	0.577	54	11.3	0.586
4	18	5.7	0.755	10	6.9	0.710
5	4	10.8	0.406	1	3.0	0.729
6	—	—	—	1	1.0	1.000

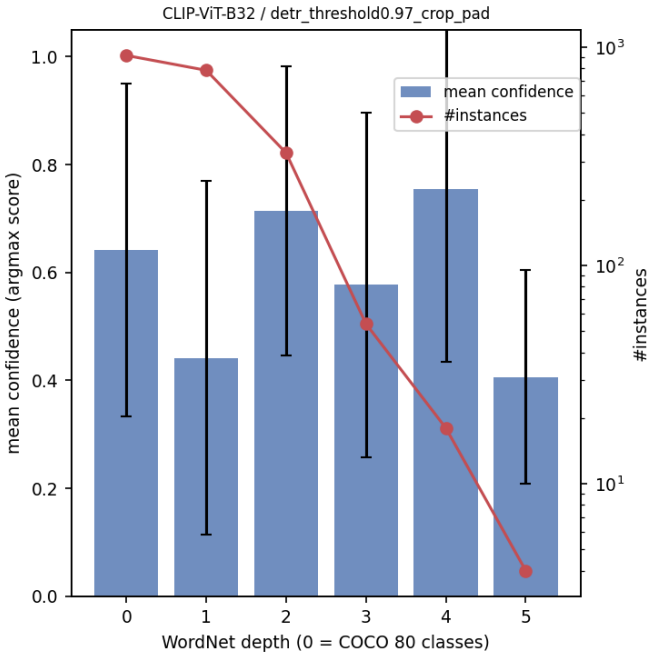


図 4　ex003 depth

上図は論文の図 3 に対応し，棒が平均確信度（誤差棒は標準偏差），折れ線がインスタンス数（対数軸）である．深さ 0 から深さ 1 にかけて確信度が 0.642 から 0.442 へ大きく低下し，深さ 2 以降は単調に低下しないという論文の観察が再現された．深さ 0〜3 のインスタンス数と確信度は論文と近い値になった．深さ 1 の平均候補数（108.8）が論文（137.2）より少ないのは，直接の下位語を候補とし表記の重複を除いた本実装の定義や，person のインスタンスの比率の違いが原因と考えられる．深さ 4 以降はインスタンス数が数件〜十数件であり，論文と同様に確信度の値を一般的な傾向として解釈することはできない．閾値 0.9，`center` の設定でも同じ傾向が得られた（`detr_threshold0.9_crop_center/table_depth.csv`）．

6. ex004：COCO 外の語を含む実画像と定性結果（論文 4.6 節，4.7 節）

`programs/ex004_open_vocab_qualitative/`，結果は `outputs/ex004_open_vocab_qualitative/CLIP-ViT-B32/` に保存した．DETR の閾値は論文 4.6 節と同じ 0.5，前処理は pad，第 1 段階の語彙は 102 語である．

- ペンギン，ヘリコプター，ラクダ，カンガルーの 4 枚では，主要被写体が第 1 段階で正しくアノテーションされた（確信度 0.74〜0.99）．



図 5　ex004 open vocab

- 下位語の段階では camel → Arabian camel（0.78）という妥当な細分化が得られ，論文と一致した．カンガルーは musk kangaroo（論文では wallaby → common wallaby），ペンギンは emperor penguin や jackass penguin となった．画像のペンギンはアデリーペンギンであり，候補に “adelie” が含まれるにもかかわらず選ばれなかったため，不正確な細分化である．
- ヘリコプターの画像では，機体（helicopter 0.99 → cargo helicopter）に加え，吊り下げられた車両の小領域が backpack（0.28）→ kitbag（1.00）とアノテーションされた．候補語彙に適切な語がない小領域に無関係な語が付くという，論文の “kite” の事例と同種の問題が再現された．
- 灯台の 2 枚では，いずれも灯台の塔そのものは検出されなかった．1 枚目では隣接する家屋 2 棟が検出され，第 1 段階で “lighthouse”（0.41，0.45）と付けられた．2 枚目では検出が 0 件であった．空を背景にした細い塔状の構造物で DETR の検出が失敗するという論文の観察と一致する．

COCO 画像に対する階層的アノテーションでは，以下の現象が見られた．

- giraffe の全 6 領域が okapi（確信度 1.00）に細分化された．`giraffe.n.01` の下位語が okapi の 1 語しかないためであり，論文 4.7 節の指摘がそのまま再現された．同じ現象はシマウマの画像中の 1 領域でも生じた．
- elephant → Indian elephant → white elephant（1.00）という推定が得られた．`indian_elephant.n.01` の下位語はアルビノのインドゾウを表す `white_elephant.n.02` の 1 語のみであり，okapi と同じく，候補が 1 語しかない分岐では画像の内容と無関係に確信度 1.00 の語が選ばれてしまう．
- cat → domestic cat（0.95）のように妥当な細分化も得られた．一方，bear → American black bear → cinnamon bear（1.00）の最後の段階も，`american_black_bear.n.01` の下位語が 1 語しかないことによるものである（report_002 で確認）．

7. 実行方法

```
cd programs/ex001_coco_val500_image_word && ../../.venv_pytorch/bin/python train.py
cd programs/ex002_coco_4img_class_agnostic_det && ../../.venv_pytorch/bin/python train.py
cd programs/ex003_coco_val500_pipeline && ../../.venv_pytorch/bin/python train.py
cd programs/ex004_open_vocab_qualitative && ../../.venv_pytorch/bin/python train.py
```

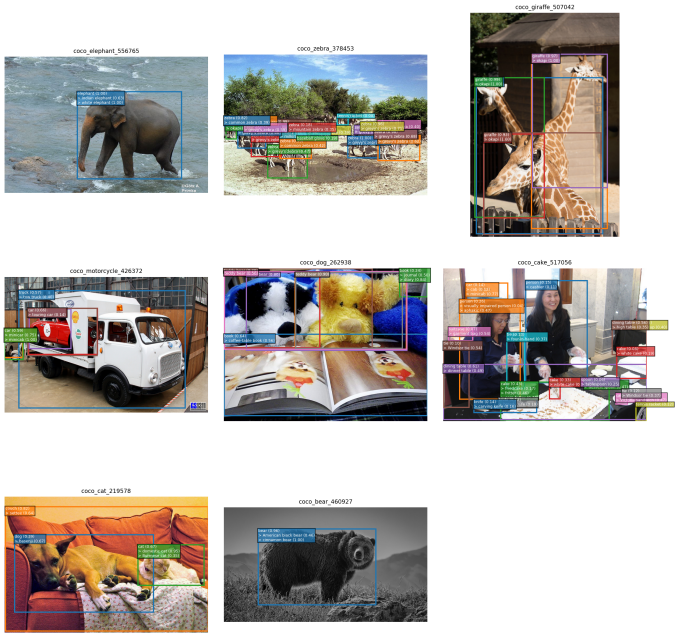


図 6　ex004 coco

```
.venv_pytorch/bin/jupyter nbconvert --to notebook --execute --inplace visualize_result.ipynb
.venv_pytorch/bin/python -m pytest tests    # 7件すべて成功
```

8. 未解決の論点と次に検討すべき作業の候補

1. **Top-1 の残差（0.604 vs 0.647）**：論文で用いた CLIP の実装（Hugging Face `openai/clip-vit-base-patch32` か open_clip か），クロップの前処理，評価インスタンスの選別条件（1466 件の内訳）が不明である．クロップの前処理（パディング色，正方形へのリサイズ，プロンプトのアンサンブル）を追加で比較すれば，差の要因を切り分けられる可能性がある．
2. **ex002 の規模**：4 画像・10 インスタンスでは統計的な比較ができない．500 枚全体で 3 手法の Recall@IoU0.5 と平均最良 IoU を比較し，Wilcoxon 検定を適用することが望ましい．検出の閾値も論文に記載がない．
3. **タスク B の語彙の差（1371 語 vs 1452 語）**：ストップワード除去の有無など，抽出条件を変えて論文の語彙数に合わせる検討が残っている．
4. **WordNet 階層のフィルタリング**：giraffe → okapi，Indian elephant → white elephant のように候補が 1 語しかない分岐で確信度 1.00 の語が選ばれる問題に対し，そうした分岐の打ち切りや，非視覚的な語義・絶滅種の除外（論文 5.4 節の今後の課題）を実装し，深さごとの確信度がどう変わるかを評価することが次の候補である．
5. **候補語彙に正解がない領域の棄却**：helicopter の吊り荷のような領域に対する確信度の閾値処理を，ex003 の確信度分布に基づいて設計できる．
6. **深さ 2 以降のインスタンス数不足**：より大規模なデータ（COCO val の全 5000 枚）で深さごとの確信度を再評価することが考えられる．