report_002：再現実験の結果に基づく和文論文の作成

1. 概要

order_001 の実験（ex001〜ex004）の結果をもとに，和文論文 `paper/main.pdf`（9 ページ，二段組，`ieicejsp.cls`）を作成した．章構成は再現対象の `main.pdf` を踏襲し，数値・図表はすべて本プロジェクトの `outputs/` の実測値を用いた．投稿先，ページ数制限，締切は指定されていないため，再現対象と同程度の分量とした．著者名と所属はプレースホルダのままである．

項目	内容
ソース	`paper/main.tex`，`paper/sections/00_abstract.tex`〜`07_references.tex`
図	`paper/figures/`（`paper/make_figures.py` で `outputs/` から生成）
ビルド	`cd paper && latexmk -pdfdvi -synctex=1 main.tex`（Overfull 等の警告なし）
分量	9 ページ，図 7，表 4，式 9，参考文献 15 件

2. 論文の構成

章	内容	対応する実験
1 はじめに	背景，提案の概要，4 つの貢献	—
2 関連研究	閉域検出，オープンボキャブラリ検出，CLIP，階層分類	—
3 提案手法	全体設計（図 1），DETR，VLM によるアノテーション（式 (1)〜(3)，正方形パディング），WordNet（式 (4)），f の実装（式 (5)，(6)）	—
4.2	ResNet50-IN1k vs CLIP（表 1，図 2，Wilcoxon 検定）	ex001
4.3	DETR vs OWL-ViT vs Grounding DINO（表 2）	ex002
4.4	パイプライン全体の精度，閾値と前処理の影響（表 3，図 3，図 4）	ex003
4.5	WordNet の深さごとの確信度と単一候補の分岐（表 4，図 5）	ex003
4.6，4.7	COCO 外の語の実画像（図 6），COCO 画像の定性結果（図 7）	ex004
5 考察	差別化点，前処理と閾値の影響，WordNet の限界，COCO 学習分布への依存，今後の課題	—
6 おわりに	まとめ	—

3. 論文作成のために追加で行った分析

論文の記述の根拠として，既存の出力（`instances.json`，`annotations.json`）に対して以下の集計を追加で行った．新たな推論は行っていない．

3.1 クロップの前処理の効果の内訳

`outputs/ex003_coco_val500_pipeline/CLIP-ViT-B32/` の center と pad を同一インスタンスで比較した．

集計（CLIP-ViT-B/32）	center	pad
全体の Top-1（ $\theta = 0.9$ ）	0.506	0.587
人物以外の Top-1（ $\theta = 0.9$ ）	0.560	0.677
人物の Top-1（ $\theta = 0.9$ ）	0.395	0.402
高さが幅の 2 倍以上のクロップの Top-1（ $\theta = 0.9$, 433 件）	0.441	0.545
人物の Top-1（ $\theta = 0.97$ ）	0.377	0.383
bottle の Top-1（ $\theta = 0.97$, 32 件）	0.344	0.844
car の Top-1（ $\theta = 0.97$, 74 件）	0.378	0.581

$\theta = 0.97$ では，pad によって正解に転じたインスタンスが 217 件，不正解に転じたインスタンスが 97 件であった．パディングによる改善は人物以外のクラスによるものであり，person → baseball bat / tie / tennis racket 等の誤りは前処理では解消されない．これに伴い，report_001 の 5.1 節の「縦長の人物クロップでは胴体付近だけが残り，ネクタイ等の付属物が支配的になる」という説明は誤りであったため訂正した．

3.2 WordNet 階層における単一候補の分岐

`detr_threshold0.97_crop_pad` の 917 件について，深さ 1 以降の全 1188 段階のうち 209 段階（約 18%，208 インスタンス）で候補語彙が 1 語のみであった．CLIP のスコアはソフトマックス（論文の式 (6)）であるため，これらの段階の確信度は必ず 1.00 になる．

深さ	段階数	単一候補	平均確信度（全体）	平均確信度（単一候補を除く）
1	784	80	0.442	0.378
2	328	110	0.715	0.571
3	54	10	0.577	0.481
4	18	9	0.755	0.511
5	4	0	0.406	0.406

深さ 2 以降で確信度が「回復」して見える現象の一部は，単一候補の分岐によるものである．頻出する単一候補の語は okapi（28 件，giraffe），spindlelegs（24 件，person → thin person），moped（18 件，motorcycle → minibike），gamp（13 件，umbrella）であった．また，person の深さ 1 では suspect（20 件），thin person（24 件），visually impaired person（9 件）など，外見から判断できない語が選ばれていた．

3.3 report_001 の訂正

論文作成時の確認で，report_001 に以下の誤りを見つけて訂正した．

- タスク A の評価画像数：497 枚 → 491 枚（`config.json` の `n_evaluated_images`）
- 5.1 節：パディングの効果の説明（3.1 節を参照）
- 6 章：bear → American black bear → cinnamon bear を「妥当な細分化」としていたが，`american_black_bear.n.01` の下位語が 1 語のみのため確信度 1.00 になったものであった．Indian elephant → white elephant も同様に単一候補の分岐である（white elephant はアルビノのインドゾウを指す語義であり，「非視覚的な語義」とした当初の記述は誤り）

4. 再現対象の論文（`main.pdf`）との主な違い

作成した論文は再現実験の実測値に基づくため，以下の点で `main.pdf` と異なる．

- Top-1/Top-5 正解率は 0.647/0.907 ではなく 0.604/0.894 である．
- クロップを正方形にパディングする前処理（式 (3)）を手法として明記し，その効果を 4.4 節・5.2 節で示した．
- 検出スコアの閾値 θ を明記し，0.5〜0.97 で比較した．
- 4.3 節では，選んだ 4 画像で全手法の Recall が 1.0 に達しないことと，その原因を記載した．
- 4.5 節・5.3 節に，単一候補の分岐の頻度と，それを除いた確信度の分析を追加した．
- 定性結果の具体例（kangaroo → musk kangaroo，helicopter の吊り荷 → backpack 等）は再現実験で得られたものに置き換えた．

5. 未解決の論点と次に検討すべき作業の候補

1. **著者情報と投稿先**：著者名・所属はプレースホルダである．投稿先が決まった場合，ページ数制限に合わせて分量を調整する必要がある（現状 9 ページ）．
2. **英文アブストラクト**：テンプレートの和文形式に合わせて和文の概要のみを記載した．投稿先が英文アブストラクトを要求する場合は追加が必要である．
3. **ex002 の評価規模**：論文中でも「統計的な結論を得るには評価規模の拡大が必要」と記載した．500 枚規模の比較を行えば 4.3 節の主張を強化できる．
4. **Top-1 正解率の改善**：人物クラスの正解率（約 0.38）が全体の精度を制限している．プロンプトの設計や，他の検出領域との包含関係を考慮した手法の検討が考えられる（論文 5.5 節の第五の課題）．
5. **WordNet 階層のフィルタリングの実装**：論文で今後の課題とした単一候補の分岐の打ち切りや，外見から判断できない語の除外を実装し，深さごとの確信度の変化を評価できる．
6. **ai-agent による検証**：`tokens.json` が存在しないため，documentation エージェントによる論文 PDF の検証は実行していない．