report_003：閉域物体検出モデル YOLO との比較と論文への追記

1. 概要

提案パイプライン（DETR + 局所クロップ + CLIP-ViT-B/32）と，COCO の 80 クラスで学習した閉域物体検出モデル YOLO を，YOLO 自体の語彙（COCO の 80 クラス）で比較した（ex005）．結果を論文 `paper/main.pdf` の 4.8 節として追記し，関連する箇所も修正した．修正箇所は赤字で示している．

比較	主な結果
COCO 80 クラスでのカテゴリアノテーション精度	YOLO の Top-1 は 0.957〜0.993 で，提案手法（0.560〜0.604）を大きく上回る
共通 GT インスタンスでの比較	YOLO11x 0.989 vs 提案手法 0.609（1480 件，McNemar 検定で $p < 10^{-150}$ ）
差の要因	YOLO11x のボックスを CLIP で分類すると 0.565〜0.604 となり，提案手法とほぼ一致した．差は検出器ではなく分類器に起因する
位置検出精度（4 画像）	YOLOv8x 0.800 / 0.767，YOLO11x 0.700 / 0.719（Recall@IoU0.5 / 平均最良 IoU）．DETR の 0.800 / 0.705 と同程度
COCO 外の語の実画像	YOLO は penguin → bird，camel → dog，kangaroo → bear / sheep，helicopter → airplane．灯台は検出なし

2. 実験条件

`programs/ex005_coco_val500_yolo_comparison/`，結果は `outputs/ex005_coco_val500_yolo_comparison/` に保存した．

項目	設定
YOLO	Ultralytics 8.3.170 の学習済みモデル YOLO11n，YOLO11m，YOLO11x，YOLOv8x（COCO train2017 で学習済み，追加学習なし）
語彙	YOLO のクラス名は COCO の 80 クラス名と完全一致することを確認した
検出スコアの閾値	0.25（既定値），0.5，0.7．NMS の IoU 閾値は既定値の 0.7
評価画像	ex003 と同じ seed=42 の 500 枚（GT インスタンス 3206 件），ex002 の 4 画像，ex004 の実画像 6 枚
対応付け	ハンガリアン法で IoU 0.5 以上の 1 対 1 対応
Top-5	NMS の `return_idxs` で残ったアンカーを特定し，生出力の 80 クラスのスコアから上位 5 件を取得した（Top-1 は YOLO の出力ラベルと一致することを確認）
正命名率 r	Top-1 が正解したインスタンス数を GT インスタンス総数（3206 件）で割った値．手法間で対応インスタンス数が異なるため導入した
共通 GT での比較	YOLO と ex003（CLIP-ViT-B/32，pad，$\theta = 0.5$ と 0.97）の両方が対応付けた GT インスタンスで Top-1 を比較し，正確な McNemar 検定（二項検定）を行った
YOLO-box + CLIP	YOLO11x の対応インスタンスのクロップを pad で CLIP-ViT-B/32 に入力し，COCO の 80 クラスで分類した

実行時間は全条件で 107 秒，ピーク VRAM は 1.8GB，ピーク RAM は 3.9GB であり，並列数は 1 とした．

3. 結果

3.1 COCO 80 クラスでのカテゴリアノテーション精度

手法	閾値	n	Top-1	Top-5	正命名率 r
提案手法（ex003）	$\theta = 0.5$	2343	0.560	0.855	0.410
提案手法（ex003）	$\theta = 0.97$	1519	0.604	0.894	0.286
YOLO11n	0.25 / 0.5 / 0.7	1717 / 1278 / 904	0.957 / 0.970 / 0.987	0.996 / 0.996 / 0.997	0.513 / 0.387 / 0.278
YOLO11m	0.25 / 0.5 / 0.7	2115 / 1699 / 1314	0.976 / 0.985 / 0.992	0.998 / 0.999 / 0.999	0.644 / 0.522 / 0.406
YOLO11x	0.25 / 0.5 / 0.7	2210 / 1832 / 1474	0.981 / 0.985 / 0.993	0.999 / 0.998 / 0.997	0.676 / 0.563 / 0.456
YOLOv8x	0.25 / 0.5 / 0.7	2220 / 1844 / 1467	0.971 / 0.984 / 0.987	0.999 / 0.999 / 0.999	0.672 / 0.566 / 0.452
YOLO11x + CLIP	0.25 / 0.5 / 0.7	2210 / 1832 / 1474	0.565 / 0.589 / 0.604	0.860 / 0.889 / 0.907	0.390 / 0.337 / 0.278

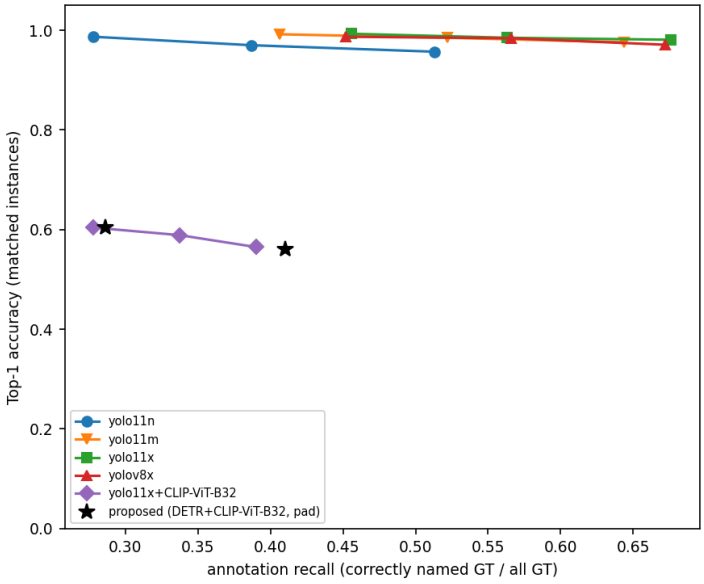


図 1　ex005

上図の横軸は正命名率，縦軸は対応インスタンスの Top-1 正解率である．YOLO は対応インスタンスの正解率と正命名率の両方で提案手法を上回った．YOLO11x + CLIP の点は提案手法（★）とほぼ同じ位置にあり，検出器を YOLO に替えても分類を CLIP で行う限り精度は変わらないことがわかる．

3.2 共通 GT インスタンスでの比較

`common_vs_*.json`，`table_common_mcnemar.csv` に全条件を保存した．以下は代表的な条件である．

YOLO	提案手法	共通件数	YOLO Top-1	提案 Top-1	YOLO のみ正解	提案のみ正解	McNemar p	人物 YOLO / 提案	人物以外 YOLO / 提案
YOLO11x 0.25	$\theta = 0.97$	1480	0.989	0.609	570	8	6.0×10^{-157}	0.998 / 0.379	0.984 / 0.732
YOLO11x 0.25	$\theta = 0.5$	2015	0.984	0.586	816	15	6.0×10^{-219}	0.998 / 0.407	0.976 / 0.675
YOLO11n 0.25	$\theta = 0.97$	1325	0.980	0.611	503	14	4.5×10^{-129}	0.994 / 0.357	0.971 / 0.757

全 24 の組合せで YOLO が有意に高かった．差の大部分は人物クラス（YOLO 約 1.0 vs 提案手法 約 0.38）によるが，人物以外でも 0.25 前後の差がある．

3.3 位置検出精度（ex002 の 4 画像，GT 10 件）

手法	閾値	平均提案数	Recall@IoU0.5	平均最良 IoU
DETR（ex002）	0.5	2.25	0.800	0.705
YOLO11n	0.25	1.50	0.600	0.569
YOLO11m	0.25	2.00	0.700	0.668
YOLO11x	0.25	2.25	0.700	0.719
YOLOv8x	0.25	2.25	0.800	0.767

閾値 0.5 と 0.7 の結果は `table_loc4.csv` に保存した（いずれも Recall 0.5〜0.6）．YOLOv8x と DETR は同程度であり，4 画像では統計的な差を論じられない．

3.4 COCO 外の語を含む実画像

YOLO11x（閾値 0.25）の結果は以下のとおりである（`yolo11x/open_vocab_conf0.25/42/grid.png`）．

画像	YOLO11x	提案手法（ex004）
penguin	bird（0.28〜0.90）×13，boat	penguin（0.74〜0.99）
helicopter	airplane（0.85），吊り荷→ boat（0.39），person（0.34）	helicopter（0.99），吊り荷→ backpack
camel	dog（0.87）	camel（0.99）→ Arabian camel
kangaroo	bear（0.82），sheep（0.48）	kangaroo（0.93，0.97）
lighthouse_1，2	検出なし	家屋 2 棟を検出（1 枚目），検出なし（2 枚目）

4. 論文への追記（赤字）

箇所	内容
概要	YOLO との比較の結論を 1 文追加
1 章	貢献の第二に YOLO との比較を追加
2.1 節	比較対象として YOLO11・YOLOv8 を挙げ，4.8 節を参照
4.3 節，表 2	YOLO11x，YOLOv8x（閾値 0.25）の位置検出精度の行と説明文を追加．最良の平均最良 IoU の太字を YOLOv8x に変更
4.8 節（新設）	実験条件，正命名率（式 (8)），表 5，図 8（正命名率と Top-1 の関係），図 9（COCO 外画像での YOLO の結果），共通 GT での比較，YOLO11x + CLIP による要因の切り分け
5.1 節	80 クラスの範囲内では YOLO が大幅に高精度であり，本手法の利点は語彙と粒度の柔軟性にあることを追記
5.5 節	今後の課題の第六として，YOLO の予測を深さ 0 に用いる組合せを追加
6 章	第五の結論として YOLO との比較を追加し，今後の課題を追記
参考文献	[16] Ultralytics YOLO を追加

論文は 9 ページから 11 ページになった．`latexmk` によるコンパイルで Overfull 等の警告はない．図は `paper/make_figures.py` に `fig_yolo_open_vocab()` と `fig_yolo_comparison()` を追加して作成した．

5. 考察

COCO の 80 クラスで教師あり学習した YOLO は，同じ 80 クラスの範囲内では，ゼロショットの CLIP を用いる提案手法より大幅に高精度である．YOLO11x + CLIP の結果から，この差は分類器の差であり，DETR を検出器に用いたことによる不利ではない．したがって，論文の主張は「80 クラス内での精度」ではなく，「学習時の語彙を超えた語や粒度でのアノテーションを再学習なしに行える

こと」に置く必要があり，論文の 5.1 節をそのように修正した．一方，COCO 外の物体に対しては，YOLO は最も近い 80 クラスの語（bird，dog，bear 等）を高い確信度で出力するため，誤りに気付きにくいという問題もある．

6. 未解決の論点と次に検討すべき作業の候補

1. **YOLO と VLM の組合せ**：YOLO の予測を深さ 0 とし，深さ 1 以降の細分化のみを CLIP で行う組合せ（論文 5.5 節の第六の課題）は未実施である．80 クラス内の精度と粒度可変性を両立できるかを評価できる．ex005 の `instances.json` と ex003 の階層アノテーションの関数を再利用すれば短時間で実施できる．
2. **COCO 外の物体に対する YOLO の誤りの定量化**：ex004 の 6 枚のみの定性比較である．LVIS や OpenImages のように COCO 外のカテゴリを含むデータセットで，YOLO と提案手法の正命名率を比較することが考えられる．
3. **人物クラスの誤り**：提案手法と YOLO の差の大部分は人物クラスによる．プロンプトの設計等で人物の誤りを改善できれば，差を縮められる可能性がある．
4. **論文の分量**：11 ページになった．投稿先のページ制限によっては，表 5 または図 8 のどちらかを削るなどの調整が必要である．
5. **赤字の扱い**：次の修正依頼があった場合は，規約に従い今回の赤字を黒字に戻した上で新たな修正箇所のみを赤字にする．