report_006：YOLO と CLIP を組み合わせたハイブリッド構成の実装と論文への追記

1. 概要

深さ 0 のカテゴリを YOLO11x の予測とし，深さ 1 以降の細分化のみを CLIP-ViT-B/32 と WordNet で行うハイブリッド構成を実装した（ex006）．COCO 外の物体に対しては，CLIP が COCO の 80 クラスと COCO 外の 22 語の中で COCO 外の語を最上位に選んだ場合に，深さ 0 を CLIP の語へ切り替える規則も評価した．結果を論文 `paper/main.pdf` の 4.9 節として追記し，概要，はじめに，考察，おわりにの関連箇所も修正した．規約に従い，order_003 で赤字にした箇所を黒字に戻した上で，今回の修正箇所のみを赤字にした．

項目	主な結果
深さ 0 の Top-1 正解率	切替なしで 0.981〜0.993（YOLO11x と同じ）．提案手法は 0.560〜0.604
階層アノテーションの対象数 N_h	閾値 0.25 で 2167 件．提案手法の $\theta = 0.5$ の 1313 件の 1.65 倍，$\theta = 0.97$ の 917 件の 2.36 倍
深さ 1 の推定の一致率	提案手法（ $\theta = 0.97$ ）と共通の 761 件で 0.775．同じ CLIP を用いるため，不一致はボックスの違いによる
切替（ $\gamma = 0$ ）	COCO の 500 枚で 47 件が切り替わり，すべて YOLO が正解していたインスタンスであった（Top-1 は 0.981 から 0.959 に低下）
切替（ $\gamma = 0.5$ ）	COCO の 500 枚では切替が 0 件で，切替なしと同一．COCO 外の実画像では penguin，helicopter，camel，kangaroo に正しく切り替わった

2. 手法

YOLO11x が出力した領域 k のボックスを $\mathbf{b}_k$ ，クラスを y_k とする．COCO 外の 22 語の集合を $\mathbb{V}_E$ ，102 語の候補語彙 $\mathbb{V}^{(0)} \cup \mathbb{V}_E$ に対する CLIP の推定単語を u_k とし，深さ 0 の単語を次のように決める．

$$\hat{v}_k^{(0)} = \begin{cases} u_k & (u_k \in \mathbb{V}_E \text{ かつ } f(\mathbf{X}_k; \mathbb{V}^{(0)} \cup \mathbb{V}_E)_{u_k} \geq \gamma) \\ y_k & (\text{それ以外}) \end{cases}$$

ここで，f は CLIP-ViT-B/32，$\mathbf{X}_k$ は YOLO のボックスを切り出して pad で正方形にしたクロップ，γ は切替に必要な確信度の下限である．深さ 1 以降は，提案手法と同じ `hierarchical_annotation`（論文の式 (3)）で WordNet の下位語をたどる．

構成名（`outputs/` の手法名）	深さ 0 の決定
`hybrid`	常に YOLO のクラス
`hybrid_switch`	$\gamma = 0$ で切替
`hybrid_switch_c0.5`	$\gamma = 0.5$ で切替（1 回目の実行結果を確認した後に追加した）

3. 実験条件

`programs/ex006_coco_val500_yolo_clip_hybrid/`，結果は `outputs/ex006_coco_val500_yolo_clip_hybrid/` に保存した．

項目	設定
評価画像	ex003，ex005 と同じ seed=42 の 500 枚（GT インスタンス 3206 件）
YOLO	YOLO11x（検出スコアの閾値 0.25，0.5，0.7）．ex005 の `instances.json`（GT との対応付け済み）を再利用した
VLM	CLIP-ViT-B/32，プロンプト “a photo of a {}”，pad
階層アノテーションの対象	深さ 0 の推定が GT カテゴリと一致したインスタンス（ex003 と同じ）

項目	設定
比較対象	提案手法（ex003，DETR + CLIP-ViT-B/32，pad，$\theta = 0.5$ と 0.97）
一致率	両手法の深さ 0 が正解となった共通の GT インスタンスのうち，両方に深さ 1 が存在するものにおける深さ 1 の単語の一致率
定性評価	ex004 の COCO 外の語を含む実画像 6 枚と，ex004 の COCO 画像 8 枚（YOLO11x の閾値 0.25）

COCO の 500 枚の評価に要した時間は，WordNet の階層をたどる処理を含めて 1 条件あたり 15〜28 秒，ピーク VRAM は 1.18GiB であり，並列数は 1 とした．

4. 結果

4.1 COCO の 500 枚での比較

`visualize_result.ipynb` が出力した `table_hybrid.csv` の値である．

手法	閾値	n	深さ 0 の Top-1	正命名率 r	N_h	切替数	深さ 1 の一致率（$\theta = 0.97$ と比較）
提案手法	$\theta = 0.5$	2343	0.560	0.410	1313	–	–
提案手法	$\theta = 0.97$	1519	0.604	0.286	917	–	–
hybrid	0.25	2210	0.981	0.676	2167	0	0.775
hybrid	0.5	1832	0.985	0.563	1804	0	0.776
hybrid	0.7	1474	0.993	0.456	1463	0	0.796
hybrid_switch	0.25	2210	0.959	0.661	2120	47	0.780
hybrid_switch	0.5	1832	0.964	0.551	1766	38	0.780
hybrid_switch	0.7	1474	0.974	0.448	1436	27	0.799
hybrid_switch_c0.5	0.25 / 0.5 / 0.7	hybrid と同一	hybrid と同一	hybrid と同一	hybrid と同一	0	hybrid と同一

左図の横軸は階層アノテーションの対象となった GT インスタンス数 N_h，縦軸は深さ 0 の Top-1 正解率である．ハイブリッド構成（$\gamma = 0.5$ は hybrid と重なる）は，提案手法（★）より右上にあり，深さ 0 の精度と階層アノテーションの対象数の両方で上回った．右図は深さ 1 以降の平均確信度である（seed は 1 つのため誤差棒はない）．

深さ 1 の平均確信度は，ハイブリッド構成（閾値 0.25）で 0.366，提案手法（$\theta = 0.97$ ）で 0.442 であった．ハイブリッド構成では人物クラスが正しく推定されるため，人物のインスタンスが対象の 32.9%（712 件）を占める．`person.n.01` の下位語は平均 398 語あり，人物の深さ 1 の平均確信度は 0.080 であった．人物以外に限ると，深さ 1 の平均確信度はハイブリッド構成で 0.537，提案手法で 0.572 であった．深さ 1 以降で下位語が 1 語しかない段階の割合は 15.0%（2712 段階中）であった．

4.2 COCO 外の語への切替

$\gamma = 0$ では，切り替わった 47 件（閾値 0.25）はすべて YOLO が正解していたインスタンスであった．主な内訳は，sheep → camel（8 件），person → dolphin，monkey，penguin（各 3 件）等である．bird → eagle（1 件）のように，切替先が GT カテゴリの下位語である場合も不正解として数えている．$\gamma = 0.5$ では，COCO の 500 枚のいずれの閾値でも切替は生じなかった．

4.3 定性評価

`hybrid_switch_c0.5/open_vocab_conf0.25/42/grid.png`, `hybrid_switch_c0.5/coco_qualitative_conf0.25/42/grid.png` に保存した．論文の図 10（`paper/figures/fig_hybrid_qualitative.pdf`）はこの結果から作成した．

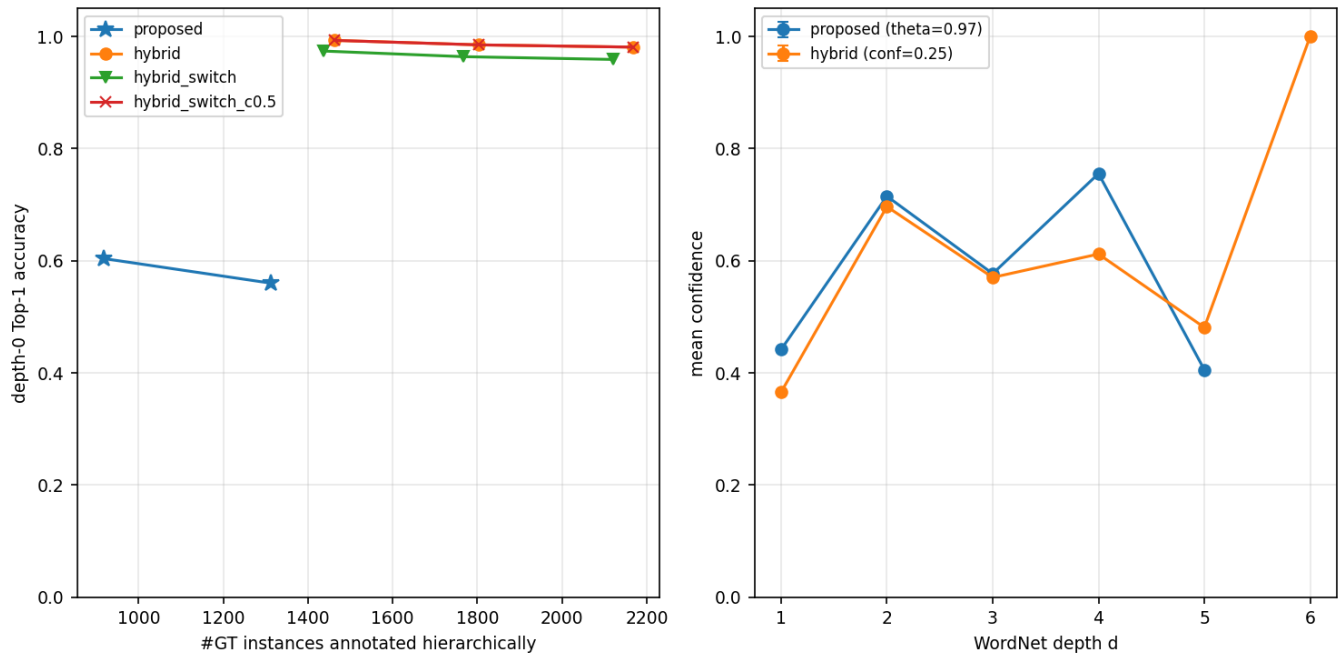


図 1　ex006

画像	YOLO11x の出力	ハイブリッド構成（$\gamma = 0.5$）
penguin	bird（13 件）	penguin（CLIP の確信度 0.78〜0.99）→ emperor penguin，jackass penguin，rock hopper
helicopter	airplane	helicopter（0.99）→ cargo helicopter
camel	dog	camel（0.99）→ Arabian camel（0.77）
kangaroo	bear，sheep	kangaroo（0.85，0.84）→ musk kangaroo
lighthouse_1，2	検出なし	検出なし
COCO 219578	dog（0.92），cat（0.78），couch（0.88）	dog → basenji（0.72），cat → domestic cat（0.93）→ Burmese cat（0.21），couch → settee（0.63）
COCO 507042	giraffe	giraffe → okapi（1.00）．単一候補の分岐は解消されない

$\gamma = 0$ では，COCO の犬の画像（262938）で，YOLO が book（0.30）と出力した領域が parrot（0.18）に切り替わったが，$\gamma = 0.5$ ではこの切替は生じなかった．

5. 論文への追記（赤字）

箇所	内容
全体	order_003 で赤字にした箇所（4.8 節，概要，1 章，2.1 節，4.3 節，5.1 節，5.5 節，6 章，参考文献）を黒字に戻した
概要	ハイブリッド構成の結果を 1 文追加
1 章	貢献の第二にハイブリッド構成の評価を追加
4.9 節（新設）	手法（式 (9)），実験条件，表 6，図 10，深さ 1 の確信度と一致率，切替の結果と限界
5.1 節	検出とカテゴリのアノテーションの分離により YOLO と VLM の利点を組み合わせられることを追記
5.5 節	第六の課題（YOLO と VLM の組合せ）を，切替の閾値の検証と深さ 1 以降の正誤評価に置き換えた
6 章	第六の結論を追加し，今後の課題を更新

論文は 11 ページから 12 ページになった．`latexmk` によるコンパイルで Overfull の警告はない．図 10 は `paper/make_figures.py` に `fig_hybrid_qualitative()` を追加して作成した．

6. 考察

ハイブリッド構成は，検出とカテゴリのアノテーションを分離した設計により，深さ 0 のみを YOLO に置き換えられることを示している．深さ 0 の精度は YOLO と同じになり，深さ 0 の誤りによって誤った分岐をたどるインスタンスが減るため，粒度可変のアノテーションを付与できる GT インスタンスが大幅に増えた．一方，深さ 1 の推定はボックスの違いだけで約 2 割が変化しており，細かい粒度の推定はクロップに敏感である．COCO 外の語への切替は，$\gamma = 0$ では COCO の物体を誤って切り替えるため有害であり，確信度の下限が必要である．ただし，$\gamma = 0.5$ は同じ 500 枚の結果を見て選んだ値であり，COCO 外の物体の評価も 6 枚の定性評価にとどまる．

7. 未解決の論点と次に検討すべき作業の候補

1. **切替の閾値 γ の検証**：$\gamma = 0.5$ は評価に用いた 500 枚の結果を見て追加した．COCO の別の画像（val2017 の残り 4500 枚）で切替が生じないか，COCO 外のカテゴリを含むデータセット（LVIS 等）で切替が正しく働くかを検証する必要がある．
2. **深さ 1 以降の正誤評価**：COCO には細かい粒度の正解がないため，ハイブリッド構成と提案手法の深さ 1 以降の優劣は評価していない．Stanford Dogs，CUB-200，LVIS 等で評価できる．
3. **人物クラスの細分化**：ハイブリッド構成では人物の深さ 1 の平均確信度が 0.080 と低く，`person.n.01` の下位語（平均 398 語）は外見で判断できない語を多く含む．WordNet 階層の選別（チャットでの提案 4）と組み合わせることが考えられる．
4. **単一候補の分岐**：giraffe → okapi のような分岐は深さ 0 の推定を変えても解消されない（深さ 1 以降の段階の 15.0%）．
5. **スライドへの反映**：`slides_object_annotation.pptx` にはハイブリッド構成を反映していない．
6. **ai-agent による検証**：`tokens.json` が存在しないため，AI エージェントによる論文の検証は実行していない．