report_008：粒度可変アノテーションの評価の改善（ex007）

1. 概要

order_008 では，直前に提案した改善策を次の順に実施した．

1. **A1・A5**：評価数 n を揃えた比較と，深さ 0 の誤りの伝播の評価
2. **B1・A3**：累積確信度による細分化の停止規則と，検証用・テスト用のデータ分割
3. **A4**：LVIS v1 を用いた深さ 1 以降の正誤の評価

新しい実験 `programs/ex007_coco_val_hierarchy_eval/` を作成した．結果は論文（4.9 節の訂正，4.10 節・4.11 節の追加）とスライド（19・20・26 枚目の訂正，23〜25 枚目の追加）に反映した．

また，作業中に **ex006 の不具合** を発見し，修正した．`hybrid_switch_c0.5`（$\gamma = 0.5$）で CLIP のスコアが計算されておらず，切替の判定が一度も行われていなかった．そのため，order_006 で報告した「$\gamma = 0.5$ では 500 枚のいずれの閾値でも切替は 0 件」は誤りである．正しくは，閾値 0.25 で 2 件，0.5 で 2 件，0.7 で 1 件の誤った切替が生じる．定性結果の図（論文の図 10）は別の関数で計算しており，この不具合の影響を受けていない．

項目	内容
データ	COCO 2017 val の 5000 枚．LVIS v1 val のアノテーションがある画像は 4809 枚
分割（seed 42）	dev500：これまでの 500 枚．test500：残り 4500 枚を 2 等分した後半から 500 枚（GT 3748 件）．lvis_dev：dev500 と前半（2604 枚）．lvis_test：後半（2148 枚）
手法	提案手法（DETR，$\theta \in \{0.5, 0.7, 0.9, 0.97\}$），ハイブリッド構成（YOLO11x，閾値 $\in \{0.25, 0.5, 0.7\}$），切替あり（$\gamma = 0$，$\gamma = 0.5$）
展開	深さ 0 の正誤によらず，全インスタンスについて下位語の集合が空になるまで展開する
停止規則	累積確信度 $c^{(d)} = \prod_{j \le d} p_j$ が τ 以上の最も深い段階まで出力する．$c^{(0)} < \tau$ なら棄却する．比較として深さの上限（0〜3）で止める規則も評価した
τ の決定	lvis_dev で階層的 F 値 hF が最大となる値を 13 通りから選ぶ
実行	検出（DETR，YOLO11x）は 5000 枚に対して 1 回ずつ実行した．全条件の合計は約 15 分，ピーク VRAM は 1.05 GiB
確認	dev500 の n，Top-1 正解率，N_h は ex003・ex005・ex006 の値と一致した．テストは 17 件すべて合格

2. 結果

2.1 A1：評価数を揃えた比較（`table_conditions.csv`，`table_pairs_agreement.csv`）

分割	提案手法	n	N_h	ハイブリッド	n	N_h	倍率	深さ 1 の一致率
dev500	θ =0.5	2343	1313	0.25	2210	2167	1.65	0.751
dev500	θ =0.97	1519	917	0.7	1474	1463	1.60	0.796
test500	θ =0.5	2736	1509	0.25	2572	2492	1.65	0.704
test500	θ =0.97	1669	1043	0.7	1584	1556	1.49	0.750

- **「2.4 倍」の訂正：**これまでスライドに書いていた「2.4 倍」は，n が揃っていない組（917 件と 2167 件）の比較であった．n を揃えると 1.49〜1.65 倍である．
- **深さ 1 の一致率：**test500 では 0.70〜0.75 である．検出器が違うだけで，約 3 割の物体で細分化の結果が変わる．

2.2 A5：深さ 0 の誤りの伝播（test500）

指標	提案手法（θ =0.5）	ハイブリッド（0.25）
誤った枝に展開した割合	0.448（1227 件）	0.031（80 件）
最深段の確信度の平均（正しい枝 / 誤った枝）	0.599 / 0.473	0.547 / 0.637
AUROC：最深段の確信度	0.611	0.418
AUROC：累積確信度	0.508	0.430
AUROC：深さ 0 の確信度	0.725	0.715

- **深い段階の確信度は誤りの手がかりにならない：**誤った枝では，誤った語の下位語の中から選ぶため，最深段の確信度で正しい枝と区別できない（AUROC はおおむね 0.5 以下）．ハイブリッド構成では，誤った枝の方がむしろ確信度が高かった．
- **手がかりは深さ 0 の確信度のみ：**AUROC は約 0.72 であった．

2.3 γ の検証（test500，閾値 0.25）

構成	切替数	深さ 0 の Top-1 正解率	GT カテゴリの下位語でない切替
切替なし	0	0.969	0
γ =0	50	0.950	41
γ =0.5	8	0.966	2（bear → panda，teddy bear → rabbit）

- **8 件の内訳：**$\gamma = 0.5$ の 8 件のうち 6 件は，bird → flamingo（4 件），parrot，penguin であった．いずれも WordNet で GT カテゴリの下位語であり，COCO の評価では誤りになるが，意味としては細かい正しい語である．
- **dev500 の 2 件：**sheep → camel（0.629）と bird → eagle（0.546）であった．

2.4 A4・B1：LVIS による深さ 1 以降の評価と停止規則（`table_stopping.csv`）

手法	停止規則	被覆率	Top-1	hP	hR	hF	LVIS の語まで到達
提案手法（θ =0.5, 489 件）	なし	1.000	0.646	0.425	0.430	0.428	0.272

手法	停止規則	被覆率	Top-1	hP	hR	hF	LVIS の語まで到達
提案手法（θ=0.5, 489 件）	深さ 1 まで	1.000	0.646	0.490	0.417	0.451	0.256
提案手法（θ=0.5, 489 件）	τ=0.2	0.775	0.792	0.611	0.372	0.462	0.192
ハイブリッド (0.25, 481 件）	なし	1.000	0.971	0.594	0.631	0.612	0.372
ハイブリッド (0.25, 481 件）	深さ 1 まで	1.000	0.971	0.683	0.617	0.648	0.353
ハイブリッド (0.25, 481 件）	τ=0.3	0.975	0.970	0.801	0.543	0.647	0.237

- **深さ 1 の正解は半数未満：**深さ 0 が正しいインスタンスに限っても，深さ 1 の語が LVIS の経路上にある割合は，提案手法で 0.440，ハイブリッド構成で 0.407 であった．深さ 1 以降の正誤を数値で示したのは，これが初めてである．
- **停止規則で適合率が上がる：**累積確信度による停止規則では，hP が 0.425 → 0.611（提案手法），0.594 → 0.801（ハイブリッド構成）に向上した．
- **COCO test500 でも誤った出力が減る：**提案手法に $\tau = 0.2$ を適用すると，誤った枝の出力は 1227 件→ 703 件に減った．一方，正しい枝の出力も 1509 件→ 1242 件に減った．
- **単純な規則と同程度：**「深さ 1 で止める」だけの規則でも，hF はほぼ同じであった．停止規則の効果は，主に深さ 0 の確信度による棄却と，深い段階の出力を削ることから来ており，深い段階の確信度を活かせてはいない．

3. 論文とスライドへの反映

- **論文：**`paper/main.pdf` は 14 ページ，Overfull なし．order_006 の赤字は黒に戻し，今回の追記を赤字にした．
  - 4.9 節：n を揃えた倍率と，$\gamma = 0.5$ の切替件数を訂正した．
  - 4.10 節を追加した：別の画像による検証と深さ 0 の誤りの伝播（表 7）．
  - 4.11 節を追加した：LVIS による評価と累積確信度による停止（式 (10)，(11)，表 8，図 11）．
  - 要旨，はじめに，考察の 5.5 節「第六」，おわりにも更新し，参考文献に LVIS と hP/hR の文献を追加した．
- **スライド：**26 枚．19 枚目（切替件数の表），20 枚目（「約 1.6 倍」，n を揃えた表），26 枚目（まとめ）を訂正した．23〜25 枚目（誤りの伝播，LVIS，停止規則）を追加した．pptx の検証はすべて合格した．
- **その他：**`visualize_result.ipynb` に ex007 のセルを追加して実行した．ex006 の `table_hybrid.csv` も修正後の値に更新した．`document.md` を更新した．

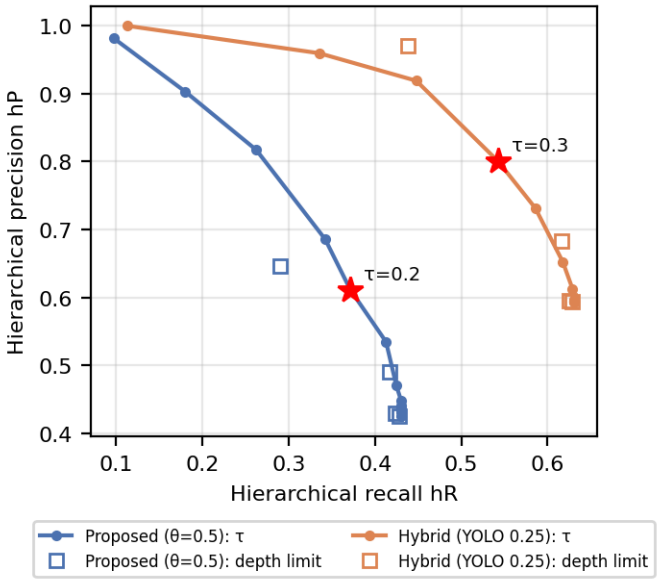


図 1　LVIS のテスト用分割における階層的適合率と再現率（星印は lvis_dev で選んだ τ）

4. 未解決の論点と次に検討すべき作業の候補

1. **深い段階の確信度の信頼性：**確信度が正誤の手がかりにならないことが分かった．次の候補は，候補語彙数による確信度の補正（提案 B2），上位語を含めたプロンプト（提案 B5），単一候補の分岐の扱いである．いずれも LVIS の hF で評価できる．
2. **LVIS で評価できる範囲：**対象は，COCO より細かいカテゴリが LVIS に付いた約 500 件（テスト用）に限られる．doughnut，cupcake，pigeon など特定のカテゴリに偏っており，人物クラスは評価できていない．
3. **LVIS より細かい出力：**正誤を判定できないため，hP の計算から除外した．この扱いによって，深い出力を多く出す条件が有利になる可能性がある．
4. **γ の位置付け：**test500 で誤った切替が 8 件生じた．ただし 6 件は GT の下位語であり，COCO の評価では誤りになるが，意味としては正しい細分化である．この扱いを論文でどう位置付けるかは検討の余地がある．
5. **ex006 の不具合の影響範囲：**修正したのは `hybrid_switch_c0.5` の COCO 500 枚の結果のみである．定性結果と，report_006・report_007 の記述は修正前のままである（report は作業記録のため改変していない）．
6. **seed：**seed は 42 のみである．CLIP と YOLO の推論は決定的だが，データ分割による変動は評価していない．
7. **ai-agent：**`tokens.json` が存在しないため，AI エージェントによる検証は実行していない．