物体領域検出とカテゴリアノテーションの分離に基づく，WordNet を用いた粒度可変物体アノテーション

Adjustable-Granularity Object Annotation via Decoupled Region Detection and WordNet-Guided Category Annotation

著者名（ご自身のお名前に置き換えてください）
Author Name (please replace with your name)

所属機関名（ご自身の所属に置き換えてください）
Affiliation (please replace with your affiliation)

概 要

本稿では，画像中の物体らしい領域を検出するタスクと，その領域に対応するカテゴリをアノテーションするタスクを明確に分離するオープンボキャブラリ物体アノテーション手法を提案する．物体領域検出にはカテゴリに依存しない DETR を用いて 1 回の推論でバウンディングボックスを得た上で，各領域のクロップに対し視覚言語モデル（VLM）によるゼロショット分類でカテゴリをアノテーションする．物体領域検出とカテゴリアノテーションが分離されているため，一度検出した領域に対し候補語彙集合を変更するだけでカテゴリアノテーションを繰り返すことができ，WordNet の上位語・下位語関係を用いることで，追加学習なしに「animal → dog → doberman」のような粒度可変のアノテーションを実現する．COCO 2017 Validation データセットを用いた定量評価により，カテゴリアノテーションにオープンボキャブラリな視覚言語モデルが必要であること（ResNet50-IN1k vs CLIP，統計的に有意差あり），物体領域検出とカテゴリアノテーションを分離する設計が，オープンボキャブラリ物体検出モデル（OWL-ViT，Grounding DINO）と同等の位置検出精度を保ちながら検出処理の再実行を不要にするという利点を持つこと，および提案パイプライン全体として Top-1 正解率 0.647，Top-5 正解率 0.907 のカテゴリアノテーション精度を達成することを確認した．さらに，COCO に含まれない語（ペンギン，ヘリコプター，カンガルー，ラクダ等）を主要な被写体とする実画像に対しても追加学習なしに正しくアノテーションできる一方，学習データと視覚的性質が大きく異なる物体（灯台）に対しては DETR の検出自体が失敗する場合があることを確認した．WordNet 階層を用いた粒度可変アノテーションについては，各粒度における確信度を定量的に評価し，最初の細分化の段階で確信度が大きく低下すること，および WordNet の生の階層構造をそのまま用いることに起因する構造上の限界（絶滅種の混入等）を明らかにする．

キーワード： オープンボキャブラリ物体検出，DETR，視覚言語モデル，CLIP，WordNet，粒度可変アノテーション

1 はじめに

画像データセットに対する物体アノテーションは，画像中のどこに物体が存在するか（物体領域）と，その物体が何であるか（カテゴリ）という，2 種類の異なる判断から構成される．YOLO[4] や DETR[8] に代表される一般的な物体検出モデルは，これら 2 つの判断を単一のモデルに統合し，あらかじめ定めた固定のクラス集合に対して同時に学習する．そのため，学習時に定めたクラス集合の範囲内では高精度な検出が可能である一方，学習後に新たなカテゴリを追加したり，カテゴリの粒度を変更したりする場合には，モデル自体の再学習が必要になるという制約を持つ．

近年では，OWL-ViT[9] や Grounding DINO[10] のように，カテゴリ名を自然言語のテキストクエリとして与えることで，固定のクラス集合に依存せずに物体を検出するオープンボキャブラリ物体検出モデルが提案されている．しかし，これらのモデルは，物体領域の検出とカテゴリの予測を単一のモデルの中で同時に行うという点では従来の物体検出モデルと変わらない．そのため，例えば「動物」という粗いカテゴリで検出した物体を,「犬」「猫」のようなより細かいカテゴリで改めて分類したい場合，候補カテゴリ集合を変更した上で検出処理そのものを再度実行する必要がある．

本研究では，物体領域の検出とカテゴリのアノテーションという 2 つの判断を，明確に分離したアーキテクチャを提案する．具体的には，物体領域の検出には，カテゴリに依存しないバウンディングボックスを 1 回の推論で出力する DETR を用い，カテゴリのアノテーションには，検出済みの領域を切り出した画像（クロップ）に対し，視覚言語モデル（Vision-Language Model，VLM）によるゼロショット分類を適用する．物体領域の検出とカテゴリのアノテーションが分離されているため，同一の検出結果に対し，候補となる語彙集合を変更するだけで，検出処理を再実行することなくカテゴリのアノテーションを繰り返すことができる．

本研究は，この分離が持つ性質を利用し，WordNet[11] の上位語・下位語（ハイポニム）関係をたどることで，追加学習を一切行わずに粒度可変のアノテーションを実現する手法を提案する．すなわち，まず粗いカテゴリ（例えば “dog”）を推定した後，そのカテゴリに対応する WordNet の Synset（同義語集合）の下位語集合（例えば “doberman”，“chihuahua” 等の犬種）を新たな候補語彙集合として与え，同一のクロップに対し再度カテゴリのアノテーションを行う．この処理を再帰的に繰り返

すことで，“animal → dog → doberman” のような，段階的に細かい粒度でのアノテーションが可能になる．候補語彙集合は COCO の 80 クラスに限定されないため，COCO に含まれない語を含む実画像に対しても，同様の仕組みでアノテーションを行うことができる．

本稿の貢献は，以下の 4 点である．第一に，物体領域の検出（DETR）とカテゴリのアノテーション（VLM によるゼロショット分類）を明確に分離するアーキテクチャを提案する．第二に，この分離を利用し，WordNet の階層構造をたどることで，追加学習なしに粒度可変のアノテーションを実現する手法を提案する．第三に，COCO 2017 Validation データセットを用いた定量評価により，カテゴリのアノテーションにオープンボキャブラリな視覚言語モデルが必要であること，物体領域の検出とカテゴリのアノテーションを分離するというアーキテクチャ上の判断が物体領域検出の精度の観点からも妥当であること，および提案パイプライン全体としてのカテゴリアノテーション精度を確認するとともに，COCO に含まれない語を主要な被写体とする実画像に対する開語彙アノテーションの実行例を通じて，本手法が COCO の 80 クラスという学習データセットの語彙に縛られない現実的なユースケースに適用できることを示す．第四に，WordNet 階層の各粒度（深さ）における VLM の確信度を定量的に評価し，粒度を細かくするにつれて確信度が変化する傾向，および WordNet の生の階層構造をそのまま用いることに起因する構造上の限界を明らかにする．

2 関連研究

2.1 閉域的な物体検出モデル

YOLO[4] や DETR[8] に代表される物体検出モデルの多くは，ImageNet-1k[3] や COCO[5] のような，あらかじめ定めた固定のクラス集合を持つデータセットを用いて学習される．特に DETR は，Transformer に基づく End-to-End の物体検出モデルであり，候補領域の生成や Non-Maximum Suppression（NMS）といった後処理を必要とせず，集合予測に基づく損失関数により学習される．これらのモデルは，学習時に定めたクラス集合の範囲内では高い精度を示す一方，学習時に存在しなかったクラスの物体を原理的に予測できないという閉域的な制約を持つ．本研究では，DETR の予測カテゴリそのものではなく，その高精度なバウンディングボックス出力のみを，物体領域検出の手段として利用する．すなわち，DETR が学習していない未知のカテゴリの物体であっても，その物体領域さえ検出できれば，後段の VLM によって開語彙のカテゴリをアノテーションできる．

2.2 オープンボキャブラリ物体検出モデルとの違い

OWL-ViT[9] や Grounding DINO[10] は，候補となるカテゴリ名や説明文をテキストクエリとして与えることで，学習時に固定されたクラス集合に依存せず物体を検出するオープンボキャブラリ物体検出モデルである．これらのモデルは，物体領域の検出と，その領域に対応するカテゴリの予測を単一のモデルで同時に行う．そのため，例えば「動物」という粗いカテゴリで検出した物体について,「犬」「猫」等のより細かいカテゴリで改めてアノテーションしたい場合，候補カテゴリ集合を変更した上で検出処理そのものを再度実行する必要がある．候補カテゴリ集合が WordNet の階層のように多段階かつ大規模（例えば `dog.n.01` の下位語だけで約 150 語）である場合，各段階・各分岐でこの再検出を繰り返すことは計算コストの観点で非効率である．

本研究が提案する設計は，物体領域の検出（1 回のみ実行する DETR の推論）と，カテゴリのアノテーション（検出済みの領域に対する軽量な VLM の推論）を明確に分離する点で，これらのモデルと異なる．この分離により，同一の検出結果（バウンディングボックス）を再利用しながら，候補語彙集合のみを変更して繰り返しカテゴリのアノテーションを行うことができ，WordNet の階層をたどる多段階の粒度可変アノテーション（3.4 節）を効率的に実現できる．4.3 節では，物体領域検出の精度そのものについても DETR・OWL-ViT・Grounding DINO を比較し，本研究の設計における物体領域検出モデルの選択が，これらのオープンボキャブラリ検出モデルとの比較においても妥当であることを確認する．

2.3 視覚言語モデルによるゼロショット分類

CLIP（Contrastive Language-Image Pre-training）[1] は，画像とその説明文のペアから構成される大規模データセット（WIT-400M）を用い，対照学習により画像エンコーダとテキストエンコーダを同時に学習するモデルである．学習後の CLIP は，任意の単語や文をテキストエンコーダに入力し，画像エンコーダの出力との類似度を計算することで，学習時に固定のクラス集合を定めることなく画像分類（ゼロショット分類）を行うことができる．本研究では，このゼロショット分類の性質を利用し，検出済みの物体領域のクロップに対して直接カテゴリのアノテーションを行う（3.3 節）．

2.4 階層的・粒度可変な分類

ImageNet の多くのクラスは WordNet[11] の Synset（同義語集合）に対応付けられており，画像分類においてクラス階層を利用する研究は古くから存在する．しかし，従来の階層的画像分類の多くは，あらかじめ定めた固定の階層構造に対して学習を行うものであり，推論時に階層の深さや分岐を動的に選択することは想定していない．本研究が提案する WordNet を用いた粒度可変アノテーション（3.4 節）は，学習を一切行わず，推論時に VLM へ与える候補語彙集合を動的に変更するだけで，任意の深さまでの粒度でアノテーションを行える点で異なる．

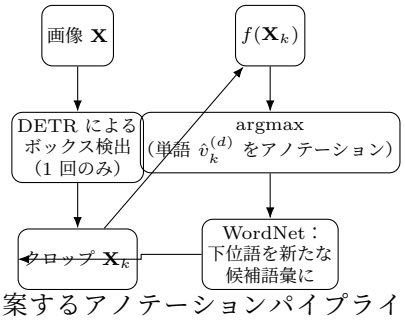


図 1: 提案するアノテーションパイプラインの概要．DETR によるボックス検出は 1 回のみ実行し，WordNet の下位語を新たな候補語彙として同一のクロップに対しカテゴリアノテーションを繰り返すことで，粒度可変アノテーション（3.4 節）を実現する．

3 提案手法

3.1 全体設計：物体領域検出とカテゴリアノテーションの分離

画像 $\mathbf{X} \in \mathbb{R}^{H\times W\times C}$ が与えられたとき，本手法の目的は，画像中の物体らしい領域それぞれに対し，その物体を表す単語をアノテーションすることである．ここで，H，W，C はそれぞれ画像の高さ，幅，チャンネル数である．

本手法は，1 章で述べた設計方針に基づき，以下の 2 つの処理を明確に分離する．

- **物体領域検出**：画像 $\mathbf{X}$ を入力すると，物体候補領域に対応する矩形（バウンディングボックス）$\{\mathbf{b}_1,\dots,\mathbf{b}_K\}$（$\mathbf{b}_k \in \mathbb{R}^4$，$K$ は検出数）を 1 回の推論で出力する（3.2 節）．
- **カテゴリアノテーション**：各領域 k について，バウンディングボックス $\mathbf{b}_k$ に切り出したクロップ $\mathbf{X}_k$ を入力とし，与えられた候補語彙集合の中から対応する単語をアノテーションする（3.3，3.4 節）．

物体領域検出は候補語彙に依存しない 1 回の推論で完結するため，カテゴリアノテーションの候補語彙集合や粒度を変更する場合，物体領域検出を再実行する必要がない．3.4 節で述べる WordNet を用いた粒度可変アノテーションは，この性質を利用する．図 1 に，提案手法のパイプラインの概要を示す．

3.2 物体領域検出

物体領域の検出には，DETR[8] を用いる．DETR は COCO の 91 クラスで学習済みであるが，本研究では DETR が予測するカテゴリラベルは使用せず，検出スコアが閾値以上のバウンディングボックス $\{\mathbf{b}_1,\dots,\mathbf{b}_K\}$ のみを利用する．これにより，DETR が学習していない未知のカテゴリの物体であっても，検出さえされれば後段の VLM によって開語彙のカテゴリをアノテーションできる．4.3 節で述べる通り，この DETR の選択は，物体領域検出の精度の観点からも妥当であることを定量的に確認している．

3.3 視覚言語モデルによるカテゴリアノテーション

各領域 k に対応する単語をアノテーションするために，語彙が単語単位の視覚言語モデル（VLM）

$$f : \mathbb{R}^{H'\times W'\times C} \to [0,1]^V \tag{1}$$

を用いる．ここで，V は f の語彙数であり，$f(\mathbf{X})$ の第 v 成分は，語彙中の v 番目の単語が画像 $\mathbf{X}$ に対して当てはまる度合い（尤もらしさ）を表す．H'，W' は f への入力画像の高さ・幅である．カテゴリのアノテーションは，クロップ $\mathbf{X}_k$ に対する f の出力の中から，与えられた候補語彙集合に対応するインデックス集合 $\mathbb{N} \subset \{1,\dots,V\}$ の範囲で最大値を与える単語を選ぶことで行う．

$$\hat{v}_k = \arg\max_{v\in\mathbb{N}} f(\mathbf{X}_k)_v \tag{2}$$

式 (1) の f への入力を画像全体とした場合，画像中に同一カテゴリの物体が複数存在する場合や，対象と無関係な背景中の物体の情報が f の出力に混入し，対象の物体に対するアノテーションが不正確になるという問題が生じる．そこで本研究では，f への入力を画像全体ではなく，領域 k のバウンディングボックス $\mathbf{b}_k$ にちょうど合わせて切り出した局所クロップ $\mathbf{X}_k = \mathrm{Crop}(\mathbf{X}, \mathbf{b}_k)$ とする．これにより，対象の物体が局所領域内で画像の大部分を占めるようになり，同一カテゴリの他インスタンスや背景の影響を受けにくくなる．クロップの余白（パディング）は，予備実験において余白を加えるほど周辺の物体が写り込みアノテーションの精度が低下することを確認したため，余白を設けず $\mathbf{b}_k$ にちょうど合わせる設定を採用した．

3.4 WordNet による粒度可変アノテーション

本手法の中心的な特徴は，物体領域検出とカテゴリアノテーションが分離されていることを利用し，同一の検出結果（バウンディングボックス $\mathbf{b}_k$，クロップ $\mathbf{X}_k$）に対して，候補語彙集合を変えながら繰り返しカテゴリアノテーションを行うことで，段階的に粒度の細かい分類を実現する点にある．

候補語彙集合として COCO の 80 オブジェクトクラス $V^{(0)}$ を用いた第 1 段階のアノテーション（式 (2)）により，単語 $\hat{v}_k^{(0)}$ を得る．$\hat{v}_k^{(0)}$ に対応する WordNet Synset を $\mathrm{synset}(\hat{v}_k^{(0)})$ とし，その直接の下位語（ハイポニム）の集合を $\mathrm{Hyponyms}(\cdot)$ とする．深さ $d \geq 1$ における候補語彙集合を，1 つ浅い段階で選ばれた Synset の下位語集合

$$V_k^{(d)} = \mathrm{Hyponyms}\big(\mathrm{synset}(\hat{v}_k^{(d-1)})\big) \tag{3}$$

とし，この候補語彙集合を用いて同一のクロップ $\mathbf{X}_k$ に対し式 (2) を再度適用することで，単語 $\hat{v}_k^{(d)}$ を得る．この処理を，$V_k^{(d)} = \emptyset$（下位語が存在しない）となるか，利用者が指定した最大深さに達するまで繰り返す．最終的な出力は，粗い粒度から細かい粒度への単語の

列 $(\hat{v}_k^{(0)}, \hat{v}_k^{(1)}, \ldots)$ と，各段階における確信度（式 (2) の arg max に対応するスコア）の組である．4.4，4.5 節では，この WordNet による粒度可変アノテーションの精度と，各段階における確信度を定量的に評価する．

3.5 視覚言語モデル f の実装

式 (1) を満たす具体的なモデル f として，本研究では性質の異なる 2 種類の実装を比較する．

3.5.1 ResNet50-IN1k（閉域モデル，比較対象）

ResNet50-IN1k[2] は，ImageNet-1k[3] で学習済みの画像分類モデルであり，学習時に固定された 1000 クラスに対する確率ベクトルを出力する．候補語彙集合の各単語について，原形化（レンマ化）した上でクラス名と完全一致するもののみ対応するクラスの確率をスコアとして採用し，一致しない候補語にはスコア 0 を割り当てる．4.2 節では，このモデルを，カテゴリアノテーションにオープンボキャブラリな視覚言語モデルが必要であることを検証するための比較対象（ベースライン）として用いる．

3.5.2 CLIP-RN50，CLIP-ViT-B/32（オープンボキャブラリモデル）

CLIP[1] は，画像エンコーダとテキストエンコーダから構成され，候補語彙集合の各単語 w を「a photo of a $\{w\}$」という形式のプロンプトに埋め込み，画像特徴量とのコサイン類似度に対しソフトマックス関数を適用したものを f の出力とする．本研究では，画像エンコーダの構造が CNN（ResNet-50 ベース）である CLIP-RN50 と，Vision Transformer（ViT-B/32）である CLIP-ViT-B/32 の 2 種類を実装した．4.2 節の比較評価を経て，以降の実験では CLIP-ViT-B/32 を，カテゴリアノテーションのための代表的な VLM として固定して用いる．

4 実験

4.1 共通設定

特に断らない限り，定量評価には COCO 2017 Validation データセットから，乱数シード 42 により再現可能な形でランダムサンプリングした 500 枚の画像を用いた．各画像には，物体検出用の矩形・カテゴリラベル（instances_val2017.json）が付与されている．推論は NVIDIA GeForce RTX 3090（24GB）上で実施した．

4.2 カテゴリアノテーションにおけるオープンボキャブラリ性の必要性

語彙数が限定的な ResNet50-IN1k と，オープンボキャブラリ表現力を持つ CLIP（CLIP-RN50，CLIP-ViT-B/32）を比較する評価を実施した．候補語彙集合を COCO の 80 オブジェクトクラス V_A に固定するタスク A（閉域評価）と，500 枚の GT キャプションから spaCy[6]（`en_core_web_sm`）を用いて抽出した名詞・動詞のユニーク集合（1452 語）V_B を用いるタスク B（広域評価）を設定し，各手法について Top-1/Top-5 Precision/Recall を計算した．統計的検定には，画像単位で対応付けられた指標値に対する Wilcoxon 符号付き順位検定 [7] と，画像単位のブートストラップリサンプリング（$B = 1000$）による 95%信頼区間を用いた．

表 1: タスク A（閉域評価）における評価結果.

手法	P@1	R@1	P@5	R@5
ResNet50-IN1k	0.255	0.095	0.084	0.132
CLIP-RN50	0.838	0.397	0.334	0.649
CLIP-ViT-B/32	0.822	0.385	0.350	0.678

表 2: タスク B（広域評価）における評価結果.

手法	P@1	R@1	P@5	R@5
ResNet50-IN1k	0.350	0.027	0.104	0.040
CLIP-RN50	0.454	0.035	0.306	0.118
CLIP-ViT-B/32	0.444	0.035	0.313	0.121

表 1，表 2 に結果を示す．

ResNet50-IN1k と CLIP 系（CLIP-RN50，CLIP-ViT-B/32）の間には，タスク A・タスク B の全指標において統計的に有意な差が認められた（多くの指標で $p < 10^{-40}$，最小でもタスク B の Top-1 Recall で $p = 8.4 \times 10^{-4}$）．図 2 に，代表的な指標の比較結果を示す．

一方，CLIP-RN50 と CLIP-ViT-B/32 の間には，タスク A の一部指標を除き統計的に有意な差は認められなかった．この結果は，f の性能差において「学習手法・語彙設計（クラス分類 vs 対照学習によるオープンボキャブラリ化）」の要因が「モデル構造（CNN vs ViT）」の要因よりも支配的であることを示唆しており，以降の実験では CLIP-ViT-B/32 を代表的な VLM として用いる．

4.3 物体領域検出モデルの選択

2.2 節で述べた設計上の理由（物体領域検出とカテゴリアノテーションの分離）により，本研究ではカテゴリ非依存の検出のみを行う DETR を物体領域検出に採用している．この選択が，物体領域検出の精度の観点からも妥当であることを確認するため，DETR と，オープンボキャブラリ物体検出モデルである OWL-ViT，Grounding DINO の 3 手法を比較する実験を行った．評価には 4 枚の画像を用い，各画像の COCO GT バウンディングボックス（計 10 件）との一致度を，各手法が予測したカテゴリの正誤を問わないクラス非依存の位置検出精度として評価した．評価指標は，GT インスタンスに対し IoU 0.5 以上で対応する提案が存在する割合（Recall@IoU0.5）と，GT インスタンスあたりの提案との最良 IoU の平均値（平均最良 IoU）である．

表 3 に結果を示す．3 手法の間で位置検出精度に大きな差は見られなかった．しかし，OWL-ViT，Grounding DINO は，候補カテゴリ集合（テキストクエリ）を検出処理の入力として必要とするため，2.2 節で述べた通り，カテゴリの粒度を変更するたびに検出処理そのものを再

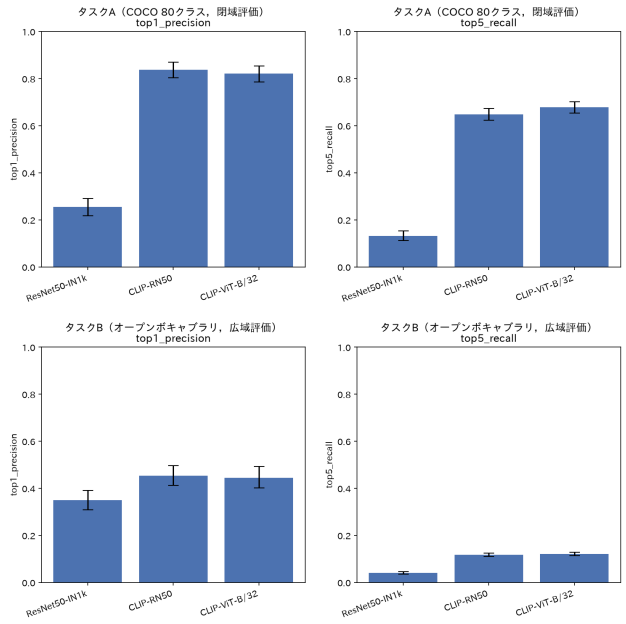


図 2: ResNet50-IN1k vs CLIP の指標比較（誤差棒はブートストラップ 95%信頼区間）．左上：タスク A Top-1 Precision，右上：タスク A Top-5 Recall，左下：タスク B Top-1 Precision，右下：タスク B Top-5 Recall.

表 3: 物体領域検出モデルの比較（$n = 4$ 画像，GT インスタンス 10 件）．

手法	平均提案数	Recall@IoU0.5	平均最良 IoU
DETR	3.0	1.000	**0.931**
OWL-ViT	5.0	1.000	0.920
Grounding DINO	3.5	1.000	0.903

実行する必要がある．一方，DETR はカテゴリに依存しない検出を 1 回のみ行えばよく，同一の検出結果を，WordNet による粒度可変アノテーション（3.4 節）を含む後段の処理全体で再利用できる．本研究では，この設計上の利点に基づき，位置検出精度が同等であることを確認した上で DETR を採用する．なお，4.6 節で示す通り，DETR の検出は COCO の学習分布から完全には独立ではなく，COCO のカテゴリと視覚的性質が大きく異なる物体に対しては検出自体に失敗する場合がある．

4.4 カテゴリアノテーションの精度

提案するパイプライン（DETR，局所クロップ，CLIP-ViT-B/32 によるゼロショット分類，式 (2)）全体としてのカテゴリアノテーション精度を評価した．DETR のバウンディングボックスと GT バウンディングボックスを IoU 0.5 で対応付けたところ，500 枚から 1466 件のインスタンスが得られた．候補語彙集合を COCO の 80 オブジェクトクラスとし，各インスタンスに対応するクロップに式 (2) を適用した結果，Top-1 正解率 0.647，Top-5 正解率 0.907 が得られた．この結果は，物体領域検出とカテゴリアノテーションを分離し，DETR による精密なクロップに対して直接ゼロショット分類を適用するという本手法の設計が，追加学習を行うことなく高いアノテーション精度を達成できることを示している．

表 4: WordNet 階層の深さごとの平均確信度（深さ 0 の推定が正解のインスタンスのみ）．

深さ	インスタンス数	平均候補数	平均確信度
0（COCO 80 クラス）	948	80.0	0.695
1	854	137.2	0.477
2	305	6.4	0.723
3	54	11.3	0.586
4	10	6.9	0.710
5	1	3.0	0.729
6	1	1.0	1.000

：粒度ごとの確信度（深さ0の推定が正解のインスタンスのみ，n=

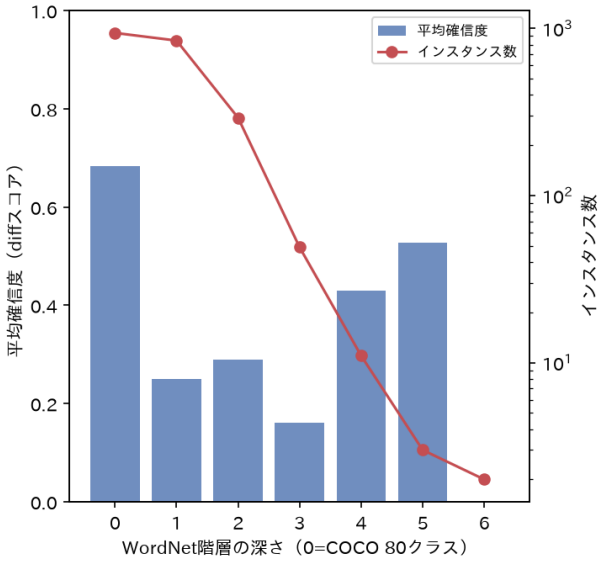


図 3: WordNet 階層の深さごとの平均確信度（棒グラフ，左軸）とインスタンス数（折れ線，右軸，対数スケール）．

4.5 WordNet 粒度可変アノテーションにおける確信度評価

3.4 節で述べた WordNet 階層を用いた粒度可変アノテーションについて，各粒度（階層の深さ）における VLM の確信度を評価した．COCO 80 クラスの粒度（深さ 0）については GT カテゴリとの正誤を判定できるが，それより細かい粒度（深さ 1 以降，例えば犬種）については COCO に GT が存在せず正誤を判定できない．そこで，深さ 0 の推定が GT カテゴリと一致した 948 件（1466 件中）を対象に，深さを増すにつれて確信度がどのように変化するかを特徴づけた．

表 4，図 3 に結果を示す．

深さ 0 から深さ 1 にかけて，平均確信度は 0.695 から 0.477 へと大きく低下した．これは，候補語彙数が COCO 80 クラスから平均 137.2 語（例えば `dog.n.01` の下位語は約 150 語）へと大きく増加し，かつ視覚的に類似した細かいカテゴリ間の識別がより困難になるためと考えられる．深さ 2 以降の確信度は 0.723，0.586，0.710 と変動しており，深さ 1 のように単調に低下する傾向は見られない．ただし，深さ 2 以降は該当インスタンス数が

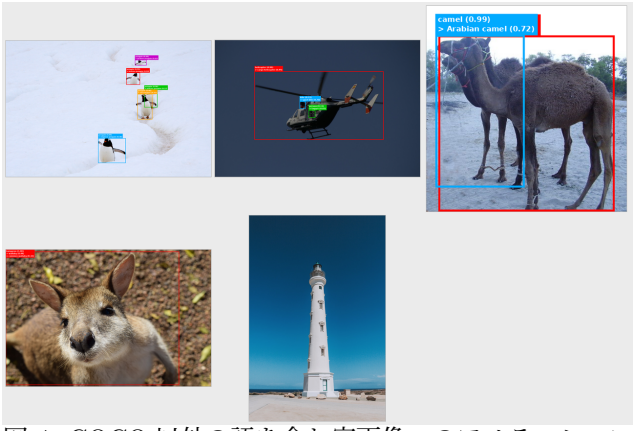


図 4: COCO 以外の語を含む実画像へのアノテーション結果．左上からペンギン，ヘリコプター，ラクダ，カンガルー，灯台（検出なし）．

急速に減少しており（深さ 3 で 54 件，深さ 5・6 では 1 件），少数のインスタンスの結果が平均値を大きく左右するため，これらの深さにおける確信度の変動を一般的な傾向として解釈することはできない点に注意が必要である．深さ 2 以降のインスタンス数の急減は，大多数の COCO カテゴリの WordNet 下位語ツリーが浅いことを反映している．

4.6　COCO 以外の語を含む実画像へのアノテーション

本手法の開語彙性が COCO の 80 クラスという評価用データセットの語彙に限定されないことを確認するため，COCO に含まれない語を主要な被写体とする実画像に対するアノテーションを実施した．第 1 段階の候補語彙集合として，COCO の 80 クラスに加え，ペンギン，ヘリコプター，カンガルー，ラクダ，灯台等，COCO に含まれない 22 語を手動で追加した，計 102 語からなる語彙集合を用いた．評価対象の画像には，Wikimedia Commons で公開されている，ペンギン，ヘリコプター，カンガルー，ラクダ，灯台の写真 5 枚を用いた．

図 4 に結果を示す．ペンギン，ヘリコプター，カンガルー，ラクダの 4 枚については，DETR が物体領域を検出し，第 1 段階でいずれも正しい語（“penguin”，“helicopter”，“kangaroo”，“camel”）がアノテーションされた（確信度 0.94〜1.00）．さらに下位語段階では，カンガルーの画像で “kangaroo” → “wallaby” → “common wallaby” という妥当な細分化が得られ，ラクダの画像でも “camel” → “Arabian camel” という妥当な細分化が得られた．一方，灯台の画像については，2 枚の異なる構図の写真を用いて確認したが，いずれも DETR が検出スコア 0.5 以上のバウンディングボックスを 1 件も出力しなかった．これは，DETR がカテゴリに依存しない検出器として利用されている場合でも，その領域提案の性質は COCO の学習データの分布から完全には独立ではなく，COCO のいずれのカテゴリとも視覚的に大きく異なる物体（空を背景とした細い塔状の構造物）に対しては検出自体に失敗し得ることを示している．

また，ヘリコプターの画像では，主要被写体に対する

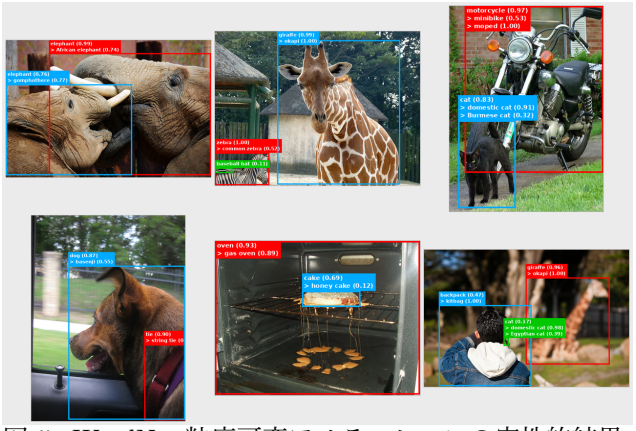


図 5: WordNet 粒度可変アノテーションの定性的結果．上段左から，接触する象 2 頭，シマウマとキリン，オートバイと黒猫．下段左から，走行中の車内から見た犬，オーブン内のケーキ，人物とキリン．各段階の推定単語と確信度を個別に表示している．

“helicopter”（確信度 0.99）のアノテーションに加え，機体上部の小さな装置（衛星通信用アンテナと推定される部分）に対応する領域が “kite”（確信度 0.13）としてアノテーションされた．この領域は候補語彙中に適切な語が存在しないため，最も類似度の高い無関係な語が選択されたと考えられ，開語彙アノテーションにおいて，候補語彙に正解語が含まれない小領域への対処が今後の課題であることを示している．

4.7　定性的結果

図 5 に，提案するパイプライン（DETR，局所クロップ，CLIP-ViT-B/32 によるゼロショット分類）による，COCO の画像に対する階層的アノテーション結果を示す．各段階の推定単語と確信度を個別に表示している．

接触する 2 頭の象がいずれも第 1 段階で正しく “elephant” とアノテーションされ，象 1 については下位語段階でも “African elephant” という妥当な細分化が得られた一方，象 2 では “gomphothere”（絶滅した古代の長鼻類）という不適切な細分化が選択された．また，“giraffe” の下位語段階では，シマウマとキリンの画像，および人物とキリンの画像の両方で “okapi”（キリン科の近縁種であるオカピ）が選択されており，`giraffe.n.01` の下位語が okapi の 1 語のみであるためアノテーションの候補選択自体が実質的に機能していないことが，複数の画像にわたって再現していることが分かる．これらの事例は，WordNet の生の階層構造をそのまま候補語彙として用いることの限界（絶滅種の混入，候補語彙数が極端に少ない分岐の存在）を示しており，5.2 節で改めて考察する．

5　考察

5.1　従来手法との差別化点

本研究の差別化点は，以下の 3 点に整理できる．

第一に，YOLO[4] や DETR[8] のような閉域的な物体検出モデルに対しては，学習時に定めた固定のクラス集

合を超えたカテゴリを予測できないという制約を解消している．本手法では，DETR の予測カテゴリを用いず，バウンディングボックス出力のみを物体領域検出に用いることで，検出済みの領域に対し後段の VLM が任意の候補語彙でカテゴリをアノテーションできるようにしている．4.6 節で確認した通り，この設計により，COCO の 80 クラスに含まれない語（ペンギン，ヘリコプター，カンガルー，ラクダ等）についても，追加学習なしにアノテーションが可能である．

第二に，OWL-ViT[9] や Grounding DINO[10] のようなオープンボキャブラリ物体検出モデルに対しては，物体領域の検出とカテゴリの予測が単一モデルに統合されているため，候補カテゴリ集合を変更するたびに検出処理全体を再実行する必要があるという制約を解消している．4.3 節で確認した通り，位置検出精度そのものは DETR とこれらのモデルの間で大きな差がないため，本手法は同等の位置検出精度を維持しつつ，物体領域検出を 1 回のみに抑え，後段のカテゴリアノテーションのみを候補語彙集合の変更に応じて繰り返す設計を実現している．

第三に，ImageNet のクラス階層を利用する従来の階層的画像分類の多くは，あらかじめ定めた固定の階層構造に対して学習を行うものであり，推論時に階層の深さや分岐を動的に選択することを想定していない．本手法は，物体領域検出とカテゴリアノテーションの分離という設計上の性質を利用し，WordNet の上位語・下位語関係を推論時にたどることで，追加学習を一切行わずに粒度可変のアノテーションを実現している点で異なる．

5.2 WordNet 階層をそのまま用いることの限界

4.5，4.7 節の結果は，WordNet の生の階層構造をそのまま候補語彙として用いることに起因する 2 種類の限界を示している．第一に，深さ 0 から深さ 1 への確信度の大幅な低下（0.695 から 0.477）に見られるように，候補語彙数の増加および視覚的に類似した細かいカテゴリ間の識別困難性により，最初の細分化の段階でアノテーションの信頼性が低下する．一方，深さ 2 以降の確信度は 0.723，0.586，0.710 と変動しており単調な低下傾向を示さないが，これは該当インスタンス数が数件〜数十件と少なく，個々のインスタンスの結果が平均値を大きく左右するためであり，深さの増加そのものが確信度を回復させると解釈すべきではない．第二に，4.7 節で確認した “gomphothere”（絶滅種）のような不適切な下位語の混入や，`giraffe.n.01` の下位語が “okapi” の 1 語のみであるためスコアリングが実質的に機能しない事例のように，WordNet の階層構造には，視覚的なカテゴリ分類の候補語彙として不適切な分岐が含まれている．この `giraffe.n.01` の事例は，キリンが被写体に含まれる複数の画像で再現しており，特定の分岐に固有の系統的な問題であることが確認できる．これらの限界は，WordNet の階層構造が本来，視覚的な類似性ではなく言語学的な意味関係に基づいて構築されていることに起因すると考えられる．

5.3 物体領域検出の COCO 学習分布への依存

4.6 節の灯台の事例は，カテゴリに依存しない検出器として利用する場合であっても，DETR の物体領域検出そのものが COCO の学習データの分布から完全には独立ではないことを示している．すなわち，本手法における「物体領域検出とカテゴリアノテーションの分離」は，カテゴリの予測に関する制約を解消するものであるが，物体領域の候補生成そのものに関する制約（学習データに存在する物体の形状・構図との類似性への依存）までは解消しない．また，ヘリコプターの機体上部の小さな装置が “kite” として誤ってアノテーションされた事例は，候補語彙集合に正解語が存在しない領域に対して，VLM が候補語彙中で最も類似度の高い無関係な語を選択してしまう問題を示している．

5.4 今後の課題

今後の課題として，第一に，WordNet 階層のフィルタリング（絶滅種・希少種・非視覚的カテゴリの除外）による粒度可変アノテーションの実用性向上が挙げられる．第二に，WordNet 階層の深さ 2 以降の確信度評価について，該当インスタンス数を増やすためのより大規模なデータセットを用いた再評価が挙げられる．第三に，物体領域検出における学習分布への依存を緩和するため，SAM 等の汎用的なセグメンテーションモデルと DETR を組み合わせるなど，物体領域検出モデル自体の改善が挙げられる．第四に，候補語彙に正解語が存在しない領域を棄却する仕組み（信頼度に対する閾値処理の高度化等）の導入が挙げられる．

6 おわりに

本稿では，画像中の物体らしい領域を検出するタスクと，その領域に対応するカテゴリをアノテーションするタスクを明確に分離するオープンボキャブラリ物体アノテーション手法を提案した．物体領域検出には，カテゴリに依存しない高精度なバウンディングボックスを 1 回の推論で出力する DETR を用い，カテゴリのアノテーションには，検出済みの領域のクロップに対する視覚言語モデル（VLM）のゼロショット分類を用いた．この分離により，一度検出した物体領域に対し，候補語彙集合を変更するだけで異なる粒度・異なる語彙でのカテゴリアノテーションを行うことができ，WordNet の上位語・下位語関係を用いることで，追加学習を一切行わずに “animal → dog → doberman” のような粒度可変のアノテーションを実現した．

一連の定量評価を通じて，以下を明らかにした．第一に，オープンボキャブラリな CLIP が，閉域的な ResNet50-IN1k に対して統計的に有意に高い単語推定精度を示すことを確認し，カテゴリアノテーションにオープンボキャブラリな視覚言語モデルが必要であることを裏付けた．第二に，物体領域検出モデルとして

DETR，OWL-ViT，Grounding DINO を比較し，位置検出精度に大きな差がないことを確認した上で，カテゴリに依存しない 1 回のみの検出で済む DETR を採用することが，物体領域検出とカテゴリアノテーションの分離という設計上の利点と，位置検出精度の両立の観点から妥当であることを示した．第三に，提案するパイプライン全体としてのカテゴリアノテーション精度を評価し，Top-1 正解率 0.647，Top-5 正解率 0.907 を達成することを確認するとともに，COCO に含まれない語（ペンギン，ヘリコプター，カンガルー，ラクダ等）を主要な被写体とする実画像に対しても，追加学習なしに正しくアノテーションできることを確認した．一方，学習データと視覚的性質が大きく異なる物体（灯台）に対しては DETR の検出自体が失敗する場合があることも確認し，物体領域検出モデルの学習分布への依存という限界を明らかにした．第四に，WordNet 階層を用いた粒度可変アノテーションについて，各粒度における確信度を定量的に評価し，最初の細分化の段階（深さ 0 から深さ 1）で確信度が大きく低下すること，および WordNet の生の階層構造をそのまま用いることに起因する限界（絶滅種の混入，候補語彙数が極端に少ない分岐の存在）を明らかにした．

今後の課題として，第一に，WordNet 階層のフィルタリング（絶滅種・希少種・非視覚的カテゴリの除外）による粒度可変アノテーションの実用性向上が挙げられる．第二に，WordNet 階層の深さ 2 以降の確信度評価について，より大規模なデータセットを用いた再評価が挙げられる．第三に，SAM 等の汎用的なセグメンテーションモデルと DETR を組み合わせるなど，物体領域検出モデル自体の学習分布への依存を緩和する改善が挙げられる．第四に，候補語彙に正解語が存在しない領域を棄却する仕組みの導入が挙げられる．

参考文献

[1] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning Transferable Visual Models From Natural Language Supervision,” in *Proc. International Conference on Machine Learning (ICML)*, 2021.

[2] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[3] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A Large-Scale Hierarchical Image Database,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2009.

[4] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[5] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common Objects in Context,” in *Proc. European Conference on Computer Vision (ECCV)*, 2014.

[6] M. Honnibal and I. Montani, “spaCy 2: Natural Language Understanding with Bloom Embeddings, Convolutional Neural Networks and Incremental Parsing,” 2017.

[7] F. Wilcoxon, “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

[8] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko, “End-to-End Object Detection with Transformers,” in *Proc. European Conference on Computer Vision (ECCV)*, 2020.

[9] M. Minderer, A. Gritsenko, A. Stone, M. Neumann, D. Weissenborn, A. Dosovitskiy, A. Mahendran, A. Arnab, M. Dehghani, Z. Shen, X. Wang, X. Zhai, T. Kipf, and N. Houlsby, “Simple Open-Vocabulary Object Detection with Vision Transformers,” in *Proc. European Conference on Computer Vision (ECCV)*, 2022.

[10] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, C. Li, J. Yang, H. Su, J. Zhu, and L. Zhang, “Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection,” in *Proc. European Conference on Computer Vision (ECCV)*, 2024.

[11] G. A. Miller, “WordNet: A Lexical Database for English,” *Communications of the ACM*, vol. 38, no. 11, pp. 39–41, 1995.