物体領域検出とカテゴリアノテーションの分離に基づく，WordNet を用いた粒度可変物体アノテーション

Adjustable-Granularity Object Annotation via Decoupled Region Detection and WordNet-Guided Category Annotation

著者名
Author Name

所属機関名
Affiliation

概 要

本稿では，画像中の物体らしい領域を検出するタスクと，その領域に対応するカテゴリをアノテーションするタスクを明確に分離した物体アノテーション手法を提案する．物体領域の検出にはカテゴリに依存しない DEtection TRansformer（DETR）を用いて 1 回の推論でバウンディングボックスを得る．カテゴリのアノテーションには，各領域のクロップに対する視覚言語モデル（Vision-Language Model，VLM）のゼロショット分類を用いる．両者が分離されているため，一度検出した領域に対して候補語彙集合を変更するだけでカテゴリのアノテーションを繰り返すことができる．さらに，WordNet の上位語・下位語関係をたどることで，追加学習なしに「animal → dog → doberman」のような粒度可変のアノテーションを実現する．COCO 2017 Validation の 500 枚を用いた評価により，以下を確認した．第一に，ImageNet で学習した閉域の分類モデルに比べて Contrastive Language-Image Pre-training（CLIP）は画像単位の単語推定精度が統計的に有意に高く，カテゴリのアノテーションにはオープンボキャブラリな VLM が必要である．第二に，クラス非依存の位置検出精度において，DETR は OWL-ViT および Grounding DINO に劣らない．第三に，提案パイプライン全体のカテゴリアノテーション精度は Top-1 正解率 0.604，Top-5 正解率 0.894 であり，クロップを正方形にパディングして VLM へ入力することで Top-1 正解率が約 0.08 向上する．第四に，WordNet 階層の最初の細分化の段階で確信度が 0.642 から 0.442 へ大きく低下する．また，下位語が 1 語しかない分岐が細分化の段階全体の約 18%で生じ，これが深い階層における見かけの確信度を押し上げていることを明らかにした．さらに，COCO の 80 クラスで学習した YOLO と同一の語彙で比較し，80 クラスの範囲内では YOLO の Top-1 正解率が 0.98 と提案手法を大きく上回るものの，その差は検出器ではなく分類器に起因すること，および YOLO は COCO 外の物体を bird や dog 等の 80 クラス内の語でしかアノテーションできないことを示した．COCO に含まれない語を主要な被写体とする実画像に対しても追加学習なしに正しくアノテーションできる一方，空を背景とした塔状の構造物では DETR の検出自体が失敗することも確認した．

キーワード：オープンボキャブラリ物体アノテーション，DETR，視覚言語モデル，CLIP，WordNet，粒度可変アノテーション

1 はじめに

画像データセットに対する物体アノテーションは，画像中のどこに物体が存在するかという物体領域の判断と，その物体が何であるかというカテゴリの判断の 2 種類から構成される．You Only Look Once（YOLO）[4] や DETR[9] に代表される一般的な物体検出モデルは，これら 2 つの判断を単一のモデルに統合し，あらかじめ定めた固定のクラス集合に対して同時に学習する．そのため，学習時に定めたクラス集合の範囲内では高精度な検出が可能である一方，学習後に新たなカテゴリを追加したり，カテゴリの粒度を変更したりする場合には，モデル自体の再学習が必要になる．

近年では，OWL-ViT[10] や Grounding DINO[11] のように，カテゴリ名を自然言語のテキストクエリとして与えることで，固定のクラス集合に依存せずに物体を検出するオープンボキャブラリ物体検出モデルが提案されている．しかし，これらのモデルも物体領域の検出とカテゴリの予測を単一のモデルの中で同時に行う．そのため，例えば「動物」という粗いカテゴリで検出した物体を「犬」「猫」のようなより細かいカテゴリで改めて分類したい場合，候補カテゴリ集合を変更した上で検出処理そのものを再度実行する必要がある．

本研究では，物体領域の検出とカテゴリのアノテーションという 2 つの判断を明確に分離したアーキテクチャを提案する．物体領域の検出には，カテゴリに依存しないバウンディングボックスを 1 回の推論で出力する DETR を用いる．カテゴリのアノテーションには，検出済みの領域を切り出した画像（クロップ）に対し，VLM によるゼロショット分類を適用する．両者が分離されているため，同一の検出結果に対して候補となる語彙集合を変更するだけで，検出処理を再実行することなくカテゴリのアノテーションを繰り返すことができる．本研究はこの性質を利用し，WordNet[12] の上位語・下位語関係をたどることで，追加学習を行わずに「animal → dog → doberman」のような粒度可変のアノテーションを実現する手法を提案する．

本稿の貢献は以下の 4 点である．第一に，物体領域の検出とカテゴリのアノテーションを分離するアーキテクチャと，その分離を利用した WordNet による粒度

可変アノテーションの手法を提案する．第二に，COCO 2017 Validation を用いた定量評価により，カテゴリのアノテーションにはオープンボキャブラリな VLM が必要であること，および物体領域の検出に DETR を用いることが位置検出精度の観点から妥当であることを示す．さらに，閉域物体検出モデルである YOLO と同一の語彙で比較し，提案手法の利点と限界を定量的に示す．第三に，提案パイプライン全体のカテゴリアノテーション精度を評価し，論文等で明示されることの少ないクロップの前処理と検出スコアの閾値が精度に大きく影響することを示す．第四に，WordNet 階層の各深さにおける VLM の確信度を定量的に評価し，粒度を細かくするにつれて確信度が変化する傾向と，WordNet の生の階層構造を候補語彙として用いることに起因する限界を，下位語が 1 語しかない分岐の頻度を含めて明らかにする．

本稿の構成は以下のとおりである．2 章では関連研究について述べる．3 章では提案手法について述べる．4 章では実験条件と結果を示し，5 章で考察を行う．6 章で本稿をまとめる．

2　関連研究

2.1　閉域的な物体検出モデル

YOLO[4] や DETR[9] に代表される物体検出モデルの多くは，ImageNet-1k[3] や COCO[5] のように，あらかじめ定めた固定のクラス集合を持つデータセットを用いて学習される．特に DETR は，Transformer に基づく End-to-End の物体検出モデルであり，候補領域の生成や Non-Maximum Suppression（NMS）といった後処理を必要とせず，集合予測に基づく損失関数により学習される．これらのモデルは，学習時に定めたクラス集合の範囲内では高い精度を示す一方，学習時に存在しなかったクラスの物体を原理的に予測できない．本研究では，YOLO の近年の実装である YOLO11 および YOLOv8[16] を比較対象とし，4.8 節で提案手法との精度の差と，その差が検出器と分類器のいずれに起因するかを評価する．本研究では，DETR の予測カテゴリそのものではなく，そのバウンディングボックス出力のみを物体領域の検出に用いる．すなわち，DETR が学習していない未知のカテゴリの物体であっても，その物体領域さえ検出できれば，後段の VLM によって開語彙のカテゴリをアノテーションできる．

2.2　オープンボキャブラリ物体検出モデル

OWL-ViT[10] や Grounding DINO[11] は，候補となるカテゴリ名や説明文をテキストクエリとして与えることで，学習時に固定されたクラス集合に依存せず物体を検出する．これらのモデルは物体領域の検出とカテゴリの予測を単一のモデルで同時に行うため，候補カテゴリ集合を変更するたびに検出処理を再実行する必要がある．候補カテゴリ集合が WordNet の階層のように多段階かつ大規模である場合，例えば `person.n.01` の直接の下位語だけで約 400 語あり，各段階・各分岐でこの再検出を繰り返すことは計算コストの観点から非効率である．本研究の設計は，物体領域の検出を 1 回だけ実行し，検出済みの領域に対する軽量な VLM の推論のみを繰り返す点で，これらのモデルと異なる．

2.3　視覚言語モデルによるゼロショット分類

CLIP[1] は，画像とその説明文のペアから構成される大規模データセットを用い，対照学習により画像エンコーダとテキストエンコーダを同時に学習するモデルである．学習後の CLIP は，任意の単語や文をテキストエンコーダに入力し，画像エンコーダの出力との類似度を計算することで，学習時に固定のクラス集合を定めることなく画像分類（ゼロショット分類）を行うことができる．本研究では，このゼロショット分類の性質を利用し，検出済みの物体領域のクロップに対して直接カテゴリのアノテーションを行う．

2.4　階層的・粒度可変な分類

ImageNet の多くのクラスは WordNet[12] の同義語集合（Synset）に対応付けられており，画像分類においてクラス階層を利用する研究は古くから存在する．しかし，従来の階層的画像分類の多くは，あらかじめ定めた固定の階層構造に対して学習を行うものであり，推論時に階層の深さや分岐を動的に選択することは想定していない．本研究の粒度可変アノテーションは，学習を一切行わず，推論時に VLM へ与える候補語彙集合を動的に変更するだけで，任意の深さまでの粒度でアノテーションを行える点で異なる．

3　提案手法

3.1　全体設計

画像 $\mathbf{X} \in \mathbb{R}^{H \times W \times C}$ が与えられたとき，本手法の目的は，画像中の物体らしい領域それぞれに対し，その物体を表す単語をアノテーションすることである．ここで，H，W，C はそれぞれ画像の高さ，幅，チャンネル数である．本手法は，以下の 2 つの処理を明確に分離する．

- **物体領域の検出**：画像 $\mathbf{X}$ を入力とし，物体候補領域に対応するバウンディングボックスの集合 $\{\mathbf{b}_1, \ldots, \mathbf{b}_K\}$ を 1 回の推論で出力する．ここで，$\mathbf{b}_k \in \mathbb{R}^4$ は k 番目の領域の左上と右下の座標，K は検出数である．
- **カテゴリのアノテーション**：各領域 k について，バウンディングボックス $\mathbf{b}_k$ に合わせて切り出したクロップ $\mathbf{X}_k$ を入力とし，与えられた候補語彙集合の中から対応する単語をアノテーションする．

物体領域の検出は候補語彙に依存しない 1 回の推論で完結するため，カテゴリのアノテーションの候補語彙集合や粒度を変更する場合でも，物体領域の検出を再実行する必要がない．3.4 節で述べる WordNet を用いた粒度可変アノテーションは，この性質を利用する．提案するパイプラインの概要を図 1 に示す．

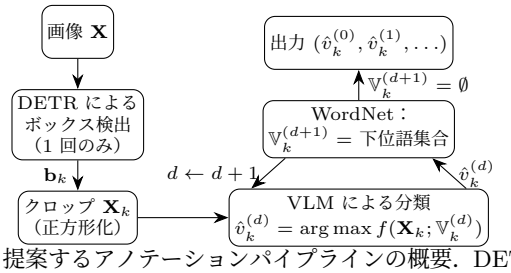


図 1: 提案するアノテーションパイプラインの概要．DETR によるボックス検出は 1 回のみ実行し，WordNet の下位語を新たな候補語彙として同一のクロップに対しカテゴリのアノテーションを繰り返す．

3.2 物体領域の検出

物体領域の検出には，DETR[9] を用いる．DETR は COCO の 91 クラスで学習済みであるが，本研究では DETR が予測するカテゴリラベルは使用せず，各出力の「物体なし」以外のクラス確率の最大値を検出スコアとし，検出スコアが閾値 θ 以上のバウンディングボックス $\{\mathbf{b}_1, \ldots, \mathbf{b}_K\}$ のみを利用する．これにより，DETR が学習していない未知のカテゴリの物体であっても，検出さえされれば後段の VLM によって開語彙のカテゴリをアノテーションできる．

3.3 視覚言語モデルによるカテゴリのアノテーション

各領域 k に対応する単語をアノテーションするために，候補語彙集合 $\mathbb{V}$ 上のスコアを出力する VLM

$$f(\cdot; \mathbb{V}) : \mathbb{R}^{H' \times W' \times C} \to [0,1]^{|\mathbb{V}|} \tag{1}$$

を用いる．ここで，$|\mathbb{V}|$ は候補語彙数であり，$f(\mathbf{X}; \mathbb{V})$ の第 v 成分 $f(\mathbf{X}; \mathbb{V})_v$ は，語彙中の単語 v が画像 $\mathbf{X}$ に対して当てはまる度合いを表す．H'，W' は f への入力画像の高さ・幅である．カテゴリのアノテーションは，クロップ $\mathbf{X}_k$ に対する f の出力が最大となる単語を選ぶことで行い，そのときの出力値を確信度 c_k とする．

$$\hat{v}_k = \arg\max_{v \in \mathbb{V}} f(\mathbf{X}_k; \mathbb{V})_v, \quad c_k = f(\mathbf{X}_k; \mathbb{V})_{\hat{v}_k} \tag{2}$$

f への入力を画像全体とした場合，画像中に同一カテゴリの物体が複数存在する場合や，対象と無関係な背景中の物体の情報が f の出力に混入し，対象の物体に対するアノテーションが不正確になる．そこで本研究では，領域 k のバウンディングボックス $\mathbf{b}_k$ にちょうど合わせて切り出したクロップを f に入力する．ただし，一般的な VLM の前処理は入力画像の短辺を所定の解像度にリサイズした後に中央の正方形を切り出すため，細長いクロップをそのまま入力すると物体の両端が失われる．そこで本研究では，クロップを黒で正方形にパディングした画像

$$\mathbf{X}_k = \mathrm{Pad}(\mathrm{Crop}(\mathbf{X}, \mathbf{b}_k)) \tag{3}$$

を f に入力する．ここで，$\mathrm{Crop}(\mathbf{X}, \mathbf{b})$ は画像 $\mathbf{X}$ から $\mathbf{b}$ の範囲を切り出す関数，$\mathrm{Pad}(\cdot)$ は長辺に合わせて上下または左右を黒で埋めて正方形にする関数である．パディングはボックス外の画像の内容を含まないため，周辺の物体が写り込むことはない．以降，パディングを行わずにクロップをそのまま入力する方式を center，(3) の方式を pad と呼ぶ．

3.4 WordNet による粒度可変アノテーション

本手法の中心的な特徴は，物体領域の検出とカテゴリのアノテーションが分離されていることを利用し，同一のクロップ $\mathbf{X}_k$ に対して候補語彙集合を変えながら繰り返しカテゴリのアノテーションを行うことで，段階的に粒度の細かい分類を実現する点にある．

候補語彙集合として COCO の 80 クラス $\mathbb{V}^{(0)}$ を用いた第 1 段階のアノテーションにより，(2) から単語 $\hat{v}_k^{(0)}$ を得る．単語 v に対応する WordNet の Synset を $\mathrm{synset}(v)$，Synset s の直接の下位語の集合を $\mathrm{Hyponyms}(s)$ とする．深さ $d \geq 1$ における候補語彙集合を，1 つ浅い段階で選ばれた Synset の下位語集合

$$\mathbb{V}_k^{(d)} = \mathrm{Hyponyms}\big(\mathrm{synset}(\hat{v}_k^{(d-1)})\big) \tag{4}$$

とし，この候補語彙集合を用いて同一のクロップ $\mathbf{X}_k$ に対し (2) を再度適用することで，単語 $\hat{v}_k^{(d)}$ と確信度 $c_k^{(d)}$ を得る．この処理を，$\mathbb{V}_k^{(d)} = \emptyset$ となるか，利用者が指定した最大深さに達するまで繰り返す．最終的な出力は，粗い粒度から細かい粒度への単語の列 $(\hat{v}_k^{(0)}, \hat{v}_k^{(1)}, \ldots)$ と，各段階の確信度 $(c_k^{(0)}, c_k^{(1)}, \ldots)$ の組である．本実装では，COCO の各クラス名に対応する Synset を定義文を確認して手動で定め，各下位語 Synset の先頭のレンマ名を候補語とする．

3.5 視覚言語モデル f の実装

(1) を満たす具体的なモデル f として，本研究では性質の異なる 2 種類の実装を比較する．

ResNet50-IN1k（閉域モデル）：ImageNet-1k[3] で学習済みの ResNet-50[2] であり，1000 クラスに対する確率ベクトル $\mathbf{p}(\mathbf{X}) \in [0,1]^{1000}$ を出力する．候補語 v の末尾の語をレンマ化した上で，クラス名と完全一致するクラスの集合を $\mathbb{M}(v)$ とし，

$$f(\mathbf{X}; \mathbb{V})_v = \begin{cases} \max_{j \in \mathbb{M}(v)} p_j(\mathbf{X}) & (\mathbb{M}(v) \neq \emptyset) \\ 0 & (\mathbb{M}(v) = \emptyset) \end{cases} \tag{5}$$

とする．ここで，$p_j(\mathbf{X})$ は $\mathbf{p}(\mathbf{X})$ の第 j 成分である．このモデルは，カテゴリのアノテーションにオープンボキャブラリな VLM が必要であることを検証するための比較対象として用いる．

CLIP-RN50，CLIP-ViT-B/32（オープンボキャブラリモデル）：CLIP[1] は画像エンコーダ g_I とテキストエンコーダ g_T から構成される．候補語 v を “a photo of a $\{v\}$” という形式のプロンプト $t(v)$ に埋め込み，

$$f(\mathbf{X};\mathbb{V})_v = \frac{\exp\big(\tau \cos(g_I(\mathbf{X}), g_T(t(v)))\big)}{\sum_{u\in\mathbb{V}} \exp\big(\tau \cos(g_I(\mathbf{X}), g_T(t(u)))\big)} \quad (6)$$

を f の出力とする．ここで，$\cos(\cdot,\cdot)$ はコサイン類似度，τ は学習済みの温度パラメータ（$\tau = 100$）である．(6) はソフトマックスであるため，候補語彙が 1 語のみの場合は画像によらず $f = 1$ となることに注意する．画像エンコーダが ResNet-50 ベースの CNN である CLIP-RN50 と，Vision Transformer（ViT）[13] である CLIP-ViT-B/32 の 2 種類を用いる．4.2 節の比較評価を経て，以降の実験では CLIP-ViT-B/32 をカテゴリのアノテーションのための代表的な VLM として用いる．

4 実験

4.1 共通設定

特に断らない限り，定量評価には COCO 2017 Validation[5] の 5000 枚から，乱数シード 42 で再現可能な形でランダムサンプリングした 500 枚の画像を用いた．500 枚に含まれる iscrowd=0 の GT インスタンスは 3206 件である．DETR は ResNet-50 をバックボーンとする学習済みモデル（facebook/detr-resnet-50），CLIP は OpenCLIP[14] で提供される OpenAI の学習済みモデル，ResNet50-IN1k は torchvision の IMAGENET1K_V1 の重みを用いた．推論は NVIDIA GeForce RTX 4070 Ti（12GB）上で実施し，いずれの実験もピークの GPU メモリ使用量は 3GB 未満であった．本研究の手法は学習を伴わないため，すべての実験は学習済みモデルの推論のみで構成される．

4.2 カテゴリのアノテーションにおけるオープンボキャブラリ性の必要性

語彙数が限定的な ResNet50-IN1k と，オープンボキャブラリな語彙表現力を持つ CLIP-RN50，CLIP-ViT-B/32 を比較した．この評価では，画像全体を f に入力し，スコアの上位 k 語の集合 $\mathbb{R}_k$ と画像の正解語集合 $\mathbb{G}$ から，画像ごとの Precision と Recall を

$$\mathrm{P@}k = \frac{|\mathbb{R}_k \cap \mathbb{G}|}{k}, \quad \mathrm{R@}k = \frac{|\mathbb{R}_k \cap \mathbb{G}|}{|\mathbb{G}|} \quad (7)$$

により計算し，画像間で平均した．候補語彙集合を COCO の 80 クラス $\mathbb{V}_A$ とし，画像中に存在する GT カテゴリの集合を正解とするタスク A（閉域評価）と，500 枚の GT キャプションから spaCy[6]（en_core_web_sm）で抽出した名詞・動詞のレンマのユニーク集合 $\mathbb{V}_B$（1371 語）を候補語彙とし，各画像のキャプション由来の語集合を正解とするタスク B（広域評価）を設定した．GT が空の画像を除き，タスク A では 491 枚，タスク B では 500 枚を評価した．統計的検定には，画像単位で対応付けられた指標値に対する Wilcoxon 符号付き順位検定 [7] と，画像単位のブートストラップリサンプリング（$B = 1000$）による 95%信頼区間 [8] を用いた．

表 1: タスク A（閉域評価）とタスク B（広域評価）における画像単位の単語推定精度．

タスク	手法	P@1	R@1	P@5	R@5
A	ResNet50-IN1k	0.216	0.091	0.069	0.123
	CLIP-RN50	0.855	0.431	0.316	0.659
	CLIP-ViT-B/32	0.855	0.433	0.328	0.687
B	ResNet50-IN1k	0.294	0.024	0.100	0.041
	CLIP-RN50	0.528	0.045	0.334	0.139
	CLIP-ViT-B/32	0.534	0.045	0.352	0.148

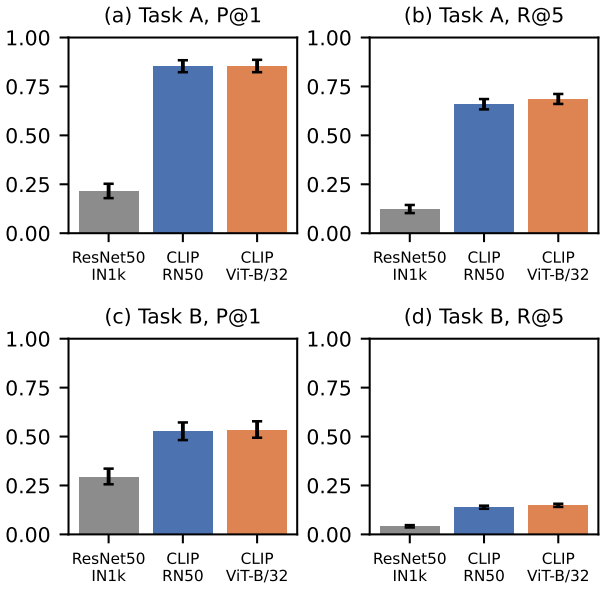


図 2: ResNet50-IN1k と CLIP の指標の比較．誤差棒は画像単位のブートストラップ 95%信頼区間である．

表 1 と図 2 に結果を示す．ResNet50-IN1k と CLIP 系の間には，タスク A・タスク B の全指標において統計的に有意な差が認められた．p 値は最大でもタスク B の R@1 における 2.2×10^{-12} であった．ResNet50-IN1k は COCO のクラス名の多くと一致する ImageNet のクラスを持たないため，例えば “person” に対するスコアは常に 0 となる．この結果は，カテゴリのアノテーションには固定のクラス集合に縛られない VLM が必要であることを示している．

一方，CLIP-RN50 と CLIP-ViT-B/32 の間では，P@1 と R@1 には有意な差が認められなかった（$p \geq 0.53$）．P@5 と R@5 では CLIP-ViT-B/32 がわずかに高く，有意な差が認められた（タスク A の R@5 で $p = 6.3 \times 10^{-4}$，タスク B の P@5 で $p = 2.8 \times 10^{-3}$）．両 CLIP の差は，ResNet50-IN1k との差と比べて 1 桁以上小さい．この結果は，f の性能差において「学習手法・語彙設計（クラス分類か，対照学習によるオープンボキャブラリ化か）」の要因が「モデル構造（CNN か ViT か）」の要因よりも支配的であることを示唆している．

4.3 物体領域検出モデルの選択

本研究ではカテゴリに依存しない検出のみを行う DETR を物体領域の検出に採用する．この選択が位

表 2: 物体領域検出モデルの比較（4 画像，GT インスタンス 10 件）．Recall は Recall@IoU0.5 である．

手法	閾値	平均提案数	Recall	平均最良 IoU
DETR	0.5	2.25	**0.800**	0.705
DETR	0.7	1.75	0.700	0.669
DETR	0.9	1.50	0.600	0.583
OWL-ViT	0.1	1.50	0.500	0.517
Grounding DINO	0.35	1.50	0.500	0.546
YOLO11x	0.25	2.25	0.700	0.719
YOLOv8x	0.25	2.25	0.800	**0.767**

置検出精度の観点からも妥当であることを確認するため，DETR と，オープンボキャブラリ物体検出モデルである OWL-ViT（owlvit-base-patch32）[10]，Grounding DINO（grounding-dino-tiny）[11] の 3 手法を比較した．OWL-ViT と Grounding DINO には，COCO の 80 クラス名をテキストクエリとして与え，予測カテゴリを捨ててクラス間で NMS（IoU 0.5）を行うことで，クラス非依存のボックス集合とした．検出スコアの閾値は OWL-ViT を 0.1，Grounding DINO を box 0.35・text 0.25 とし，DETR は $\theta \in \{0.5, 0.7, 0.9\}$ を比較した．評価には，500 枚のうち GT インスタンスが 2〜3 件の画像をサンプリング順に走査し，GT インスタンスの合計が 10 件となる最初の 4 枚の組を用いた．評価指標は，GT インスタンスに対し Intersection over Union（IoU）が 0.5 以上の提案が存在する割合（Recall@IoU0.5）と，GT インスタンスごとの提案との最良 IoU の平均値（平均最良 IoU）である．

表 2 に結果を示す．平均提案数をそろえた条件（DETR の $\theta = 0.9$）でも，DETR の Recall@IoU0.5 と平均最良 IoU は OWL-ViT および Grounding DINO と同等以上であった．3 手法とも Recall が 1.0 に達しない原因を調べたところ，画像面積の 0.3%しかない遠方の車と，画像のほぼ全体（面積比 98%）を占める食卓の GT が，全手法で検出されていなかった．したがって，位置検出精度の観点から OWL-ViT や Grounding DINO を用いる利点は認められない．一方，OWL-ViT と Grounding DINO は候補カテゴリ集合を検出処理の入力として必要とするため，カテゴリの粒度を変更するたびに検出処理そのものを再実行する必要がある．DETR はカテゴリに依存しない検出を 1 回行えばよく，同一の検出結果を後段の処理全体で再利用できる．本研究ではこの設計上の利点に基づき，DETR を採用する．なお，4.8 節で用いる YOLO11x と YOLOv8x（検出スコアの閾値 0.25）を同じ 4 画像で評価したところ，Recall@IoU0.5 はそれぞれ 0.700，0.800，平均最良 IoU は 0.719，0.767 であり，DETR（$\theta = 0.5$）と同程度であった．ただし，4 画像・10 インスタンスによる比較であり，統計的な結論を得るには評価規模の拡大が必要である．

4.4 カテゴリのアノテーションの精度

提案するパイプライン全体としてのカテゴリアノテーション精度を評価した．500 枚に対し DETR を 1 回ずつ実行し，検出ボックスと GT ボックスをハンガリアン法

表 3: パイプライン全体のカテゴリアノテーション精度．n は評価インスタンス数である．

θ	前処理	n	CLIP-ViT-B/32 Top-1	CLIP-ViT-B/32 Top-5	CLIP-RN50 Top-1	CLIP-RN50 Top-5
0.5	center	2343	0.481	0.778	0.367	0.649
0.7	center	2217	0.488	0.783	0.371	0.655
0.9	center	1892	0.506	0.804	0.389	0.681
0.97	center	1519	0.525	0.830	0.408	0.709
0.5	pad	2343	0.560	0.855	0.460	0.740
0.7	pad	2217	0.568	0.858	0.467	0.747
0.9	pad	1892	0.587	0.874	0.484	0.776
0.97	pad	1519	**0.604**	**0.894**	0.512	0.808

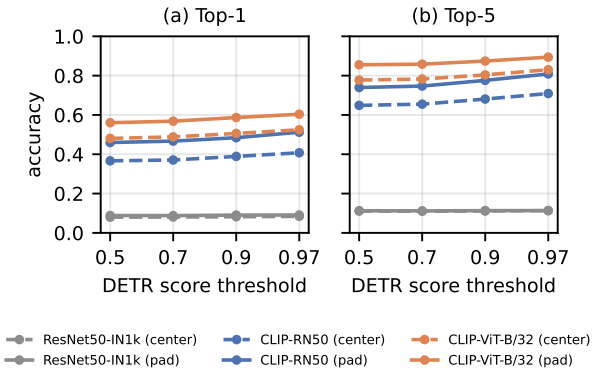


図 3: DETR の検出スコアの閾値に対するカテゴリアノテーション精度．破線は center，実線は pad である．

[15] により IoU 0.5 以上で 1 対 1 に対応付けた組を評価インスタンスとした．候補語彙集合を COCO の 80 クラスとし，各インスタンスのクロップに (2) を適用して，推定単語が GT カテゴリと一致する割合（Top-1 正解率）と，上位 5 語に GT カテゴリが含まれる割合（Top-5 正解率）を計算した．検出スコアの閾値 $\theta \in \{0.5, 0.7, 0.9, 0.97\}$ と，3.3 節で述べたクロップの前処理（center，pad）を変化させた．

表 3 と図 3 に結果を示す．CLIP-ViT-B/32，$\theta = 0.97$，pad の設定で，Top-1 正解率 0.604，Top-5 正解率 0.894 が得られた．CLIP の 2 モデルでは，すべての閾値において pad は center より Top-1 正解率が 0.08〜0.10 高かった．例えば $\theta = 0.97$ の CLIP-ViT-B/32 では，pad によって正解に転じたインスタンスが 217 件，逆に不正解に転じたインスタンスが 97 件であった．クラス別では，bottle の正解率が 0.344 から 0.844 へ，car の正解率が 0.378 から 0.581 へ向上した．図 4 に例を示す．縦長のボトルのクロップは center ではラベル部分だけが残り “book” と推定されたが，pad では全体形状が保たれて “bottle” と推定された．また，閾値を高くするほど正解率は単調に向上した．これは，検出スコアの高い，すなわち明瞭に写った物体のみが評価対象として残るためと考えられる．なお，同じパイプラインに ResNet50-IN1k を用いた場合の Top-1 正解率は全条件で 0.09 以下であり，4.2 節の結論と整合する．

一方，人物クラスの正解率は前処理によらず低く，$\theta = 0.97$ で center が 0.377，pad が 0.383 であった．人物は評価インスタンスの 34%を占め，主な誤りは person →

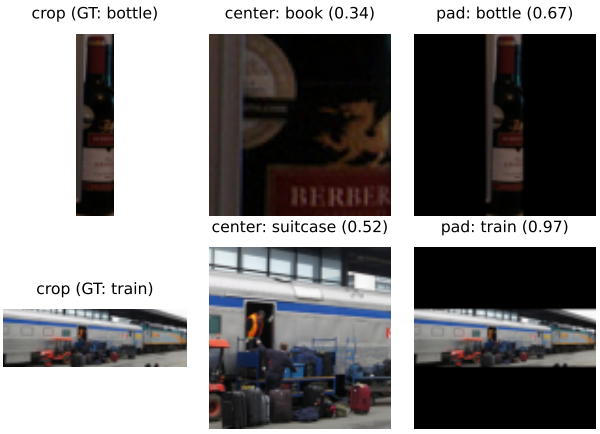


図 4: クロップの前処理による VLM への入力の違い．左からクロップ，center で VLM に入力される領域，pad の入力であり，見出しは推定単語と確信度である．

baseball bat（38 件），skateboard（27 件），tie（26 件），tennis racket（24 件）であった．これは，人物が持っている物や身に着けている物に対して CLIP が強く反応するためであり，前処理では解消されない誤りである．

4.5 WordNet による粒度可変アノテーションにおける確信度の評価

3.4 節で述べた WordNet 階層を用いた粒度可変アノテーションについて，各深さにおける VLM の確信度を評価した．COCO の 80 クラス（深さ 0）については GT カテゴリとの正誤を判定できるが，それより細かい粒度については COCO に GT が存在せず正誤を判定できない．そこで，4.4 節の最良の設定（CLIP-ViT-B/32, $\theta = 0.97$，pad）において深さ 0 の推定が GT カテゴリと一致した 917 件を対象に，深さを増すにつれて確信度がどのように変化するかを調べた．最大深さは設けず，下位語集合が空になるまで細分化を繰り返した．

表 4 と図 5 に結果を示す．深さ 0 から深さ 1 にかけて，平均確信度は 0.642 から 0.442 へ大きく低下した．深さ 1 では，候補語彙数が COCO の 80 クラスから平均 108.8 語へ増加し，かつ視覚的に類似した細かいカテゴリ間の識別が求められる．特に `person.n.01` の直接の下位語は 398 語あり，深さ 1 の候補数の平均を押し上げている．深さ 2 以降の平均確信度は 0.715，0.577，0.755 と変動しており，深さ 1 のように単調に低下する傾向は見られない．しかし，(6) より候補語彙が 1 語のみの段階では確信度が必ず 1 となる．このような段階は深さ 1 以降の全 1188 段階のうち 209 段階（約 18%）あり，特に深さ 2 では 328 段階中 110 段階を占めた．これらを除いた平均確信度は，深さ 1 で 0.378，深さ 2 で 0.571，深さ 3 で 0.481 であり，深さ 2 以降の見かけの確信度の高さの一部は単一候補の分岐によるものである．また，深さ 3 以降のインスタンス数は数件〜数十件と急減するため，これらの深さにおける確信度の変動を一般的な傾向として解釈することはできない．深さ 2 以降のインスタンス数の急減は，大多数の COCO カテゴリの WordNet 下位語ツリーが浅いことを反映している．

表 4: WordNet 階層の深さごとの統計．単一は候補語彙が 1 語のみの段階の数，除外は単一の段階を除いた平均確信度である．

深さ d	インスタンス数	平均候補数	平均確信度	単一	除外
0	917	80.0	0.642	0	0.642
1	784	108.8	0.442	80	0.378
2	328	6.2	0.715	110	0.571
3	54	14.5	0.577	10	0.481
4	18	5.7	0.755	9	0.511
5	4	10.8	0.406	0	0.406

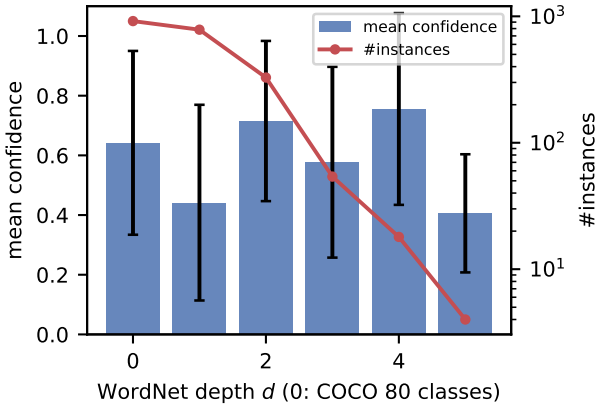


図 5: WordNet 階層の深さごとの平均確信度（棒，左軸，誤差棒は標準偏差）とインスタンス数（折れ線，右軸，対数）．

4.6 COCO 以外の語を含む実画像へのアノテーション

本手法の開語彙性が COCO の 80 クラスという評価用データセットの語彙に限定されないことを確認するため，COCO に含まれない語を主要な被写体とする実画像に対するアノテーションを実施した．第 1 段階の候補語彙集合として，COCO の 80 クラスに加え，penguin, helicopter, kangaroo, camel, lighthouse 等，COCO に含まれない 22 語を手動で追加した計 102 語からなる語彙集合を用いた．評価対象の画像には，Wikimedia Commons で公開されている，ペンギン，ヘリコプター，ラクダ，カンガルー，灯台の写真 6 枚を用いた．灯台については構図の異なる 2 枚を用いた．DETR の閾値は $\theta = 0.5$，前処理は pad とした．

図 6 に結果を示す．ペンギン，ヘリコプター，ラクダ，カンガルーの 4 枚については，DETR が物体領域を検出し，第 1 段階でいずれも正しい語（“penguin”，“helicopter”，“camel”，“kangaroo”）がアノテーションされた．主要被写体の確信度は 0.74〜0.99 であった．さらに下位語の段階では，ラクダの画像で “camel” → “Arabian camel”（確信度 0.78）という妥当な細分化が得られた．一方，アデリーペンギンの画像では，候補に “adelie” が含まれるにもかかわらず “emperor penguin” や “jackass penguin” が選ばれ，細分化は不正確であった．灯台の画像については，2 枚のいずれにおいても灯台の塔そのものは検出されなかった．1 枚目では塔の隣の家屋 2 棟が検出され，それらに “lighthouse”（確信度 0.41，0.45）

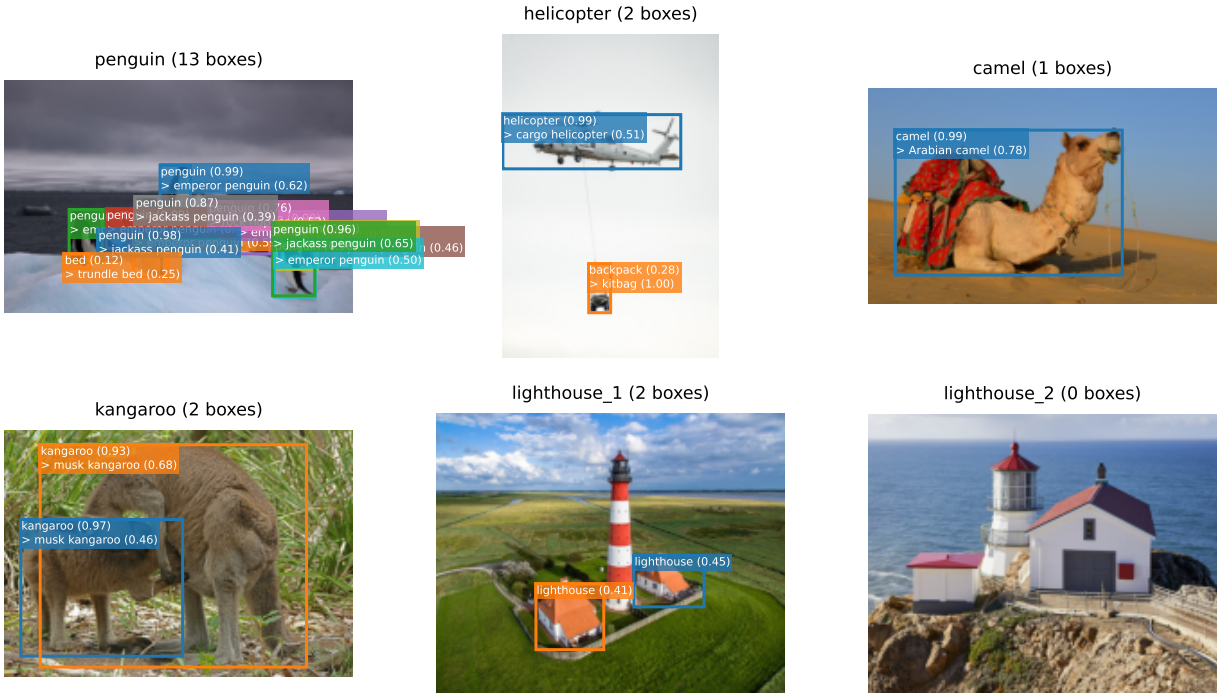


図 6: COCO 以外の語を含む実画像へのアノテーション結果．各ボックスに各段階の推定単語と確信度を示す．画像は Wikimedia Commons（CC BY 2.0，CC0，CC BY-SA 3.0/4.0）より取得した．

が付与された．2 枚目では検出スコア 0.5 以上のボックスが 1 件も出力されなかった．これは，DETR がカテゴリに依存しない検出器として利用されている場合でも，その領域提案の性質は COCO の学習データの分布から完全には独立ではなく，COCO のいずれのカテゴリとも視覚的に大きく異なる物体に対しては検出自体に失敗し得ることを示している．

また，ヘリコプターの画像では，機体の “helicopter”（確信度 0.99）に加え，吊り下げられた車両の小領域が “backpack”（確信度 0.28）→ “kitbag” とアノテーションされた．この領域は候補語彙中に適切な語が存在しないため，最も類似度の高い無関係な語が選択されたと考えられる．開語彙アノテーションにおいて，候補語彙に正解語が含まれない領域への対処が今後の課題であることを示している．

4.7　定性的結果

図 7 に，COCO の画像に対する階層的アノテーションの結果を示す．猫の領域は “cat” → “domestic cat”（確信度 0.95）と妥当に細分化された．一方，キリンの画像では 6 領域すべてが “giraffe” の下位語段階で “okapi”（キリン科の近縁種であるオカピ）に細分化された．これは `giraffe.n.01` の下位語が okapi の 1 語のみであり，候補選択が実質的に機能していないためである．同様に，象の画像では “Indian elephant” の唯一の下位語である “white elephant”（アルビノのインドゾウ）が，熊の画像では “American black bear” の唯一の下位語である “cinnamon bear” が，いずれも確信度 1.00 で選ばれた．4.5 節で定量的に示したとおり，このような単一候補の分岐は例外的なものではなく，okapi（28 件），spindlelegs（24 件），moped（18 件）等，COCO の評価インスタンス全体にわたって再現している．

4.8　閉域物体検出モデル YOLO との比較

提案手法の第 1 段階は，COCO の 80 クラスを候補語彙とするため，COCO の 80 クラスで学習した閉域物体検出モデルと同じ語彙でアノテーションを行う．そこで，YOLO 自体の語彙である COCO の 80 クラスを用いて，提案手法と YOLO を比較した．YOLO には，Ultralytics[16] の学習済みモデルである YOLO11n，YOLO11m，YOLO11x，YOLOv8x を用いた．これらは COCO train2017 で学習されており，評価に用いる val2017 は学習データに含まれない．YOLO の検出スコアの閾値は既定値の 0.25 に加えて 0.5 と 0.7 を比較し，NMS の IoU 閾値は既定値の 0.7 とした．4.4 節と同じ 500 枚に対し，YOLO の検出ボックスと GT ボックスをハンガリアン法により IoU 0.5 以上で 1 対 1 に対応付け，YOLO が出力したクラスによる Top-1 正解率と，80 クラスのスコアの上位 5 件による Top-5 正解率を計算した．また，対応付けられるインスタンスの数は手法や閾値によって異なるため，GT インスタンス全体のうち正しいカテゴリでアノテーションされた割合を正命名率

$$r = \frac{N_{\mathrm{correct}}}{N_{\mathrm{GT}}} \tag{8}$$

として計算した．ここで，N_{correct} は Top-1 の推定が GT カテゴリと一致したインスタンス数，N_{GT} は GT インスタンスの総数（3206 件）である．

表 5 と図 8 に結果を示す．COCO の 80 クラスの範囲

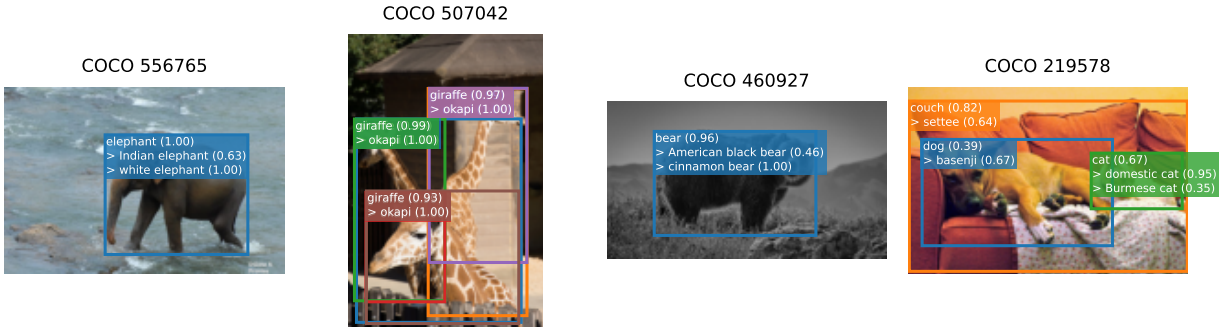


図 7: WordNet による粒度可変アノテーションの定性的結果．左から，象，キリン，熊，犬と猫とソファの画像である．

表 5: YOLO と提案手法のカテゴリアノテーション精度（COCO の 80 クラス）．閾値は提案手法では θ，YOLO では検出スコアの閾値，r は正命名率である．

手法	閾値	n	Top-1	Top-5	r
提案手法	0.5	2343	0.560	0.855	0.410
提案手法	0.97	1519	0.604	0.894	0.286
YOLO11n	0.25	1717	0.957	0.996	0.513
YOLO11m	0.25	2115	0.976	0.998	0.644
YOLO11x	0.25	2210	0.981	0.999	**0.676**
YOLO11x	0.7	1474	**0.993**	0.997	0.456
YOLOv8x	0.25	2220	0.971	0.999	0.672
YOLO11x + CLIP	0.25	2210	0.565	0.860	0.390
YOLO11x + CLIP	0.7	1474	0.604	0.907	0.278

内では，YOLO の Top-1 正解率は 0.957〜0.993 であり，提案手法の 0.560〜0.604 を大きく上回った．正命名率も YOLO11x の 0.676 に対し提案手法は 0.410 であり，YOLO の方が高い．両手法が検出した共通の GT インスタンスに限定して比較しても，YOLO11x（閾値 0.25）と提案手法（$\theta = 0.97$）に共通する 1480 件において，Top-1 正解率は YOLO11x が 0.989，提案手法が 0.609 であった．YOLO11x のみが正解した件数は 570 件，提案手法のみが正解した件数は 8 件であり，McNemar 検定で有意な差が認められた（$p < 10^{-150}$）．人物クラスに限ると，YOLO11x の正解率は 0.998 であるのに対し，提案手法は 0.379 であり，4.4 節で述べた人物クロップの誤りが差の大きな部分を占める．ただし，人物以外のクラスでも，YOLO11x が 0.984，提案手法が 0.732 と差があった．

この差が検出器と分類器のいずれに起因するかを切り分けるため，YOLO11x の検出ボックスのクロップを pad の前処理で CLIP-ViT-B/32 に入力して分類する組合せ（YOLO11x + CLIP）を評価した．その結果，Top-1 正解率は 0.565〜0.604 となり，インスタンス数が同程度の提案手法とほぼ一致した．例えば，YOLO11x + CLIP の閾値 0.7（1474 件）と提案手法の $\theta = 0.97$（1519 件）は，いずれも Top-1 正解率が 0.604 であった．したがって，COCO の 80 クラスの範囲内での YOLO との差は検出器ではなく，COCO の 80 クラスで教師あり学習された YOLO の分類と，ゼロショットの CLIP による分類との精度の差に起因する．

一方，図 9 に示すとおり，4.6 節の COCO 以外の語を含む実画像に対しては，YOLO11x はペンギンを “bird”，

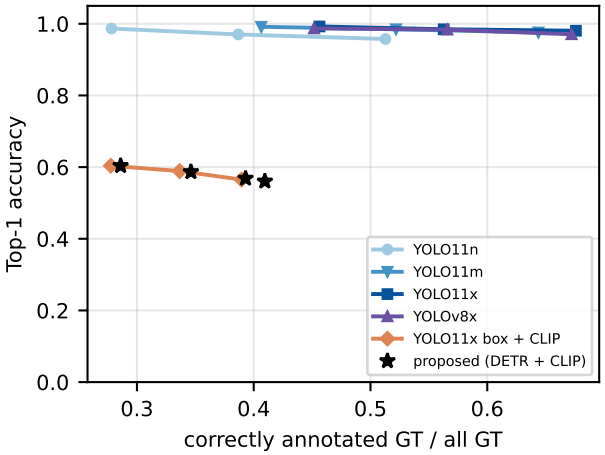


図 8: 正命名率（横軸）と，対応付けられたインスタンスにおける Top-1 正解率（縦軸）の関係．YOLO は検出スコアの閾値 0.25，0.5，0.7，提案手法は $\theta = 0.5, 0.7, 0.9, 0.97$ の結果である．

ラクダを “dog”，カンガルーを “bear” と “sheep”，ヘリコプターを “airplane” とアノテーションした．YOLO は学習した 80 クラスの語しか出力できないため，これらの物体を正しく命名することは原理的にできない．同じ画像に対し，提案手法は “penguin”，“camel”，“kangaroo”，“helicopter” を正しくアノテーションしている（図 6）．また，灯台の画像 2 枚では，YOLO11x も検出スコア 0.25 以上のボックスを 1 件も出力しなかった．

5 考察

5.1 従来手法との差別化点

本研究の差別化点は，以下の 3 点に整理できる．

第一に，YOLO[4] や DETR[9] のような閉域的な物体検出モデルに対しては，学習時に定めた固定のクラス集合を超えたカテゴリを予測できないという制約を解消している．本手法では，DETR の予測カテゴリを用いず，バウンディングボックス出力のみを物体領域の検出に用いることで，検出済みの領域に対し後段の VLM が任意の候補語彙でカテゴリをアノテーションできるようにしている．4.6 節で確認したとおり，この設計により，COCO の 80 クラスに含まれない語（penguin, helicopter, kangaroo, camel）についても，追加学習なしにアノテーションが可能である．ただし，4.8 節で示したとおり，COCO の 80 クラスの範囲内では，そのク



図 9: COCO 以外の語を含む実画像に対する YOLO11x（検出スコアの閾値 0.25）の検出結果．各ボックスに YOLO が出力したクラスと検出スコアを示す．

ラスで教師あり学習した YOLO の方がカテゴリのアノテーション精度は大幅に高い．本手法の利点は学習時の語彙を超えた語や粒度の異なる語でアノテーションできる点にあり，閉域の語彙で十分な用途では YOLO のような閉域モデルが適している．

第二に，OWL-ViT[10] や Grounding DINO[11] のようなオープンボキャブラリ物体検出モデルに対しては，候補カテゴリ集合を変更するたびに検出処理全体を再実行する必要があるという制約を解消している．4.3 節で確認したとおり，位置検出精度は DETR とこれらのモデルの間で大きな差がないため，本手法は同等の位置検出精度を維持しつつ，物体領域の検出を 1 回のみに抑え，後段のカテゴリのアノテーションのみを候補語彙集合の変更に応じて繰り返す設計を実現している．

第三に，ImageNet のクラス階層を利用する従来の階層的画像分類の多くは，あらかじめ定めた固定の階層構造に対して学習を行うものであり，推論時に階層の深さや分岐を動的に選択することは想定していない．本手法は，WordNet の上位語・下位語関係を推論時にたどることで，学習を一切行わずに粒度可変のアノテーションを実現している点で異なる．

5.2 クロップの前処理と検出スコアの閾値の影響

4.4 節の結果は，同一の DETR と VLM を用いても，クロップの前処理と検出スコアの閾値によって Top-1 正解率が 0.481 から 0.604 まで変化することを示している．特に前処理の影響は，pad でも center でも物体の外側の画像内容は含まないにもかかわらず，VLM の標準前処理である中央切り出しによって細長い物体の一部が失われることに起因する．高さが幅の 2 倍以上のクロップでは，$\theta = 0.9$ において Top-1 正解率が center の 0.441 から pad の 0.545 へ向上した．クロップを入力とする VLM のゼロショット分類では，前処理を明示することが精度の比較に不可欠である．一方，人物クラスでは前処理によらず正解率が 0.38 程度にとどまった．人物のクロップには，人物とともにバット，ネクタイ，ラケット等の物体が含まれることが多く，“a photo of a person” よりもそれらの物体のプロンプトとの類似度が高くなる．これは，候補語彙の中で包含関係にある物体同士をどのように扱うかという，クロップに基づくアノテーションに固有の課題である．

5.3 WordNet 階層をそのまま用いることの限界

4.5 節，4.7 節の結果は，WordNet の生の階層構造をそのまま候補語彙として用いることに起因する 2 種類の限界を示している．

第一に，深さ 0 から深さ 1 への確信度の大幅な低下（0.642 から 0.442）に見られるように，候補語彙数の増加および視覚的に類似した細かいカテゴリ間の識別困難性により，最初の細分化の段階でアノテーションの信頼性が低下する．さらに，`person.n.01` の下位語には “suspect”（20 件），“thin person”（24 件），“visually impaired person”（9 件）等，外見だけからは判断できない社会的・属性的な語が多く含まれ，これらが実際に選択されていた．

第二に，giraffe → okapi のように，WordNet の階層構造には，視覚的なカテゴリ分類の候補語彙として不適切な分岐が含まれている．特に下位語が 1 語しかない分岐では，(6) のソフトマックスにより確信度が画像によらず 1 となり，候補選択が実質的に機能しない．このような段階は細分化の段階全体の約 18%を占め，深さ 2 以降の平均確信度を見かけ上押し上げていた．単一候補の段階を除くと，深さ 1 から深さ 3 の平均確信度は 0.378，0.571，0.481 であり，深さ 0 と比べて一貫して低い．これらの限界は，WordNet の階層構造が視覚的な類似性ではなく言語学的な意味関係に基づいて構築されていることに起因すると考えられる．

5.4 物体領域の検出の COCO 学習分布への依存

4.6 節の灯台の事例は，カテゴリに依存しない検出器として利用する場合であっても，DETR の物体領域の検出そのものが COCO の学習データの分布から完全には独立ではないことを示している．すなわち，本手法における「物体領域の検出とカテゴリのアノテーションの分離」は，カテゴリの予測に関する制約を解消するものであるが，物体領域の候補生成そのものに関する制約は解消しない．学習データに存在する物体の形状・構図との類似性への依存は残る．また，ヘリコプターの吊り荷が “backpack” として誤ってアノテーションされた事例は，候補語彙集合に正解語が存在しない領域に対して，VLM が候補語彙中で最も類似度の高い無関係な語を選択してしまう問題を示している．

5.5 今後の課題

今後の課題として，第一に，WordNet 階層のフィルタリングによる粒度可変アノテーションの実用性向上が挙げられる．具体的には，下位語が 1 語しかない分岐の打ち切りや，絶滅種・希少種・外見から判断できない語の除外である．第二に，物体領域の検出モデルの比較を本稿の 4 画像から 500 枚規模へ拡大し，統計的な比較を行うことが挙げられる．第三に，物体領域の検出における学習分布への依存を緩和するため，Segment Anything Model（SAM）等の汎用的なセグメンテーションモデルと DETR を組み合わせるなど，物体領域の検出モデル自体の改善が挙げられる．第四に，候補語彙に正解語が存在しない領域を棄却する仕組みとして，確信度に対する閾値処理の高度化や，候補語彙に「その他」に相当する語を加える方法の導入が挙げられる．第五に，人物クロップにおける持ち物・装着物への誤反応を抑えるため，プロンプトの設計や，検出済みの他の領域との包含関係を考慮したアノテーションが挙げられる．第六に，4.8 節の結果を踏まえ，COCO の 80 クラスで高精度な YOLO の予測を深さ 0 のアノテーションとして用い，深さ 1 以降の細分化と 80 クラスに含まれない語のアノテーションのみを VLM で行う組合せが挙げられる．

6 おわりに

本稿では，画像中の物体らしい領域を検出するタスクと，その領域に対応するカテゴリをアノテーションするタスクを明確に分離する物体アノテーション手法を提案した．物体領域の検出にはカテゴリに依存しない高精度なバウンディングボックスを 1 回の推論で出力する DETR を用い，カテゴリのアノテーションには検出済みの領域のクロップに対する VLM のゼロショット分類を用いた．この分離により，一度検出した物体領域に対し，候補語彙集合を変更するだけで異なる粒度・異なる語彙でのカテゴリのアノテーションを行うことができ，WordNet の上位語・下位語関係を用いることで，追加学習を一切行わずに粒度可変のアノテーションを実現した．

一連の定量評価を通じて，以下を明らかにした．第一に，オープンボキャブラリな CLIP が閉域的な ResNet50-IN1k に対して統計的に有意に高い単語推定精度を示し，カテゴリのアノテーションにはオープンボキャブラリな VLM が必要であることを確認した．第二に，物体領域の検出モデルとして DETR，OWL-ViT，Grounding DINO を比較し，位置検出精度において DETR が劣らないことを確認した上で，検出を 1 回で済ませられる DETR の採用が妥当であることを示した．第三に，提案パイプライン全体で Top-1 正解率 0.604，Top-5 正解率 0.894 を達成し，クロップを正方形にパディングして VLM に入力することで Top-1 正解率が約 0.08 向上することを示した．また，COCO に含まれない語を主要な被写体とする実画像に対しても追加学習なしに正しくアノテーションできることを確認した一方，学習データと視覚的性質が大きく異なる物体（灯台）に対しては DETR の検出自体が失敗することも確認した．第四に，WordNet 階層を用いた粒度可変アノテーションについて，最初の細分化の段階で確信度が大きく低下すること，および下位語が 1 語しかない分岐が細分化の約 18%で生じ，深い階層の見かけの確信度を押し上げていることを明らかにした．第五に，COCO の 80 クラスで学習した YOLO と同一の語彙で比較し，80 クラスの範囲内では YOLO の精度が大幅に高く，その差は検出器ではなく分類器に起因すること，一方で YOLO は COCO 外の物体を 80 クラス内の語でしかアノテーションできないことを示した．

今後の課題として，WordNet 階層のフィルタリング，物体領域の検出モデルの大規模な比較，SAM 等の汎用的なセグメンテーションモデルとの組み合わせ，候補語彙に正解語が存在しない領域を棄却する仕組みの導入，および YOLO と VLM を組み合わせた階層的アノテーションが挙げられる．

参考文献

[1] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning Transferable Visual Models From Natural Language Supervision,” in *Proc. International Conference on Machine Learning (ICML)*, 2021.

[2] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[3] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A Large-Scale Hierarchical Image Database,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2009.

[4] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You Only Look Once: Unified, Real-Time Object Detection,” in *Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.

[5] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common Objects in Context,” in *Proc. European Conference on Computer Vision (ECCV)*, 2014.

[6] M. Honnibal and I. Montani, “spaCy 2: Natural Language Understanding with Bloom Embeddings, Convolutional Neural Networks and Incremental Parsing,” 2017.

[7] F. Wilcoxon, “Individual Comparisons by Ranking Methods,” *Biometrics Bulletin*, vol. 1, no. 6, pp. 80–83, 1945.

[8] B. Efron, “Bootstrap Methods: Another Look at the Jackknife,” *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.

[9] N. Carion, F. Massa, G. Synnaeve, N. Usunier, A. Kirillov, and S. Zagoruyko, “End-to-End Object Detection with Transformers,” in *Proc. European Conference on Computer Vision (ECCV)*, 2020.

[10] M. Minderer, A. Gritsenko, A. Stone, M. Neumann, D. Weissenborn, A. Dosovitskiy, A. Mahendran, A. Arnab, M. Dehghani, Z. Shen, X. Wang, X. Zhai,

T. Kipf, and N. Houlsby, "Simple Open-Vocabulary Object Detection with Vision Transformers," in *Proc. European Conference on Computer Vision (ECCV)*, 2022.

[11] S. Liu, Z. Zeng, T. Ren, F. Li, H. Zhang, J. Yang, C. Li, J. Yang, H. Su, J. Zhu, and L. Zhang, "Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection," in *Proc. European Conference on Computer Vision (ECCV)*, 2024.

[12] G. A. Miller, "WordNet: A Lexical Database for English," *Communications of the ACM*, vol. 38, no. 11, pp. 39–41, 1995.

[13] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in *Proc. International Conference on Learning Representations (ICLR)*, 2021.

[14] G. Ilharco, M. Wortsman, R. Wightman, C. Gordon, N. Carlini, R. Taori, A. Dave, V. Shankar, H. Namkoong, J. Miller, H. Hajishirzi, A. Farhadi, and L. Schmidt, "OpenCLIP," Zenodo, 2021, doi: 10.5281/zenodo.5143773.

[15] H. W. Kuhn, "The Hungarian Method for the Assignment Problem," *Naval Research Logistics Quarterly*, vol. 2, no. 1–2, pp. 83–97, 1955.

[16] G. Jocher, J. Qiu, and A. Chaurasia, "Ultralytics YOLO," 2023, `https://github.com/ultralytics/ultralytics`.