粒度可変物体アノテーションの論文に関する質疑応答の整理

2026 年 11 月 9 日

本資料は，物体領域検出とカテゴリアノテーションの分離に基づく粒度可変物体アノテーションの論文（再現元の `main.pdf` と再現実験の `paper/main.pdf`）について，手法と実験結果に関する質問とその回答を整理したものである．

A. 手法の全体像

Q1. この論文は何をしているのか

画像中の物体の場所を検出する部品（DETR）と，検出した物体にカテゴリ名を付与する部品（CLIP）を分離した手法である．分離により，1 回の検出結果に対して候補語彙を差し替えられるため，WordNet の下位語をたどって animal → dog → doberman のように粒度を段階的に変えたアノテーションを再学習なしに行える．

Q2. 処理の流れはどうなっているのか

画像 → DETR（1 回のみ）→ クロップ（pad で正方形化）
→ 深さ 0：CLIP が COCO の 80 クラスから 1 語を選ぶ（例：dog）
→ WordNet が，選ばれた 1 語の直接の下位語を辞書から取り出す（例：basenji 等の 18 語）
→ 深さ 1：同じクロップに対し，CLIP がその下位語から 1 語を選ぶ（例：basenji）
→ 下位語が存在しなくなるまで繰り返す

WordNet は新しい語を生成するのではなく，登録済みの下位語を取り出すだけである．また，次の段階の候補語彙は，深さ 0 の語彙全体の下位語ではなく，前の段階で選ばれた 1 語の下位語のみである．DETR の推論は最初の 1 回のみであり，以降の段階では同じクロップを再利用する．出力は粗い語から細かい語への列と，各段階の確信度である．

Q3. COCO 以外の語を出力できたのは，CLIP 自体が語を出力したためか

CLIP は語を生成するモデルではなく，与えられた候補語彙の中から画像に最も合う語を選ぶモデルである．COCO 外の語（camel 等）を出力できたのは，COCO 外の 22 語を候補語彙に追加したためである．CLIP の利点は，語を追加するだけで，その語を再学習なしに認識できる点にある．YOLO で同じ語を扱うには，画像の収集，アノテーション，再学習が必要である．なお，深さ 1 以降の語（Arabian camel 等）は人手で追加したものではなく，WordNet から自動的に得たものである．

Q4. COCO の 80 クラスは何のために用いたのか

COCO の 80 クラスはデータセットの公式のカテゴリであり，本研究で作成したものではない．人手で作成したのは，80 クラスと WordNet の Synset の対応表（例：fire hydrant → fireplug.n.01）と，COCO 外の 22 語である．80 クラスを用いた理由は以下の 3 点である．

1. COCO の正解は 80 クラスで付与されているため，推定結果と正解を同じ語どうしで照合できる．
2. WordNet の階層をたどる出発点（深さ 0）として，身の回りの物体を適度な粒度で表す語彙である．
3. 同じ 80 クラスで学習した YOLO と，同一の条件で比較できる．

手法自体は 80 クラスに依存しないが，深さ 0 で誤った語を選ぶと，以降の段階でも誤った分岐をたどるという弱点がある．

B. 部品の選択

Q5. なぜ DETR を用いるのか

DETR はカテゴリ名の入力を必要とせず，1 回の推論でバウンディングボックスを出力できる．そのため，候補語彙を何度変更しても検出を再実行する必要がない．位置検出精度も OWL-ViT や Grounding DINO と同程度であり，Non-Maximum Suppression（NMS）を必要としない点も扱いやすい．

Q6. なぜ DETR と CLIP の組み合わせを提案するのか

検出した領域を CLIP で分類する組み合わせ自体は既存であり，ViLD 等でベースラインとして用いられている．また，RegionCLIP は，画像全体と文章の組で学習した CLIP がクロップした領域の分類を苦手とすることを指摘している．本研究の新規性は組み合わせではなく，1 回の検出結果を再利用して粒度を段階的に変えるという使い方と，その性質の分析にある．各部品には，分離の効果を明確にするために標準的なモデルを用いている．

Q7. DETR 以外の選択肢はないのか．DETR にしかできないことはあるか

DETR にしかできないことはない．YOLO，RT-DETR，Region Proposal Network（RPN），Object Localization Network（OLN），Segment Anything（SAM），汎用的な語「object」を与えた Grounding DINO 等で置き換えられる．実際に，YOLO11x のボックスを CLIP で分類しても，Top-1 正解率は提案手法と同じ 0.604 であった．ただし，OWL-ViT や Grounding DINO も「object」で 1 回だけ検出すれば検出の再実行は不要であり，論文における比較の前提として留意が必要である．DETR のスコアは COCO のクラスらしさを表すため，COCO と外見が大きく異なる物体（灯台）は検出されなかった．COCO 外の物体を対象とする場合は，SAM や OLN のようにカテゴリに依存しない検出器が適している可能性がある．

C. 前処理（pad と center）

Q8. クロップは物体自身であるのに，なぜ pad や center が必要なのか．スコアは高くなるのか

CLIP は 224×224 ピクセルの正方形の画像のみを入力とするが，クロップは物体の形状に応じて縦長や横長になる．そのため，クロップを正方形に変換する処理が必要であり，center と pad はその変換方法の違いである．

方法	処理	結果
center	短辺を 224 に縮小し，中央の正方形を切り出す（CLIP の標準の前処理）	長辺方向の端が欠ける．瓶は book，電車は suitcase と誤った
pad	黒の余白を加えて正方形にしてから縮小する	物体の全体が残る．瓶は bottle（0.67），電車は train（0.97）となった

pad により bottle の正解率は 0.344 から 0.844 に向上し，全体の Top-1 正解率は約 0.08 向上した．目的はスコアを上げることではなく物体の全体を CLIP に入力することであり，その結果として精度が向上した．ただし，人物の正解率は約 0.38 のままであり，pad による改善は見られなかった．

Q9. 単純に 224×224 に拡大縮小（引き伸ばし）することはできないのか

可能であり，CLIP は引き伸ばした画像も入力として受け付ける．引き伸ばしは本研究では実験しておらず，精度への影響は未検証である．歪みにより学習時と異なる見た目となるため精度が低下する可能性がある一方，物体が画像全体に写り pad より多くの画素を物体に使えるため精度が向上する可能性もある．R-CNN では，検出領域を引き伸ばし（warp）で正方形にする方法が良い結果を示している．CLIP における効果を確認するには，`make_crop` に引き伸ばしを追加し，center，pad と比較する実験が必要である．

D. 実験と結果の読み方

Q10. 実験 1（4.2 節）は何をしているのか

カテゴリのアノテーションに CLIP のような視覚言語モデル（Vision-Language Model，VLM）が必要かを確かめる実験であり，検出は用いず画像全体を入力している．ImageNet の 1000 クラスで学習した ResNet50-IN1k と，2 種類の CLIP（CLIP-RN50，CLIP-ViT-B/32）を比較した．タスク A は COCO の 80 クラスから選ぶ閉域評価，タスク B はキャプションから抽出した 1371 語から選ぶ広域評価である．

P@k は上位 k 語のうち正解の割合，R@k は正解のうち上位 k 語に含まれた割合である．例えば，正解が 3 語の画像で CLIP が tie，person，handbag，wine glass，dining table の順に出力し，tie と person を含む 3 語が正解である場合，P@1 = 1.0，R@1 = 0.33，P@5 = 0.6，R@5 = 1.0 となる．タスク B の R@1 が低いのは，1 枚あたりの正解語が十数語あるという指標の性質による．

タスク A の P@1 は，ResNet50-IN1k が 0.216，CLIP が 0.855 であった．COCO の 80 クラスのうち ImageNet に同名のクラスが存在するのは 19 クラスのみであり，ResNet50-IN1k は person や dog を出力できない．2 種類の CLIP の差は小さく，性能を左右するのはモデルの構造（CNN か ViT か）ではなく，学習方法と語彙の設計であることが示唆される．

Q11. 図 7 と YOLO との比較は深さ 0 のみか．図 7 は提案手法の結果か

YOLO との比較は深さ 0（COCO の 80 クラス）のみであり，4.8 節の表 5，図 8，図 9 に示している．図 7 は WordNet による粒度可変アノテーションの定性結果であり，提案手法（DETR の閾値 0.5，pad，CLIP-ViT-B/32，WordNet）で得た結果である．

Q12. dog の確信度が低く下位語で高くなり，cat → domestic cat → Burmese cat で確信度が上下するのは良い結果か

確信度の上下のみでは良否を判断できず，手法の性質どおりの挙動である．各段階の確信度はその段階の候補語彙の中での相対的な値であり，候補数が段階ごとに異なるため，深さ間で直接比較できない．

段階	選ばれた語	確信度	候補数	偶然の水準に対する倍率
深さ 0	dog	0.389	80	約 31 倍
深さ 1	basenji	0.671	18	約 12 倍
深さ 0	cat	0.672	80	約 54 倍

段階	選ばれた語	確信度	候補数	偶然の水準に対する倍率
深さ 1	domestic cat	0.950	2	約 1.9 倍
深さ 2	Burmese cat	0.354	15	約 5.3 倍

dog の確信度が低いのは，クロップ内に写る猫やソファのカテゴリと競合したためと考えられる．一方で，候補語が互いに排他的でないこと（犬種と hunting dog，puppy 等の混在），細かい段階の正誤を COCO では検証できないこと，候補が 1 語の場合は必ず 1.00 となることが問題点として挙げられる．対策として，各段階の確信度の積である累積確信度と，確信度と候補数の積を併記する方法がある．

Q13. 表 5 で YOLO11x と YOLO11x + CLIP は同じ閾値なのに，なぜ n が異なるのか

論文の表 5 では，同じ閾値であれば n は一致している（閾値 0.25 で 2210 件，0.7 で 1474 件）．YOLO11x + CLIP は YOLO11x のボックスをそのまま用い，カテゴリの付与のみを CLIP に替えたものであるため，n は必ず一致する．n が異なって見えるのはスライド 16 枚目の表であり，閾値の列を示さずに閾値 0.25 の YOLO11x と閾値 0.7 の YOLO11x + CLIP を並べたことによる．

E. COCO 外の語に対する YOLO との比較

Q14. YOLO11x ではなく，YOLO11x + CLIP と比較する方が公平ではないか

YOLO は再学習が不可能なわけではなく，新しいクラスの画像とアノテーションを用意すれば追加学習できるが，その準備には大きな手間を要する．論文の比較は，YOLO を再学習せずに用いた場合の限界を示すことを目的としている．YOLO11x + CLIP は「提案手法の検出器を YOLO に替えたもの」であるため，提案手法との比較は検出器の比較となる．この比較を追加すれば，設計が検出器に依存しないことの裏付けとなるが，COCO 外の画像に対する YOLO11x + CLIP の実験は未実施である．再学習なしに新しい語を扱えるという同一の条件で比較する相手としては，YOLO-World が最も適している．

Q15. COCO 外の語の比較は深さ 0 のみで，WordNet は用いていないのか

YOLO との比較は深さ 0 のみである．一方，4.6 節の提案手法の実験では，COCO 外の 22 語にも WordNet の Synset を対応付けており，camel → Arabian camel，kangaroo → musk kangaroo のように深さ 1 以降もたどっている．YOLO には下位語の仕組みがないため，深さ 1 以降は比較していない．

Q16. この比較は不公平ではないか

深さ 0 で比較したこと自体は，YOLO に深さ 1 以降の出力がないための妥当な選択である．しかし，以下の 2 点で不公平である．

1. 追加した 22 語は被写体を既知として選んだものであり，提案手法の候補語彙には正解が必ず含まれる．一方，YOLO の 80 クラスには正解が含まれない．
2. 評価に用いた画像は 6 枚のみである．

したがって，この比較は閉域モデルでは出力できない語を提案手法が再学習なしに出力できるという機能の違いを示すものであり，精度の優劣を示すものではない．公平な比較とするには，被写体を見ずに定めた大規模な語彙（LVIS の 1203 カテゴリ等）を用いること，YOLO-World や YOLO11x + CLIP に同じ語彙を与えること，評価画像を増やすことが必要である．

未実施の検討事項

1. 引き伸ばしを加えた前処理の比較（center，pad，引き伸ばし）.
2. CLIP を他の VLM（SigLIP，EVA-CLIP 等）に替えた比較.
3. COCO 外の画像に対する YOLO11x + CLIP の評価と，YOLO-World との比較.
4. LVIS 等を用いた深さ 1 以降の正解率の評価と，被写体を既知としない語彙での評価.
5. スライド 16 枚目の表への閾値の列の追加.
6. 論文における，COCO 外の語の比較の限界の追記.