物体領域検出とカテゴリアノテーションの分離に基づく，WordNetを用いた粒度可変物体アノテーション

所属機関名

〇著者名

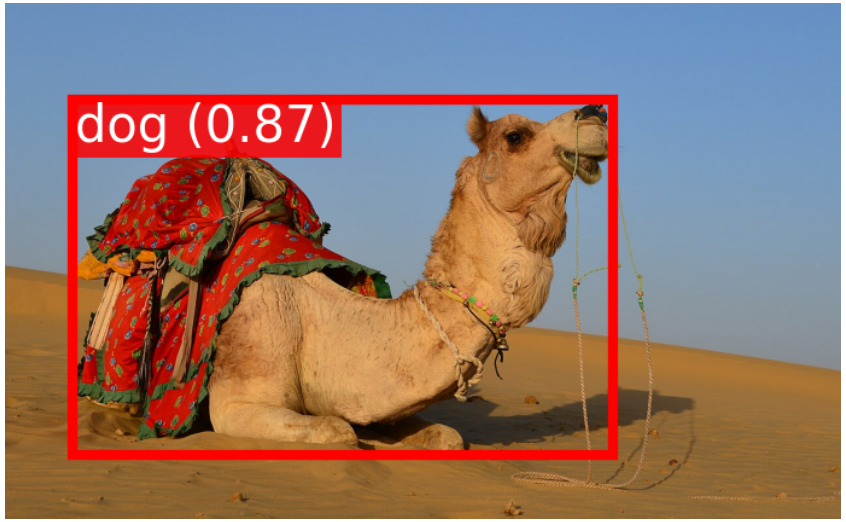


やりたいことを、できることに。
湘南工科大学
SHONAN INSTITUTE OF TECHNOLOGY
AI R&D CENTER

研究背景：閉域的な物体検出モデルの限界

- 物体アノテーション：「どこ」＋「何」
- YOLO[1]やDETR[2]は1つのモデルで学習
- 出力できるのは学習したクラスのみ
  例：COCO[7]の80クラス

→ 語の追加・粒度の変更には再学習が必要



YOLO11x[8]：ラクダ → “dog”

[1] J. Redmon, et al., “You Only Look Once: Unified, Real-Time Object Detection,” Proc. IEEE CVPR, pp.779-788, 2016.
[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[7] T.-Y. Lin, et al., “Microsoft COCO: Common Objects in Context,” Proc. ECCV, pp.740-755, 2014.
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

従来手法の課題

閉域的な物体検出
YOLO[1], DETR[2]

- 語彙が学習時に固定
- 新しい語には再学習が必要

オープンボキャブラリ検出
OWL-ViT[3], Grounding DINO[4]

- 語彙をテキストで指定できる
- 語彙の変更ごとに検出を再実行
  → 多段階の語彙では非効率

[1] J. Redmon, et al., “You Only Look Once: Unified, Real-Time Object Detection,” Proc. IEEE CVPR, pp.779-788, 2016.
[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[3] M. Minderer, et al., “Simple Open-Vocabulary Object Detection with Vision Transformers,” Proc. ECCV, pp.728-755, 2022.
[4] S. Liu, et al., “Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection,” Proc. ECCV, 2024.

研究目的

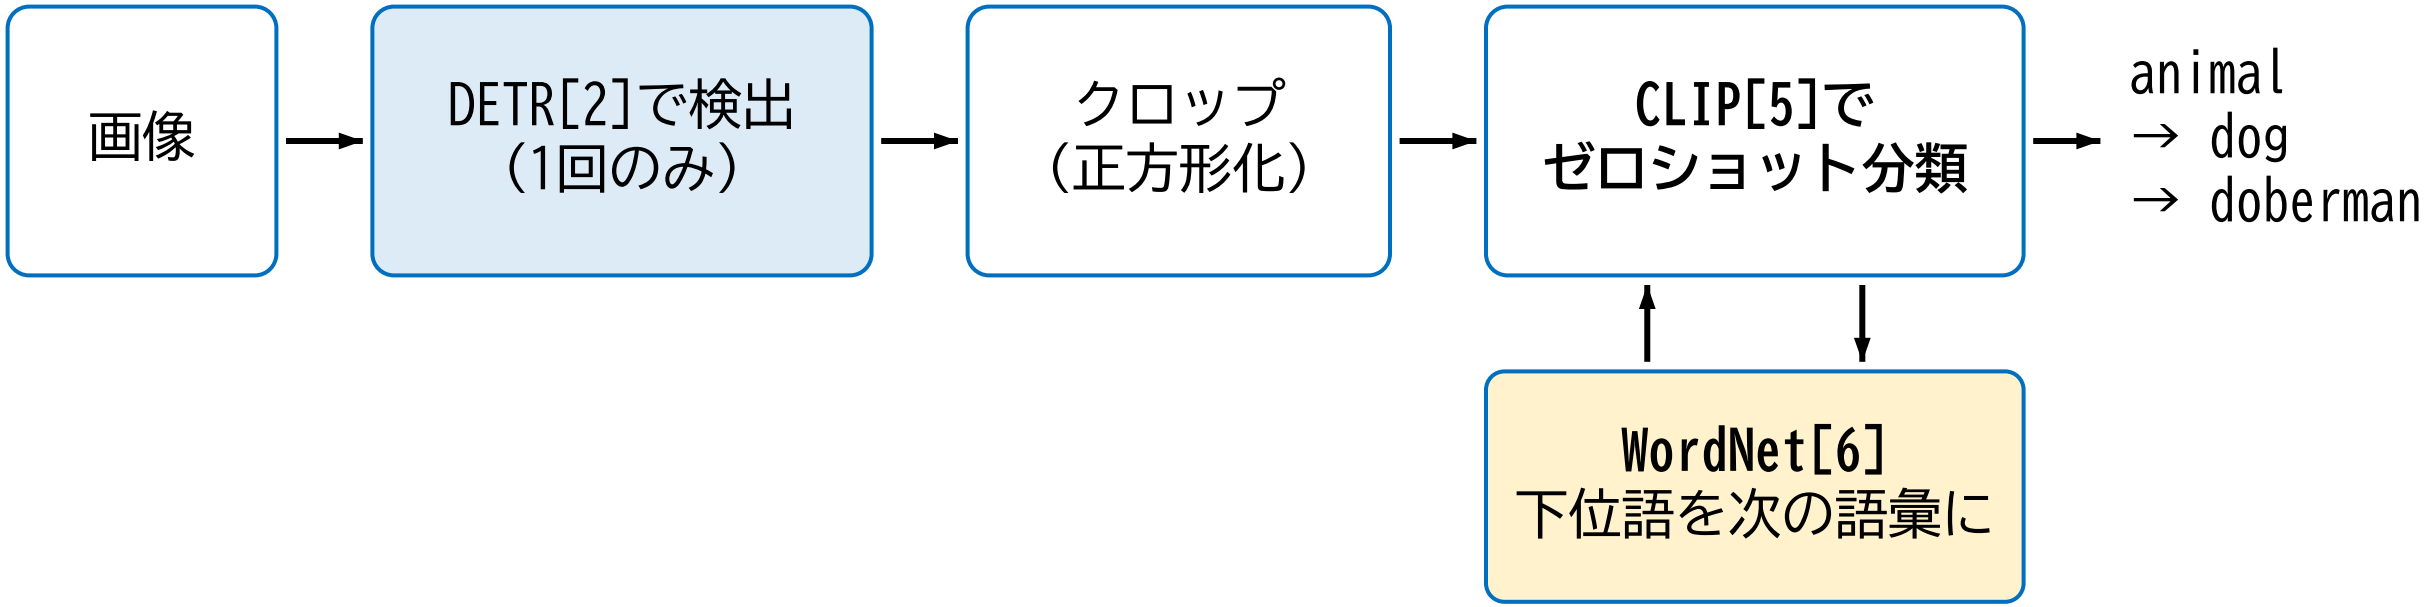
検出とカテゴリ付与を分離し，**再学習なし**で語彙と粒度を変える

検出は1回だけ行い，同じ領域で語彙を変えながら繰り返す



同じクロップに対し，WordNetの下位語を次の候補語彙にする

提案手法：検出とカテゴリ付与の分離



- 検出は語彙に依存しない → 語彙や粒度を変えても再検出は不要
- 繰り返すのは軽量なVLMの推論のみ

[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[5] A. Radford, et al., “Learning Transferable Visual Models From Natural Language Supervision,” Proc. ICML, pp.8748-8763, 2021.
[6] G. A. Miller, “WordNet: A Lexical Database for English,” Communications of the ACM, vol.38, no.11, pp.39-41, 1995.

VLMによるカテゴリのアノテーション

クロップに対するスコアが最大の単語を選ぶ

$$\hat{v}_k = \underset{v \in \mathbb{V}}{\operatorname{argmax}} f(\mathbf{X}_k; \mathbb{V})_v \tag{1}$$

CLIP[5]：プロンプトとの類似度のソフトマックス

$$f(\mathbf{X}; \mathbb{V})_v = \frac{exp\left(\tau cos\left(g_I(\mathbf{X}), g_T(t(v))\right)\right)}{\sum_{u \in \mathbb{V}} exp\left(\tau cos\left(g_I(\mathbf{X}), g_T(t(u))\right)\right)} \tag{2}$$

$\mathbf{X}_k$：領域kのクロップ，$\mathbb{V}$：候補語彙集合，$\hat{v}_k$：推定単語

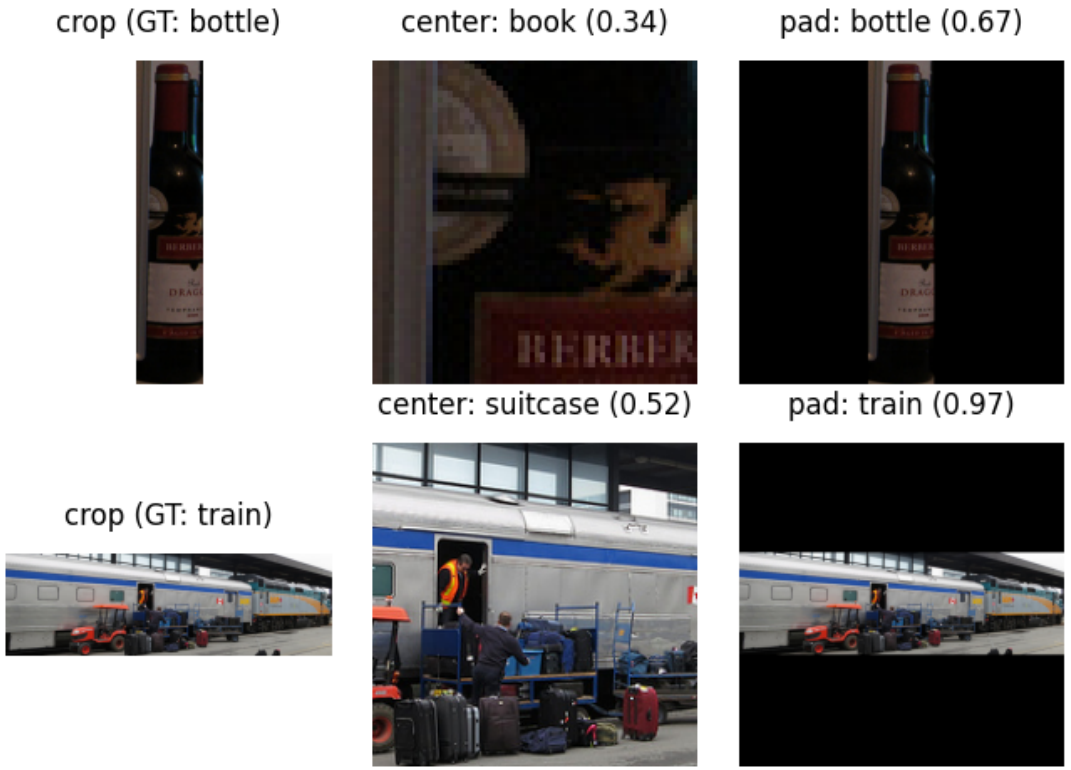
g_I，g_T：画像・テキストエンコーダ，$t(v)$：“a photo of a {v}”

τ：温度パラメータ（100），cos：コサイン類似度

[5] A. Radford, et al., “Learning Transferable Visual Models From Natural Language Supervision,” Proc. ICML, pp.8748-8763, 2021.

クロップの前処理：正方形パディング

- ボックスに合わせて切り出す
  周辺の物体の写り込みを防ぐ
- 中央切り出しでは端が欠ける
  VLMの標準の前処理
- 黒で正方形にパディング
  ボックス外の画像内容は含めない



WordNetによる粒度可変アノテーション

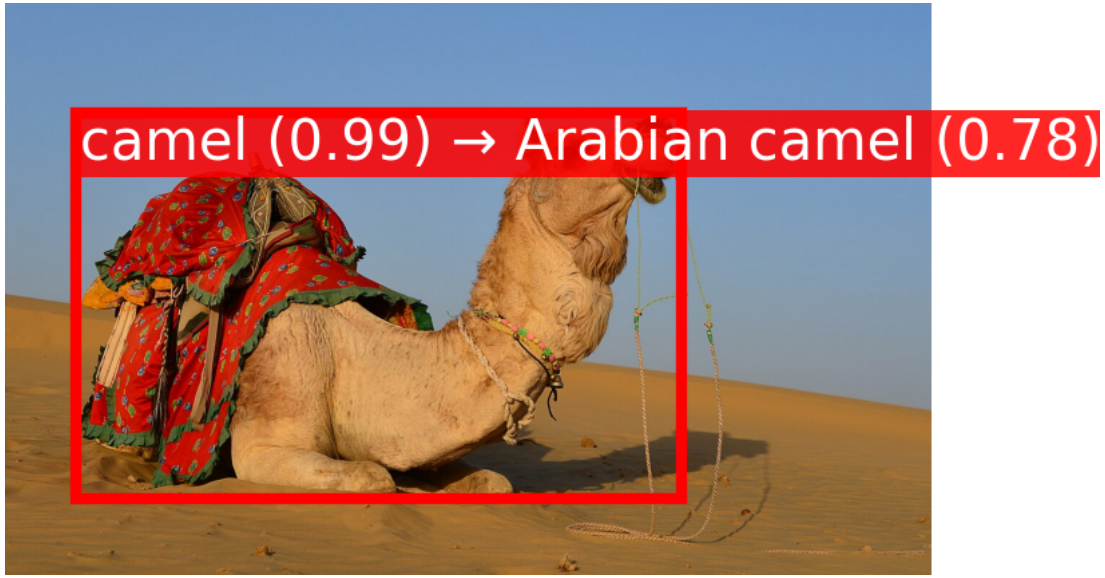
1つ浅い段階で選ばれた語の下位語を，次の候補語彙にする

$$\mathbb{V}_k^{(d)} = Hyponyms\left(synset\left(\hat{v}_k^{(d-1)}\right)\right) \quad (3)$$

d：深さ（$\mathbb{V}^{(0)}$はCOCOの80クラス）

Hyponyms：直接の下位語の集合

- 下位語がなくなるまで(1)を反復
- 出力：粗い語→細かい語の列
  各段階の確信度も出力



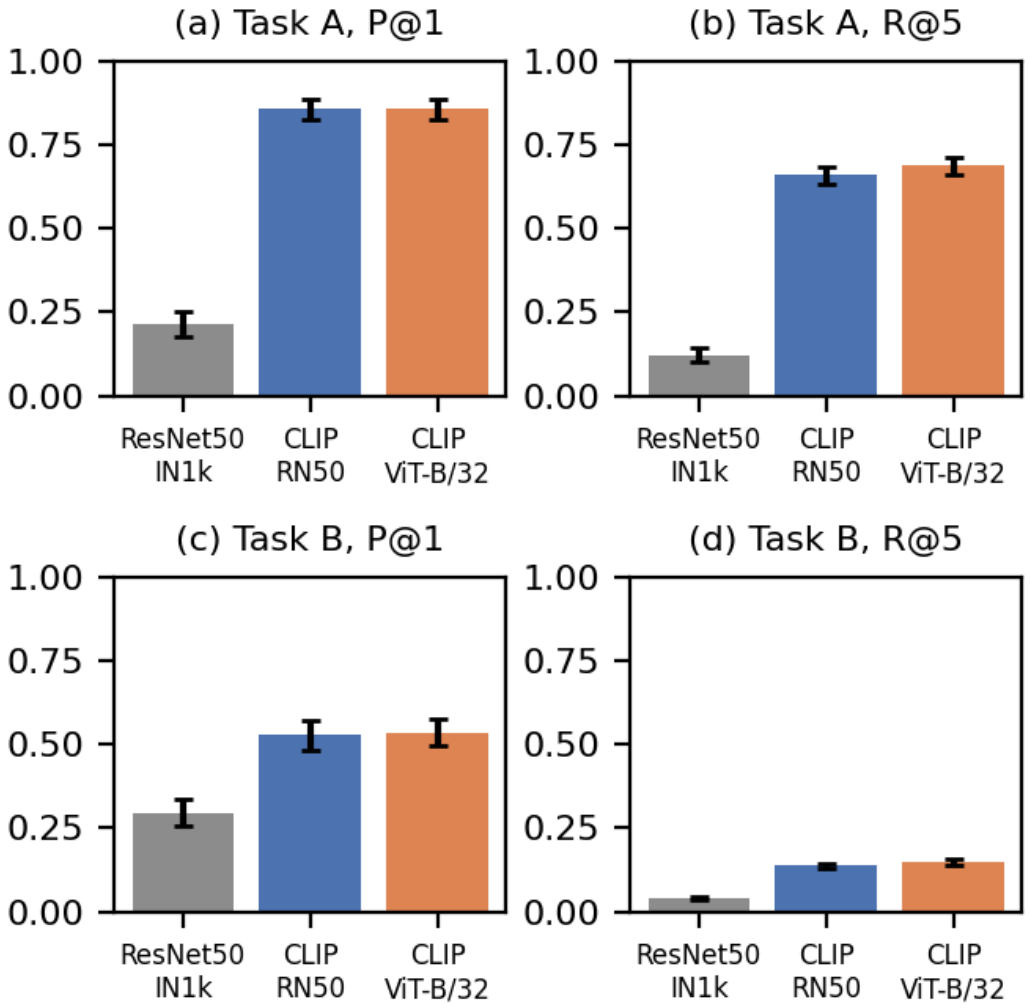
[6] G. A. Miller, “WordNet: A Lexical Database for English,” Communications of the ACM, vol.38, no.11, pp.39-41, 1995.

実験設定

項目	設定
データ	COCO 2017 Val.[7]の500枚（GTインスタンス3206件）
物体領域検出	DETR[2]（ResNet-50），検出スコアの閾値 θ
VLM	CLIP-ViT-B/32[5]（比較：ResNet50-IN1k，CLIP-RN50）
比較する検出器	OWL-ViT[3]，Grounding DINO[4]，YOLO11 / YOLOv8[8]
評価指標	Top-1/Top-5正解率，P@k / R@k，IoU，正命名率
学習	なし（すべて学習済みモデルの推論のみ）

[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[3] M. Minderer, et al., “Simple Open-Vocabulary Object Detection with Vision Transformers,” Proc. ECCV, pp.728-755, 2022.
[4] S. Liu, et al., “Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection,” Proc. ECCV, 2024.
[5] A. Radford, et al., “Learning Transferable Visual Models From Natural Language Supervision,” Proc. ICML, pp.8748-8763, 2021.
[7] T.-Y. Lin, et al., “Microsoft COCO: Common Objects in Context,” Proc. ECCV, pp.740-755, 2014.
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

実験1：オープンボキャブラリなVLMの必要性



- 画像単位の単語推定（500枚）
  タスクA：COCOの80クラス
  タスクB：キャプション由来の1371語
- タスクAのP@1：**0.216 → 0.855**
- 全指標で有意差（$p < 10^{-11}$）
- CLIP-RN50とViT-B/32の差は小さい

実験2：物体領域検出モデルの比較

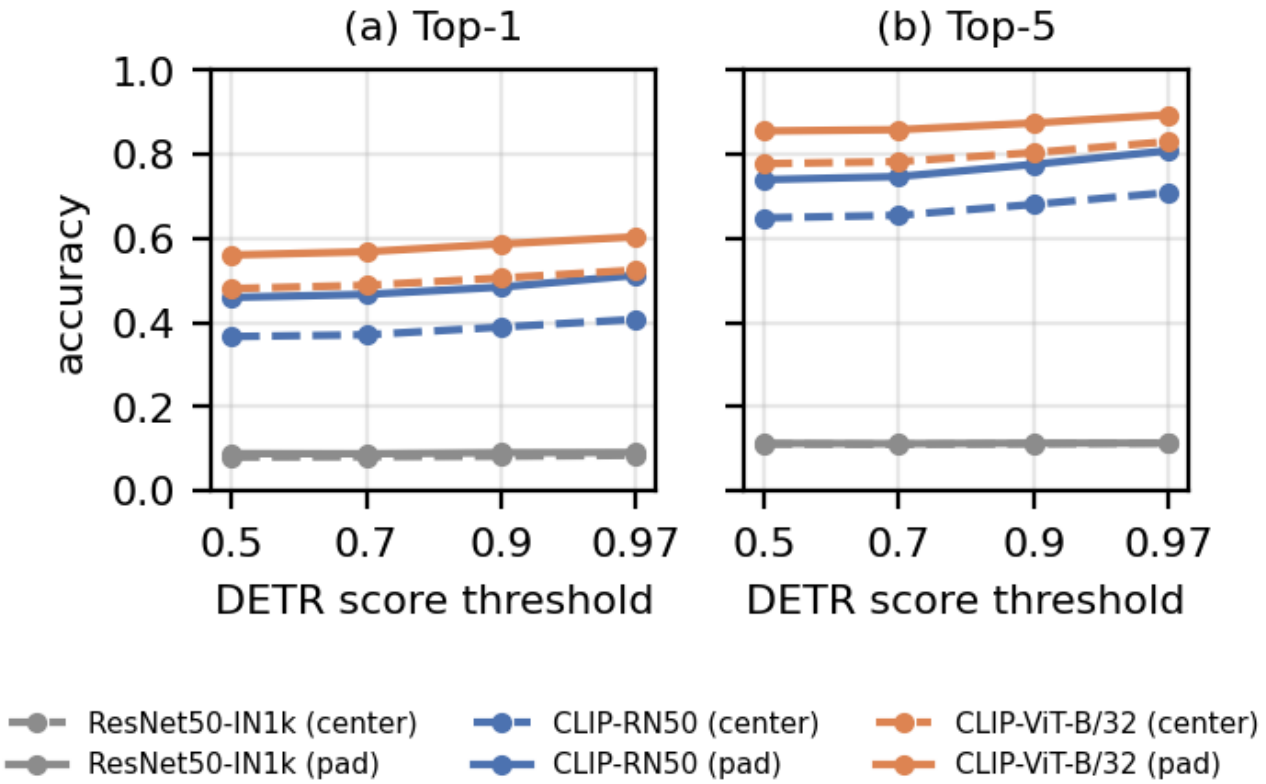
DETRの位置検出精度は他の検出器と同程度

手法	閾値	平均提案数	Recall@IoU0.5	平均最良IoU
DETR[2]	0.5	2.25	**0.800**	**0.705**
DETR[2]	0.9	1.50	0.600	0.583
OWL-ViT[3]	0.1	1.50	0.500	0.517
Grounding DINO[4]	0.35	1.50	0.500	0.546
YOLOv8x[8]	0.25	2.25	0.800	0.767

4画像・GTインスタンス10件．極小の車や画像全体を覆う食卓は全手法で未検出

[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213–229, 2020.
[3] M. Minderer, et al., “Simple Open-Vocabulary Object Detection with Vision Transformers,” Proc. ECCV, pp.728–755, 2022.
[4] S. Liu, et al., “Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection,” Proc. ECCV, 2024.
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

実験3：パイプライン全体のカテゴリアノテーション精度



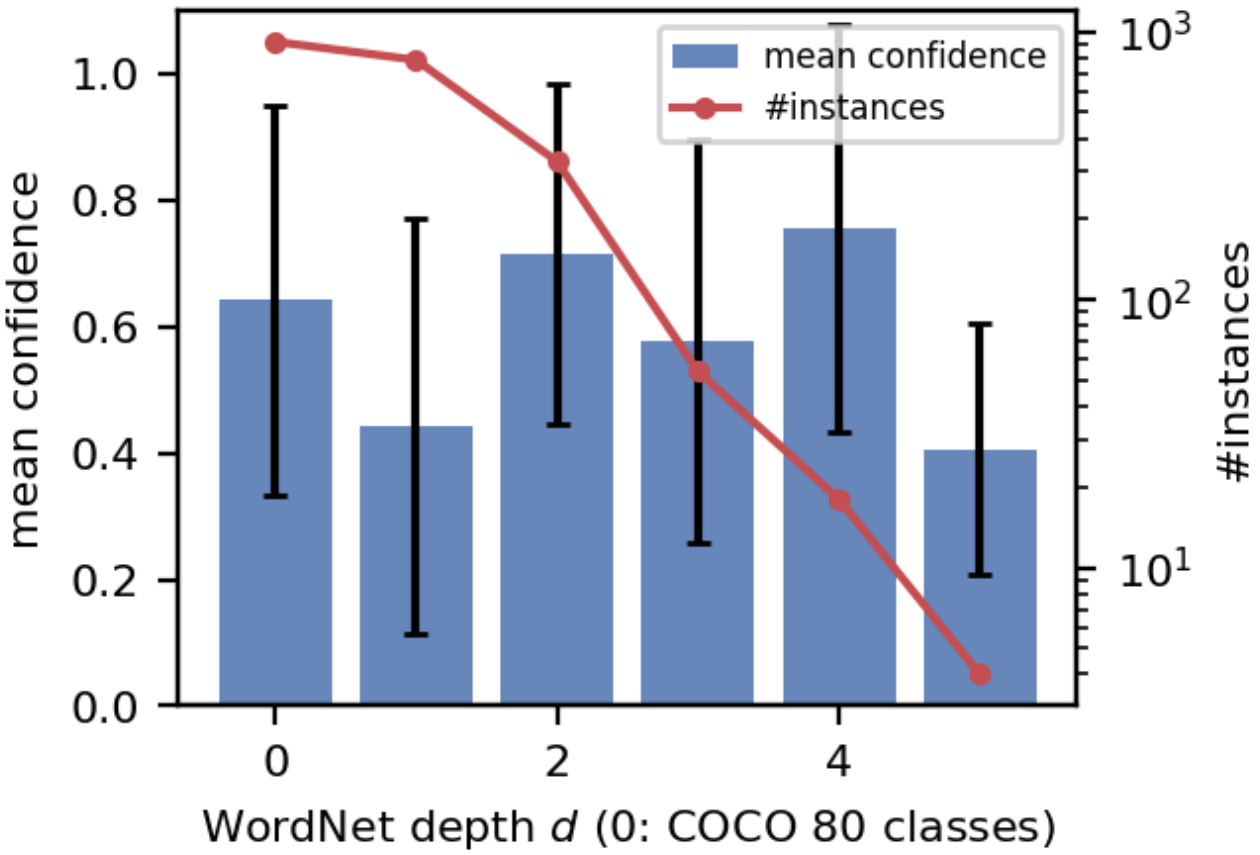
0.604
Top-1正解率

0.894
Top-5正解率

CLIP-ViT-B/32, θ=0.97, pad

- padでTop-1が約0.08向上
  bottle：0.344 → 0.844
- 人物は約0.38にとどまる

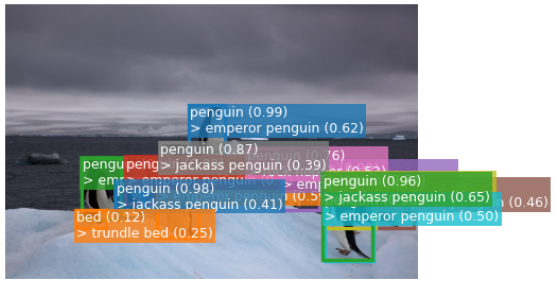
実験4：WordNet階層の深さごとの確信度



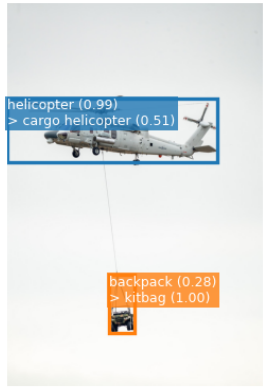
- 深さ0→1：**0.642 → 0.442**
  候補が80語→平均109語に増加
- 下位語が1語の分岐が18%
  確信度は常に1（ソフトマックス）
  除いた深さ1～3の確信度
  0.378，0.571，0.481

実験5：COCO以外の語を含む実画像

penguin (13 boxes)



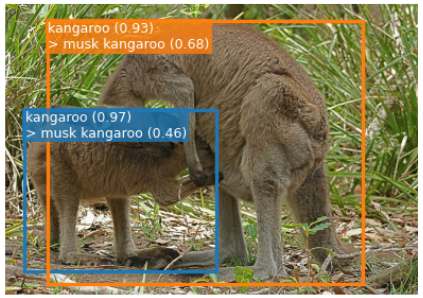
helicopter (2 boxes)



camel (1 boxes)



kangaroo (2 boxes)



lighthouse_1 (2 boxes)



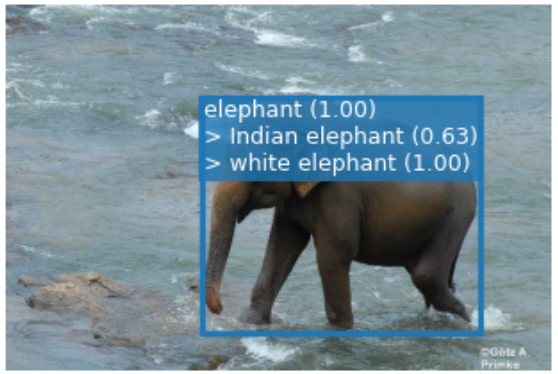
lighthouse_2 (0 boxes)



・penguin, helicopter, camel, kangarooを**再学習なしで正しく付与**
camel → Arabian camel (0.78)．灯台の塔はDETRで検出できない

WordNetの階層をそのまま使うことの限界

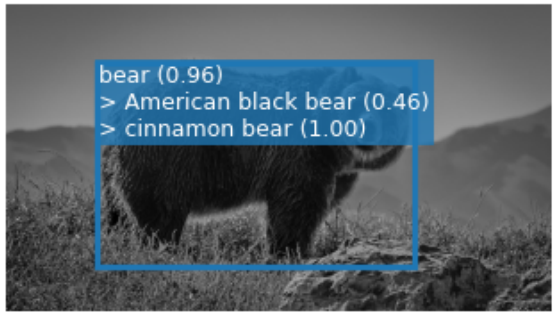
COCO 556765



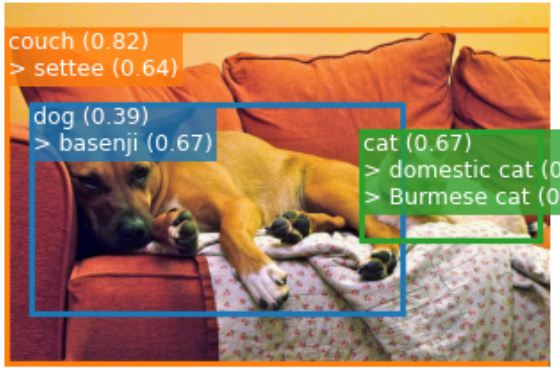
COCO 507042



COCO 460927



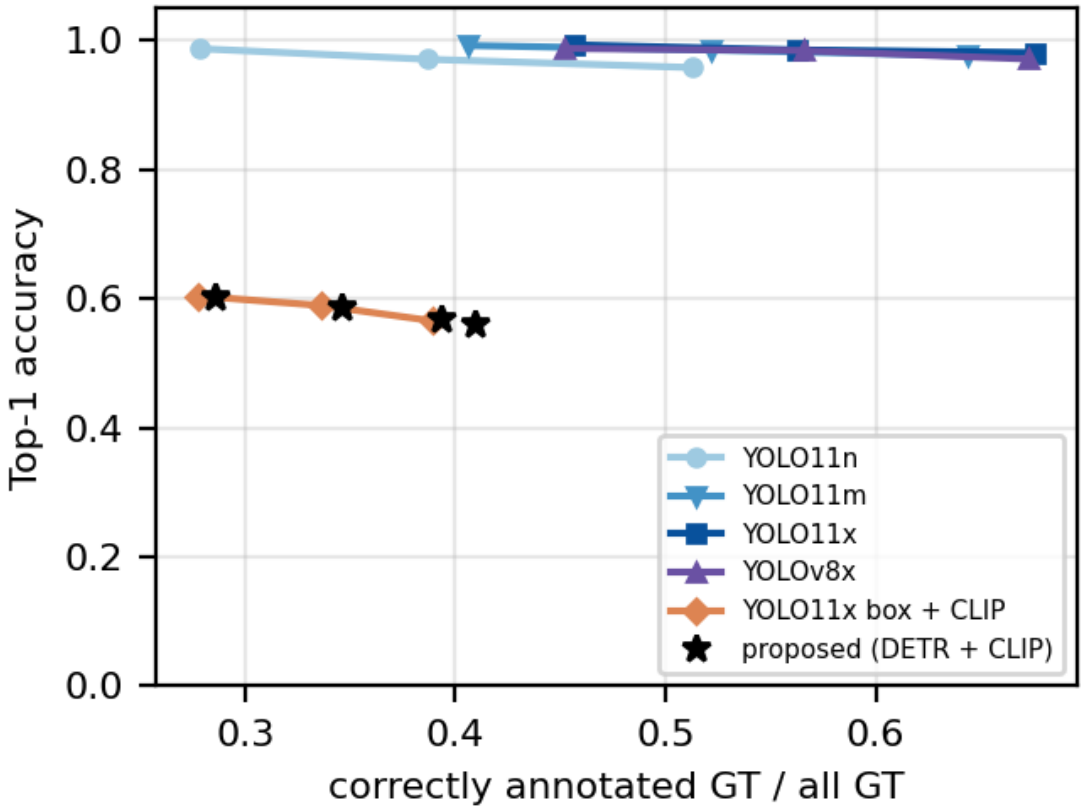
COCO 219578



- giraffe → okapi（1.00）：下位語が1語しかない
- person → suspect など，外見で判断できない語も選ばれる

YOLOとの比較①：COCOの80クラスの範囲内

手法	n	Top-1	Top-5
提案手法（θ=0.97）	1519	0.604	0.894
YOLO11x[8]	2210	**0.981**	0.999
YOLO11x + CLIP	1474	0.604	0.907

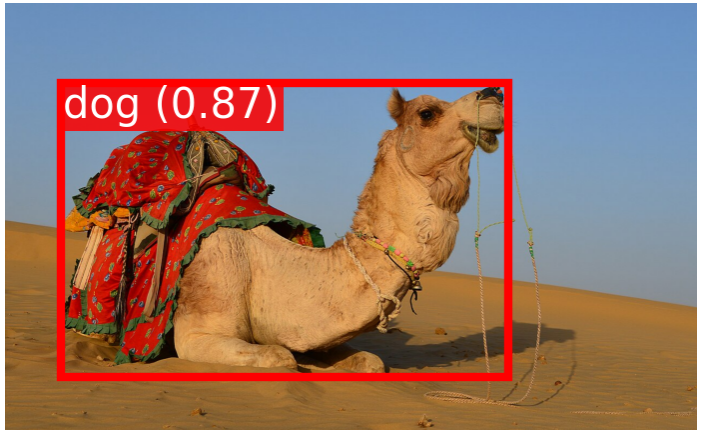


- 80クラス内はYOLOが高精度
  共通1480件：0.989 vs 0.609
- YOLOの領域をCLIPで分類
  → 提案手法と同等（0.604）
  差の原因は検出器ではなく分類器

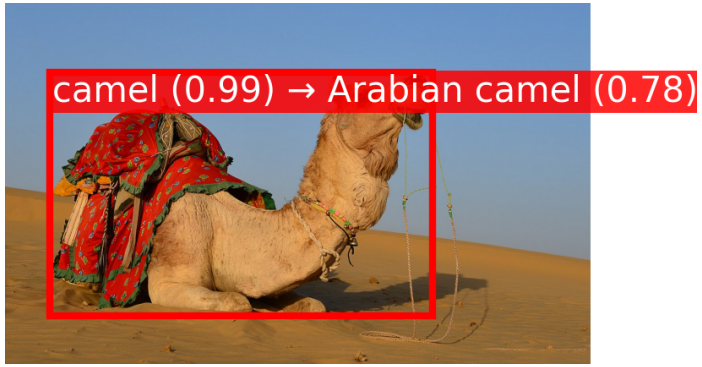
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

YOLOとの比較②：COCO以外の語

被写体	YOLO11x	提案手法
ペンギン	bird	penguin
ラクダ	dog	camel
カンガルー	bear, sheep	kangaroo
ヘリコプター	airplane	helicopter
灯台	検出なし	検出なし



YOLO11x



提案手法

- YOLOは80クラスの語しか出力できない
- 提案手法は語彙を変えるだけで対応できる

[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

ハイブリッド構成：深さ0の分類をYOLOに任せる



例：YOLO: dog (0.92) → CLIP: basenji (0.72)

- 80クラス内の分類はYOLOが高精度（0.981）
- 深さ0の誤りが減る → 誤った分岐をたどりにくい
- 細分化はこれまでと同じく再学習なし

[5] A. Radford, et al., “Learning Transferable Visual Models From Natural Language Supervision,” Proc. ICML, pp.8748-8763, 2021.
[6] G. A. Miller, “WordNet: A Lexical Database for English,” Communications of the ACM, vol.38, no.11, pp.39-41, 1995.
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

COCO以外の語への切替規則と閾値γ

CLIPがCOCO外の語を高い確信度で選んだときのみ切り替える

$$\hat{v}_k^{(0)} = \begin{cases} u_k & \left(u_k \in \mathbb{V}_E, f\left(\mathbf{X}_k; \mathbb{V}^{(0)} \cup \mathbb{V}_E\right)_{u_k} \geq \gamma\right) \\ y_k & (otherwise) \end{cases} \tag{4}$$

y_k：YOLOのクラス，$\mathbb{V}_E$：COCO外の22語，γ：切替に必要な確信度の下限

u_k：80クラスと22語の計102語を候補として(1)で推定した単語

構成	検証用の500枚	テスト用の500枚	COCO外の画像
γ=0	47件を誤って切替	50件を誤って切替	切り替わる
γ=0.5	2件	8件（6件は下位語）	切り替わる

下位語：bird → flamingo など，WordNetでGTカテゴリの下位語となる切替

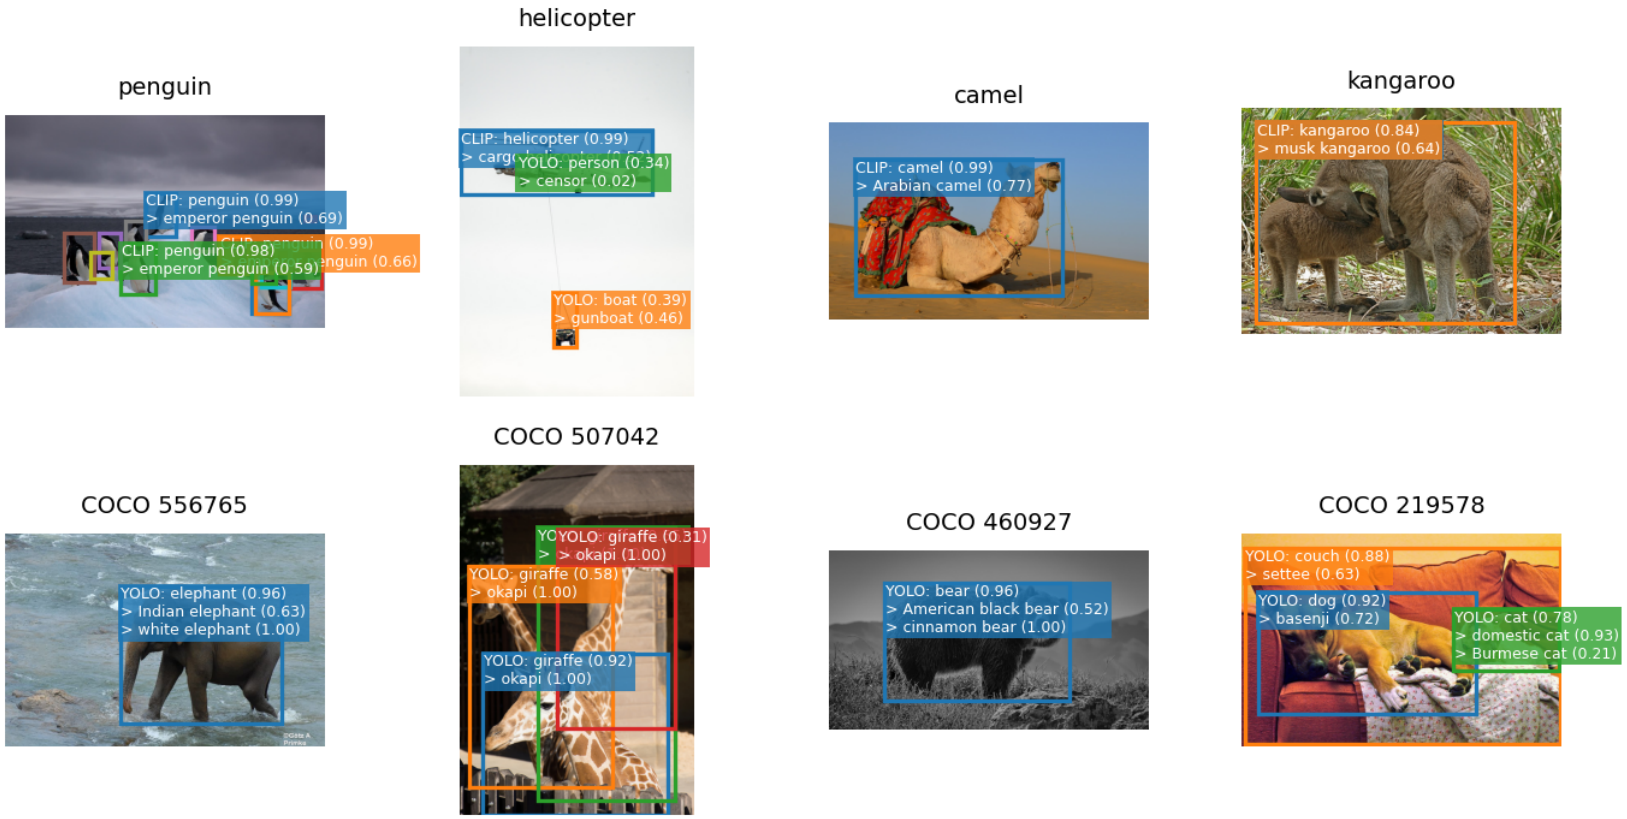
ハイブリッド構成の結果：細分化できる物体が約1.6倍

手法	閾値	n	Top-1	r	N_h
提案手法（DETR）	θ=0.5	2343	0.560	0.410	1313
ハイブリッド	0.25	2210	0.981	0.676	**2167**
提案手法（DETR）	θ=0.97	1519	0.604	0.286	917
ハイブリッド	0.7	1474	0.993	0.456	**1463**

- 評価数nが近い組で比較：**1.65倍，1.60倍**
  検出スコアの定義が異なるため，閾値の値では揃えない
- N_h：深さ0が正解の物体数，r：GT 3206件に対する割合

[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

ハイブリッド構成の定性結果：COCO外の語も細分化

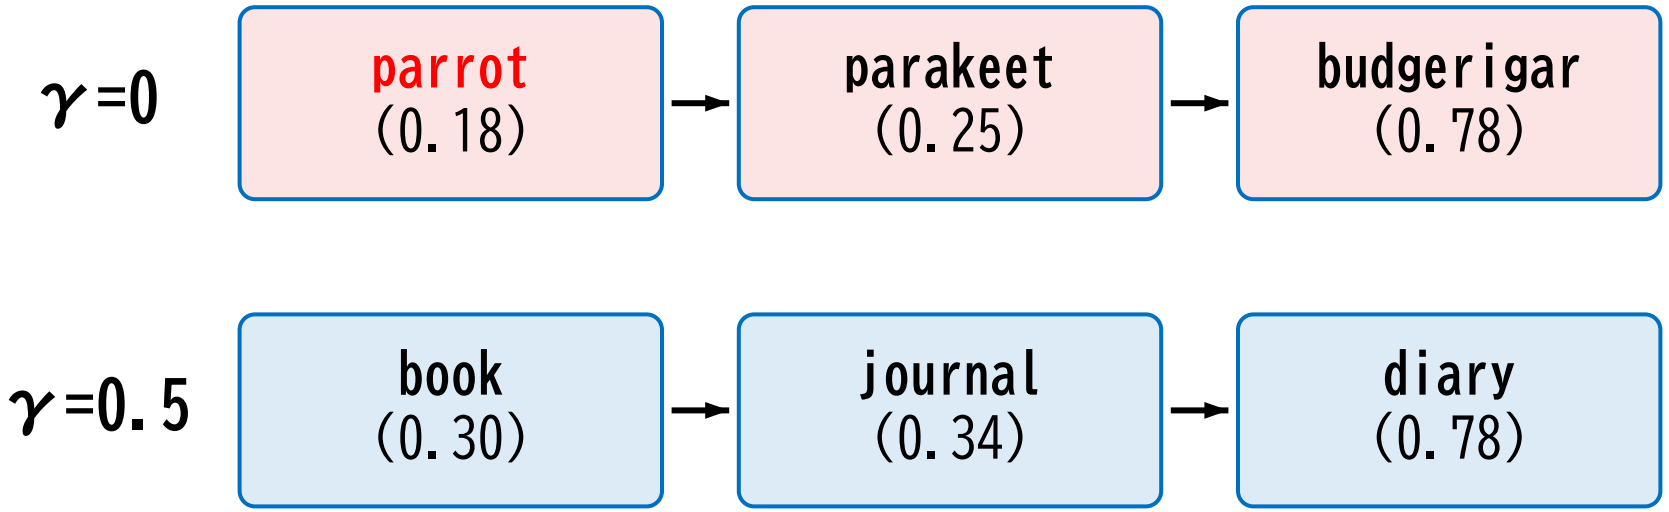


・bird / dog → **CLIP: penguin (0.99) / camel (0.99)** に切替後，細分化
YOLOが検出しない灯台や，giraffe → okapi の分岐は解消されない

限界：深さ0の誤りはそのまま下位語へ展開される



YOLO: book (0.30)



- 誤った語の下位語の中から選ぶ
  → 深い段階の確信度は高く見える（0.78）
- COCOの評価は深さ0が正解の物体のみ集計
  誤りの展開は表の数値に含まれない

誤った枝は深い段階の確信度では見分けられない

テスト用の500枚	閾値	提案手法	ハイブリッド
細分化できる物体数	θ=0.5 / 0.25	1509	2492（1.65倍）
誤った枝に展開	θ=0.5 / 0.25	44.8%	3.1%
AUROC：最深段の確信度	θ=0.5 / 0.25	0.611	0.418
AUROC：深さ0の確信度	θ=0.5 / 0.25	0.725	0.715

- 閾値やγを決めた500枚とは別の500枚で再評価
- 誤った枝の最深段の確信度は正しい枝と同程度
  → 誤りの手がかりは深さ0の確信度のみ

LVISによる評価：深さ1の正解は半数未満

- LVIS[9]：COCOの画像に1203カテゴリ（WordNetのSynset付き）
  COCOより細かい正解の例：bird → pigeon, bottle → wine bottle

LVISのテスト用分割	提案手法（θ=0.5）	ハイブリッド（0.25）
評価インスタンス数	489	481
深さ1が正しい割合	**0.440**	**0.407**
LVISの語まで到達	0.272	0.372

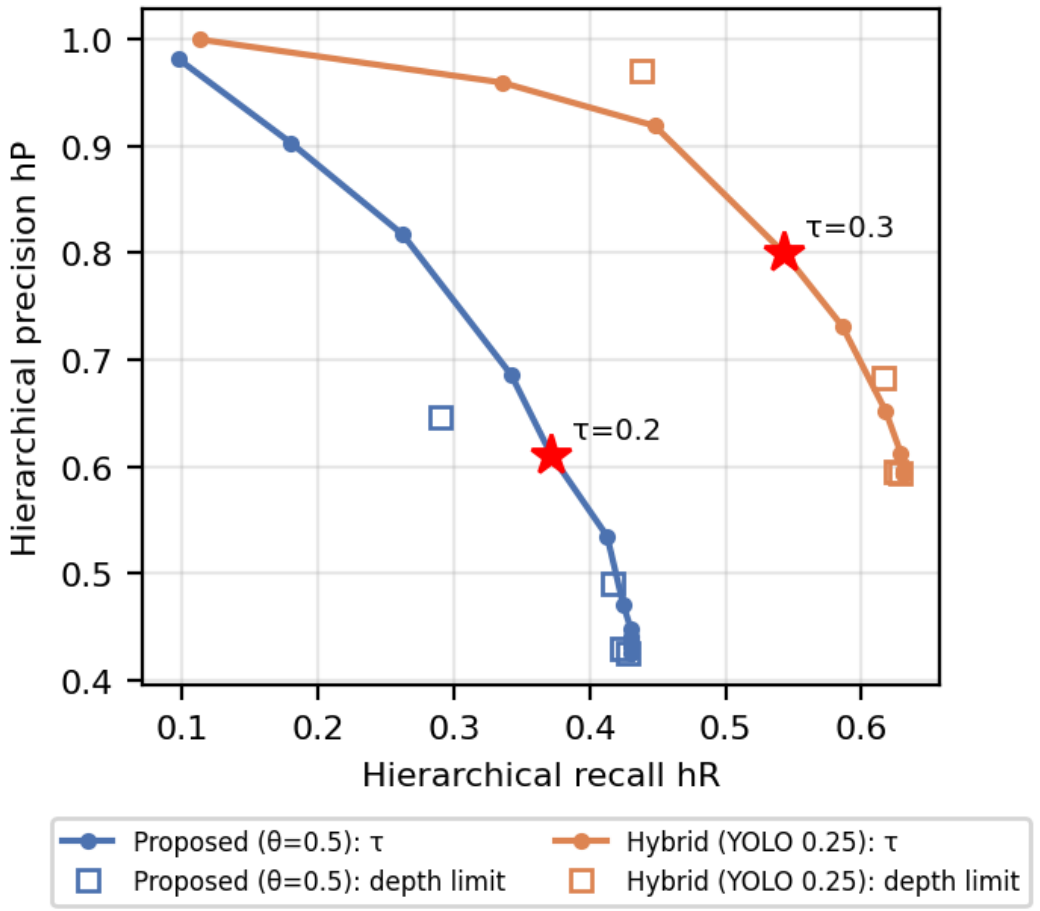
- 深さ0が正しい物体のみで集計しても半数未満
  深さ1での確信度の低下（0.642→0.442）は実際の誤りを伴う

[9] A. Gupta, P. Dollár, and R. Girshick, “LVIS: A Dataset for Large Vocabulary Instance Segmentation,” Proc. IEEE/CVF CVPR, pp.5356-5364, 2019.

累積確信度で細分化を止める

$$c_k^{(d)} = \prod_{j=0}^{d} f\left(\mathbf{X}_k; \mathbb{V}_k^{(j)}\right)_{\hat{v}_k^{(j)}} \geq \tau \qquad (5)$$

- 満たす最も深い段階まで出力
  $c_k^{(0)} < \tau$ なら棄却
- τは検証用の分割で決定
- テスト用：hP **0.594 → 0.801**
  ハイブリッド構成，τ=0.3
- 深さ1で止める規則とhFは同程度



まとめと今後の課題

まとめ

1. 検出とカテゴリ付与の分離
2. 再学習なしの粒度可変化
3. Top-1 0.604, Top-5 0.894
4. COCO外の語も付与できる
5. 80クラス内はYOLOが優位
6. YOLOとの組み合わせで
   細分化できる物体が約1.6倍
7. 深さ1の正解は半数未満

今後の課題

1. WordNet階層の選別
2. 深い段階の確信度の改善
3. 人物クラスの細分化の評価
4. 語彙外の領域の棄却
5. 検出の学習分布依存の緩和