物体領域検出とカテゴリアノテーションの分離に基づく，WordNetを用いた粒度可変物体アノテーション

所属機関名
〇著者名

やりたいことを、できることに。
湘南工科大学
SHONAN INSTITUTE OF TECHNOLOGY
AI R&D CENTER

研究背景：閉域的な物体検出モデルの限界

- 物体アノテーション：「どこ」＋「何」
- YOLO[1]やDETR[2]は1つのモデルで学習
- 出力できるのは学習したクラスのみ

  例：COCO[7]の80クラス

→ 語の追加・粒度の変更には再学習が必要

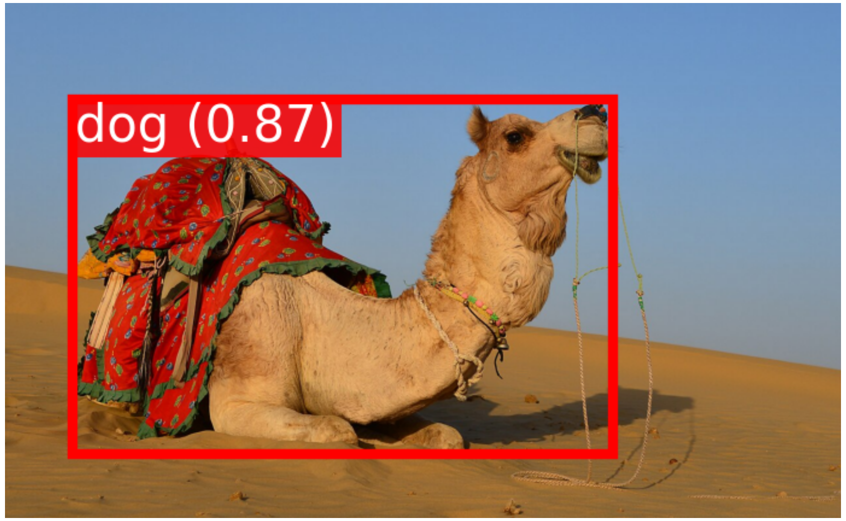

YOLO11x[8]：ラクダ → “dog”

[1] J. Redmon, et al., “You Only Look Once: Unified, Real-Time Object Detection,” Proc. IEEE CVPR, pp.779-788, 2016.
[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[7] T.-Y. Lin, et al., “Microsoft COCO: Common Objects in Context,” Proc. ECCV, pp.740-755, 2014.
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

従来手法の課題

閉域的な物体検出

YOLO[1], DETR[2]

- 語彙が学習時に固定
- 新しい語には再学習が必要

オープンボキャブラリ検出

OWL-ViT[3], Grounding DINO[4]

- 語彙をテキストで指定できる
- 語彙の変更ごとに検出を再実行

→ 多段階の語彙では非効率

[1] J. Redmon, et al., "You Only Look Once: Unified, Real-Time Object Detection," Proc. IEEE CVPR, pp.779-788, 2016.
[2] N. Carion, et al., "End-to-End Object Detection with Transformers," Proc. ECCV, pp.213-229, 2020.
[3] M. Minderer, et al., "Simple Open-Vocabulary Object Detection with Vision Transformers," Proc. ECCV, pp.728-755, 2022.
[4] S. Liu, et al., "Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection," Proc. ECCV, 2024.

研究目的

検出とカテゴリ付与を分離し，**再学習なし**で語彙と粒度を変える

検出は1回だけ行い，同じ領域で語彙を変えながら繰り返す

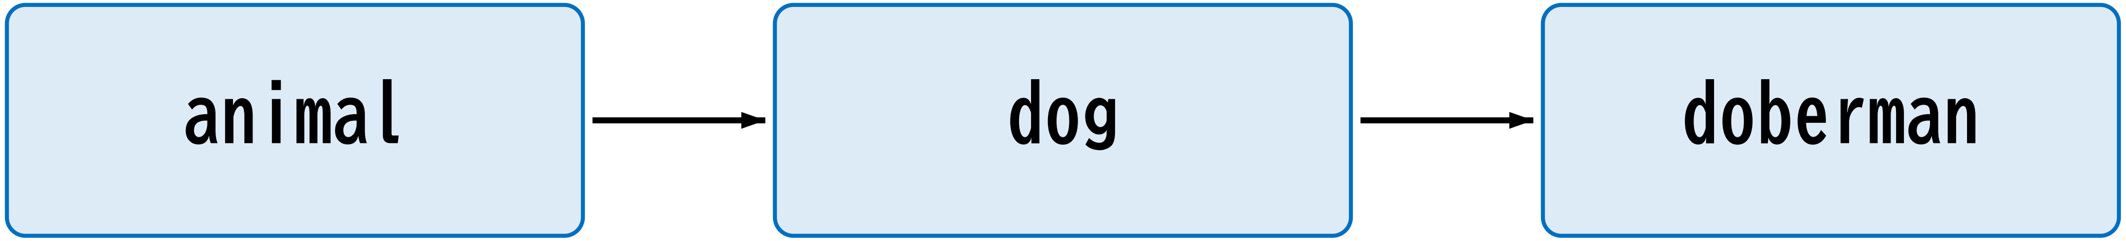
animal
dog
doberman

粗い粒度　　細かい粒度

同じクロップに対し，WordNetの下位語を次の候補語彙にする

提案手法：検出とカテゴリ付与の分離

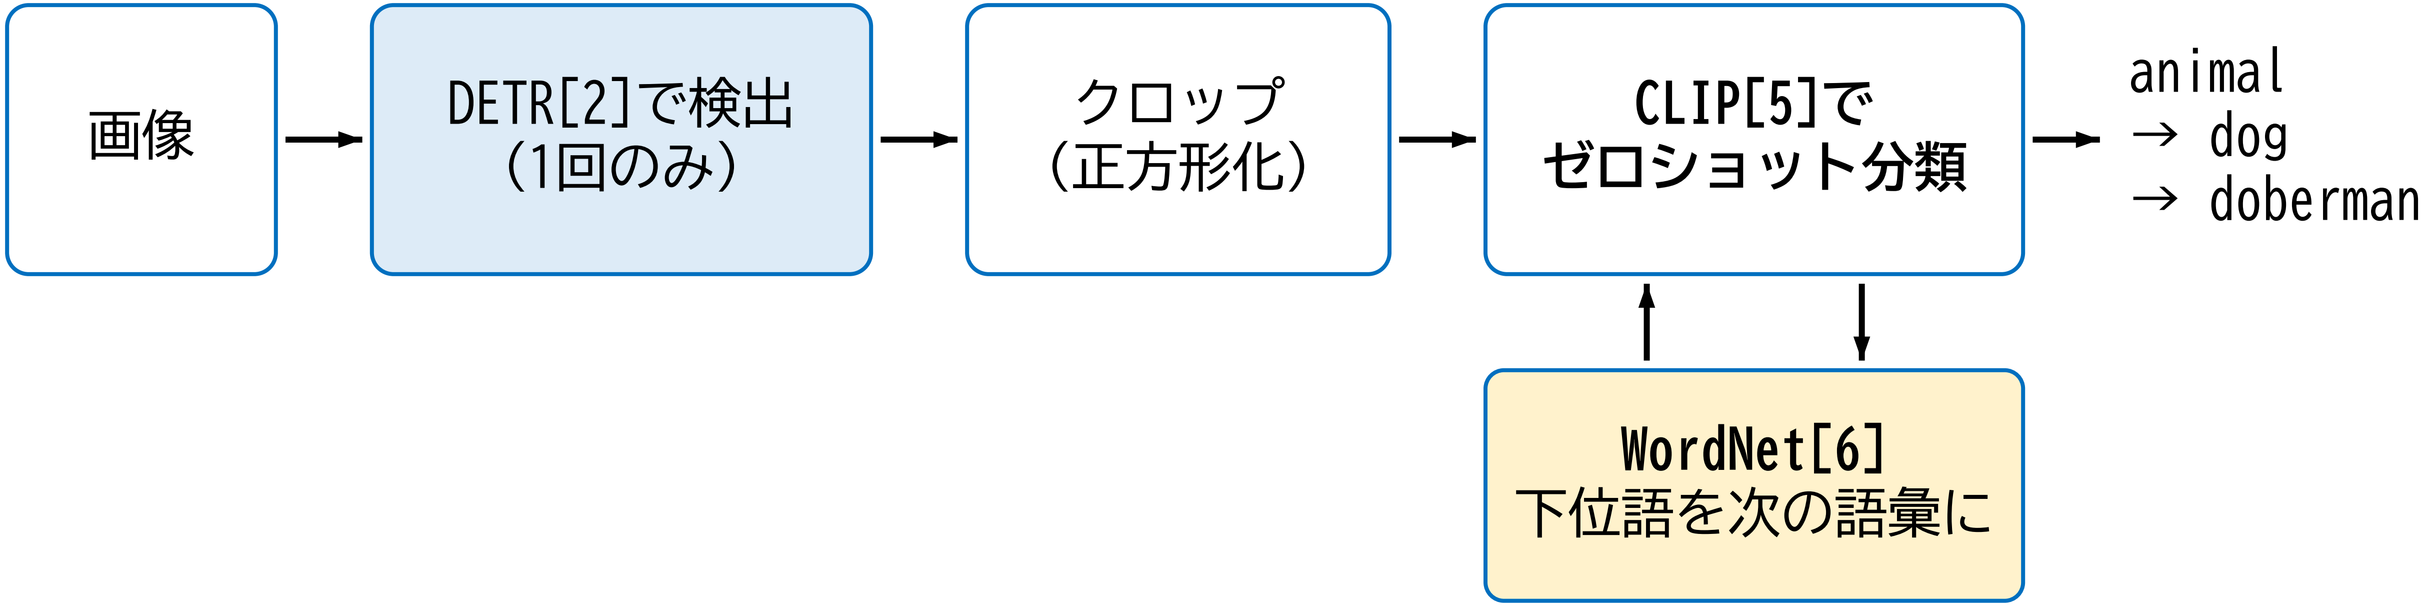
画像

DETR[2]で検出
(1回のみ)

クロップ
(正方形化)

CLIP[5]で
ゼロショット分類

animal
→ dog
→ doberman

WordNet[6]
下位語を次の語彙に

- 検出は語彙に依存しない → 語彙や粒度を変えても再検出は不要
- 繰り返すのは軽量なVLMの推論のみ

[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[5] A. Radford, et al., “Learning Transferable Visual Models From Natural Language Supervision,” Proc. ICML, pp.8748-8763, 2021.
[6] G. A. Miller, “WordNet: A Lexical Database for English,” Communications of the ACM, vol.38, no.11, pp.39-41, 1995.

VLMによるカテゴリのアノテーション

クロップに対するスコアが最大の単語を選ぶ

$$\hat{v}_k = \underset{v \in \mathbb{V}}{\mathrm{argmax}} f\left(\mathbf{X}_k; \mathbb{V}\right)_v \tag{1}$$

CLIP[5]：プロンプトとの類似度のソフトマックス

$$f\left(\mathbf{X}; \mathbb{V}\right)_v = \frac{exp\left(\tau cos\left(g_I\left(\mathbf{X}\right), g_T\left(t\left(v\right)\right)\right)\right)}{\sum_{u \in \mathbb{V}} exp\left(\tau cos\left(g_I\left(\mathbf{X}\right), g_T\left(t\left(u\right)\right)\right)\right)} \tag{2}$$

$\mathbf{X}_k$：領域kのクロップ，$\mathbb{V}$：候補語彙集合，$\hat{v}_k$：推定単語

g_I，g_T：画像・テキストエンコーダ，$t\left(v\right)$：“a photo of a $\{v\}$”

τ：温度パラメータ（100），cos：コサイン類似度

[5] A. Radford, et al., “Learning Transferable Visual Models From Natural Language Supervision,” Proc. ICML, pp.8748-8763, 2021.

クロップの前処理：正方形パディング

- ボックスに合わせて切り出す
  周辺の物体の写り込みを防ぐ
- 中央切り出しでは端が欠ける
  VLMの標準の前処理
- 黒で正方形にパディング
  ボックス外の画像内容は含めない

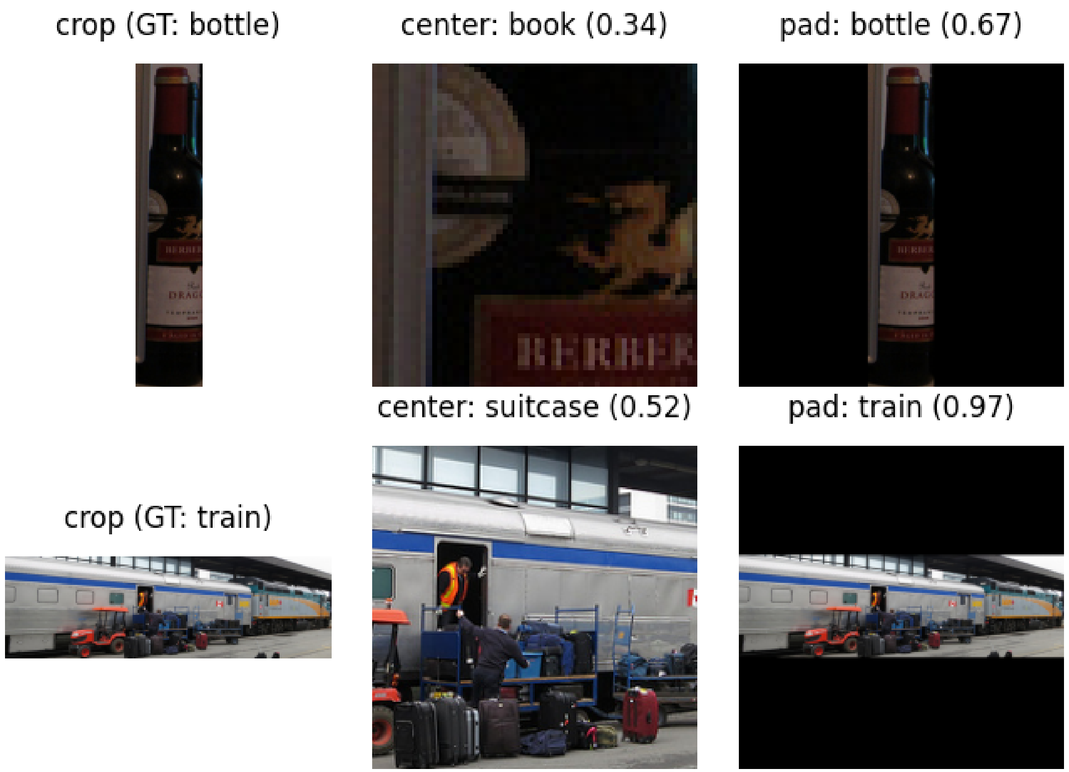
crop (GT: bottle)
center: book (0.34)
pad: bottle (0.67)
crop (GT: train)
center: suitcase (0.52)
pad: train (0.97)

WordNetによる粒度可変アノテーション

1つ浅い段階で選ばれた語の下位語を，次の候補語彙にする

$$\mathbb{V}_k^{(d)} = Hyponyms\left(synset\left(\hat{v}_k^{(d-1)}\right)\right) \tag{3}$$

d：深さ（$\mathbb{V}^{(0)}$はCOCOの80クラス）

Hyponyms：直接の下位語の集合

- 下位語がなくなるまで(1)を反復
- 出力：粗い語→細かい語の列
  各段階の確信度も出力

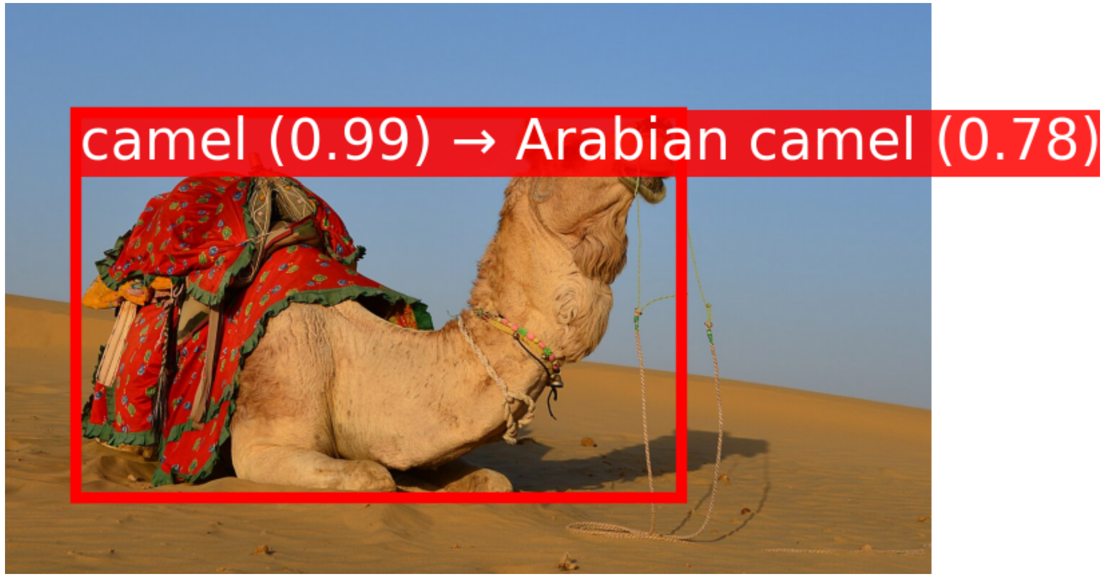

[6] G. A. Miller, "WordNet: A Lexical Database for English," Communications of the ACM, vol.38, no.11, pp.39-41, 1995.

実験設定

項目	設定
データ	COCO 2017 Val.[7]の500枚（GTインスタンス3206件）
物体領域検出	DETR[2]（ResNet-50），検出スコアの閾値 θ
VLM	CLIP-ViT-B/32[5]（比較：ResNet50-IN1k, CLIP-RN50）
比較する検出器	OWL-ViT[3], Grounding DINO[4], YOLO11 / YOLOv8[8]
評価指標	Top-1/Top-5正解率, P@k / R@k, IoU, 正命名率
学習	なし（すべて学習済みモデルの推論のみ）

[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[3] M. Minderer, et al., “Simple Open-Vocabulary Object Detection with Vision Transformers,” Proc. ECCV, pp.728-755, 2022.
[4] S. Liu, et al., “Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection,” Proc. ECCV, 2024.
[5] A. Radford, et al., “Learning Transferable Visual Models From Natural Language Supervision,” Proc. ICML, pp.8748-8763, 2021.
[7] T.-Y. Lin, et al., “Microsoft COCO: Common Objects in Context,” Proc. ECCV, pp.740-755, 2014.
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

実験1：オープンボキャブラリなVLMの必要性

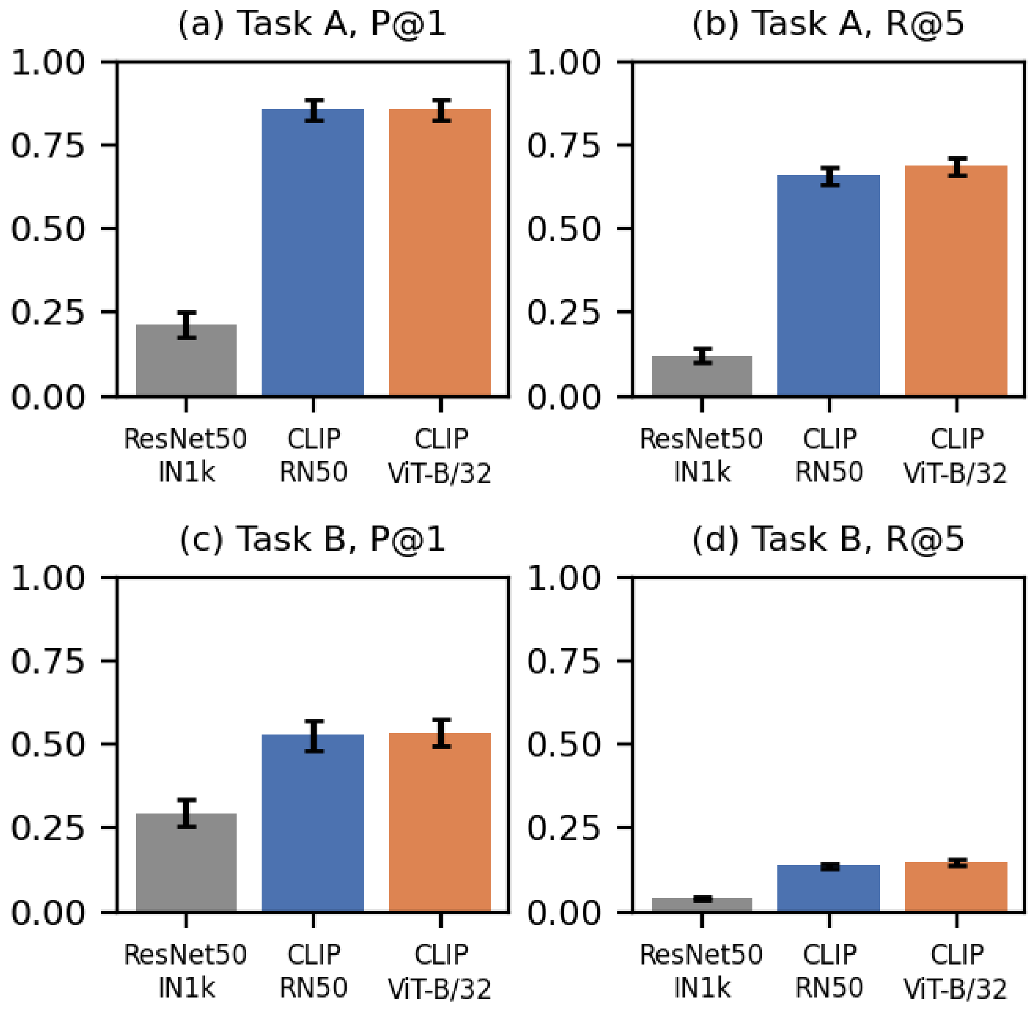

- 画像単位の単語推定（500枚）
  タスクA：COCOの80クラス
  タスクB：キャプション由来の1371語
- タスクAのP@1：0.216 → 0.855
- 全指標で有意差（$p < 10^{-11}$）
- CLIP-RN50とViT-B/32の差は小さい

実験2：物体領域検出モデルの比較

DETRの位置検出精度は他の検出器と同程度

手法	閾値	平均提案数	Recall@IoU0.5	平均最良IoU
DETR[2]	0.5	2.25	0.800	0.705
DETR[2]	0.9	1.50	0.600	0.583
OWL-ViT[3]	0.1	1.50	0.500	0.517
Grounding DINO[4]	0.35	1.50	0.500	0.546
YOLOv8x[8]	0.25	2.25	0.800	0.767

4画像・GTインスタンス10件．極小の車や画像全体を覆う食卓は全手法で未検出

[2] N. Carion, et al., “End-to-End Object Detection with Transformers,” Proc. ECCV, pp.213-229, 2020.
[3] M. Minderer, et al., “Simple Open-Vocabulary Object Detection with Vision Transformers,” Proc. ECCV, pp.728-755, 2022.
[4] S. Liu, et al., “Grounding DINO: Marrying DINO with Grounded Pre-Training for Open-Set Object Detection,” Proc. ECCV, 2024.
[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

実験3：パイプライン全体のカテゴリアノテーション精度

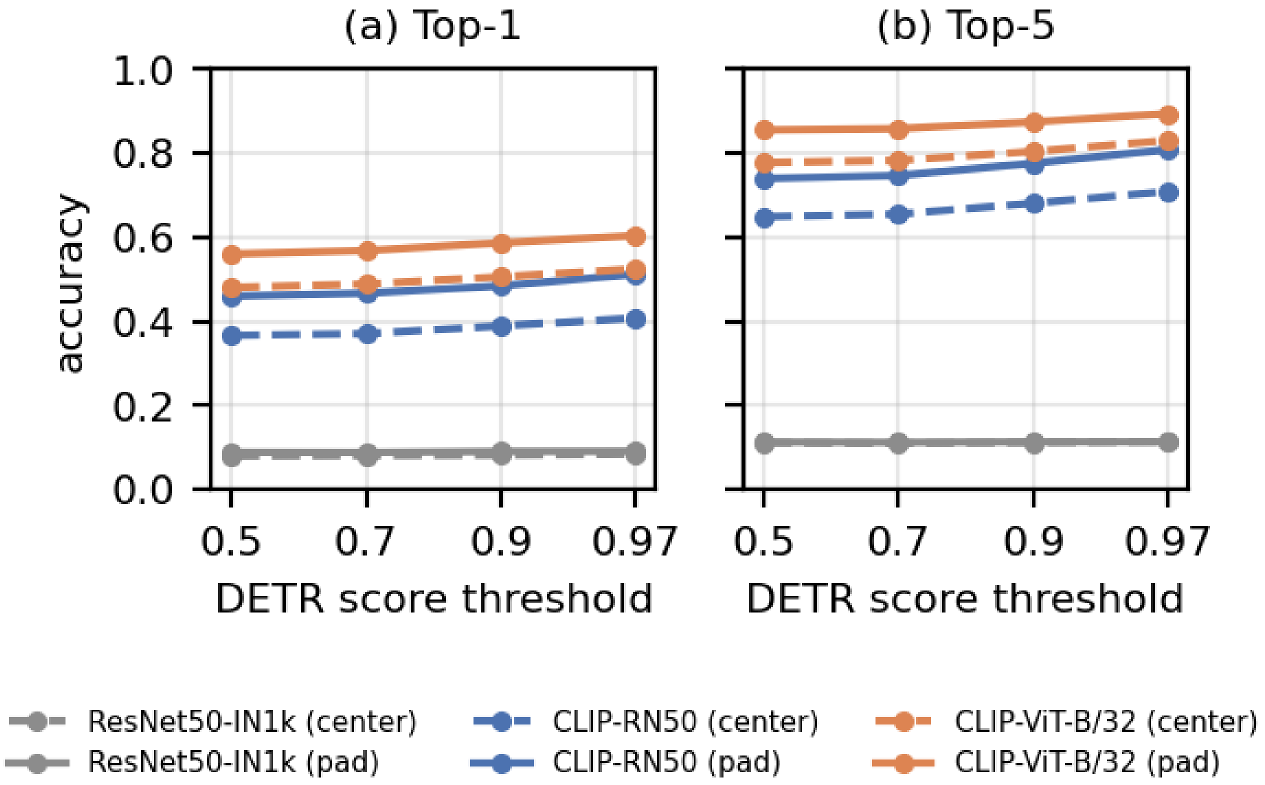

0.604
Top-1正解率

0.894
Top-5正解率

CLIP-ViT-B/32, θ=0.97, pad

- padでTop-1が約0.08向上
  bottle：0.344 → 0.844
- 人物は約0.38にとどまる

実験4：WordNet階層の深さごとの確信度

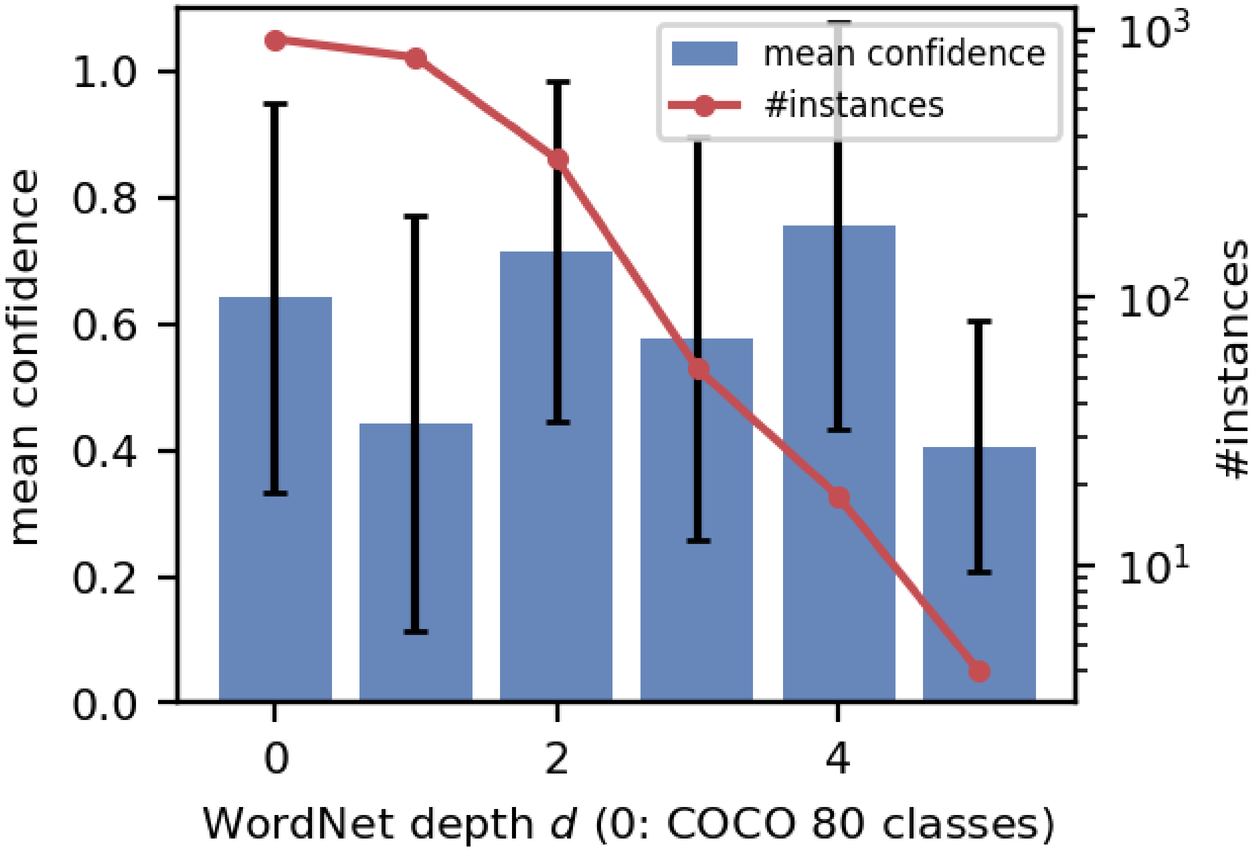

- 深さ0→1：0.642 → 0.442
  候補が80語→平均109語に増加
- 下位語が1語の分岐が18%
  確信度は常に1（ソフトマックス）
  除いた深さ1～3の確信度
  0.378，0.571，0.481

実験5：COCO以外の語を含む実画像

penguin (13 boxes)

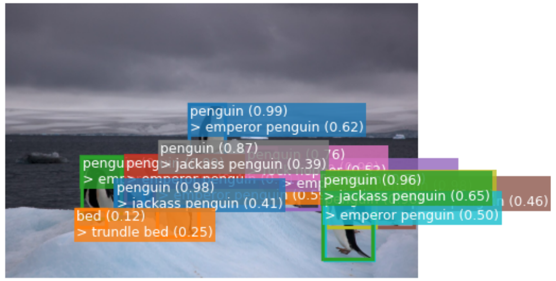
penguin (0.99)
> emperor penguin (0.62)
penguin (0.87)
> jackass penguin (0.39)
penguin (0.98)
> jackass penguin (0.41)
penguin (0.96)
> jackass penguin (0.65)
> emperor penguin (0.50)
(0.46)
bed (0.12)
> trundle bed (0.25)

helicopter (2 boxes)

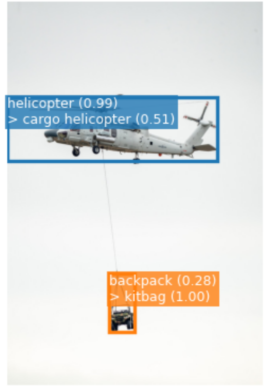
helicopter (0.99)
> cargo helicopter (0.51)
backpack (0.28)
> kitbag (1.00)

camel (1 boxes)

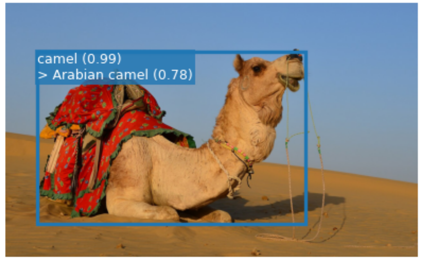
camel (0.99)
> Arabian camel (0.78)

kangaroo (2 boxes)

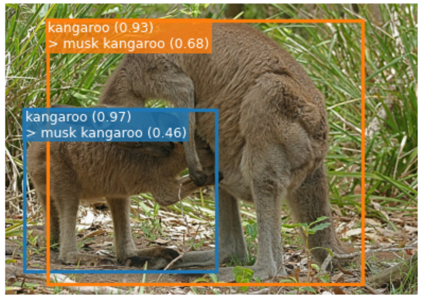
kangaroo (0.93)
> musk kangaroo (0.68)
kangaroo (0.97)
> musk kangaroo (0.46)

lighthouse_1 (2 boxes)

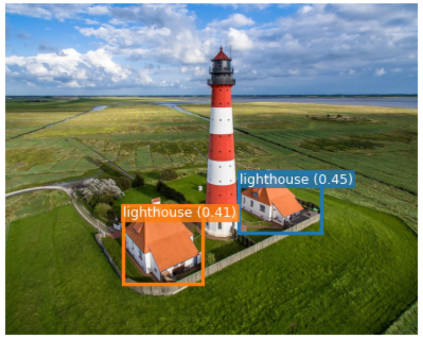
lighthouse (0.45)
lighthouse (0.41)

lighthouse_2 (0 boxes)

・penguin，helicopter，camel，kangarooを再学習なしで正しく付与

camel → Arabian camel（0.78）．灯台の塔はDETRで検出できない

WordNetの階層をそのまま使うことの限界

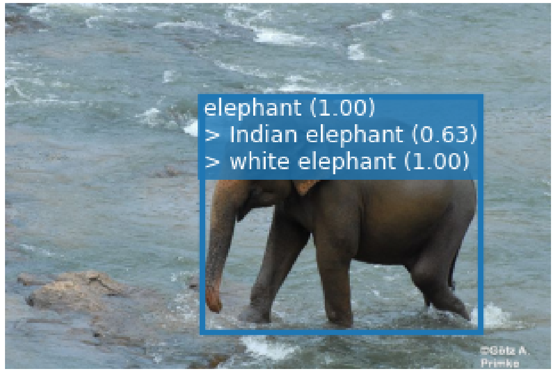
COCO 556765
elephant (1.00)
> Indian elephant (0.63)
> white elephant (1.00)
©Götz A. Primke

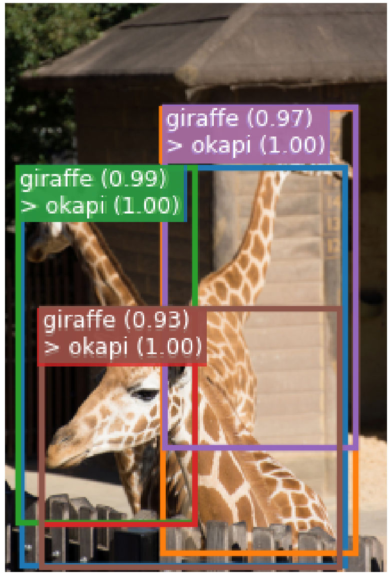
COCO 507042
giraffe (0.97)
> okapi (1.00)
giraffe (0.99)
> okapi (1.00)
giraffe (0.93)
> okapi (1.00)

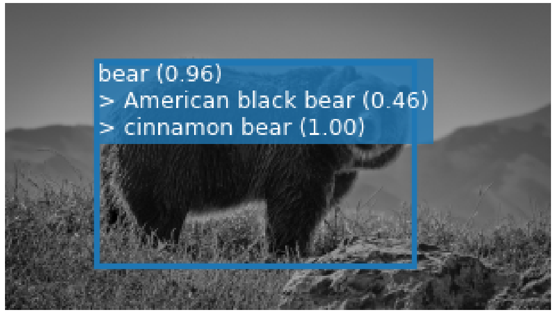
COCO 460927
bear (0.96)
> American black bear (0.46)
> cinnamon bear (1.00)

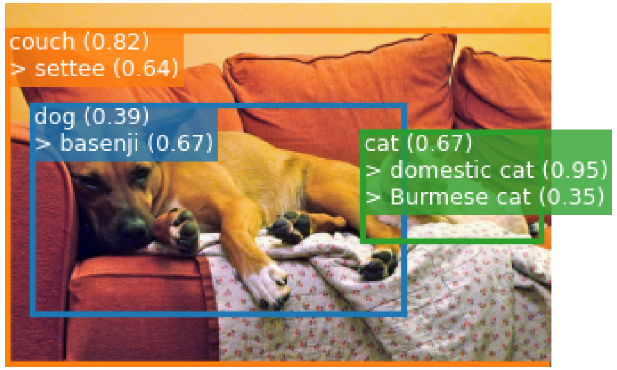
COCO 219578
couch (0.82)
> settee (0.64)
dog (0.39)
> basenji (0.67)
cat (0.67)
> domestic cat (0.95)
> Burmese cat (0.35)

- giraffe → okapi（1.00）：下位語が1語しかない
- person → suspect など，外見で判断できない語も選ばれる

YOLOとの比較①：COCOの80クラスの範囲内

手法	n	Top-1	Top-5
提案手法（θ=0.97）	1519	0.604	0.894
YOLO11x[8]	2210	0.981	0.999
YOLO11x + CLIP	1474	0.604	0.907

- 80クラス内はYOLOが高精度
  共通1480件：0.989 vs 0.609
- YOLOの領域をCLIPで分類
  → 提案手法と同等（0.604）
  差の原因は検出器ではなく分類器

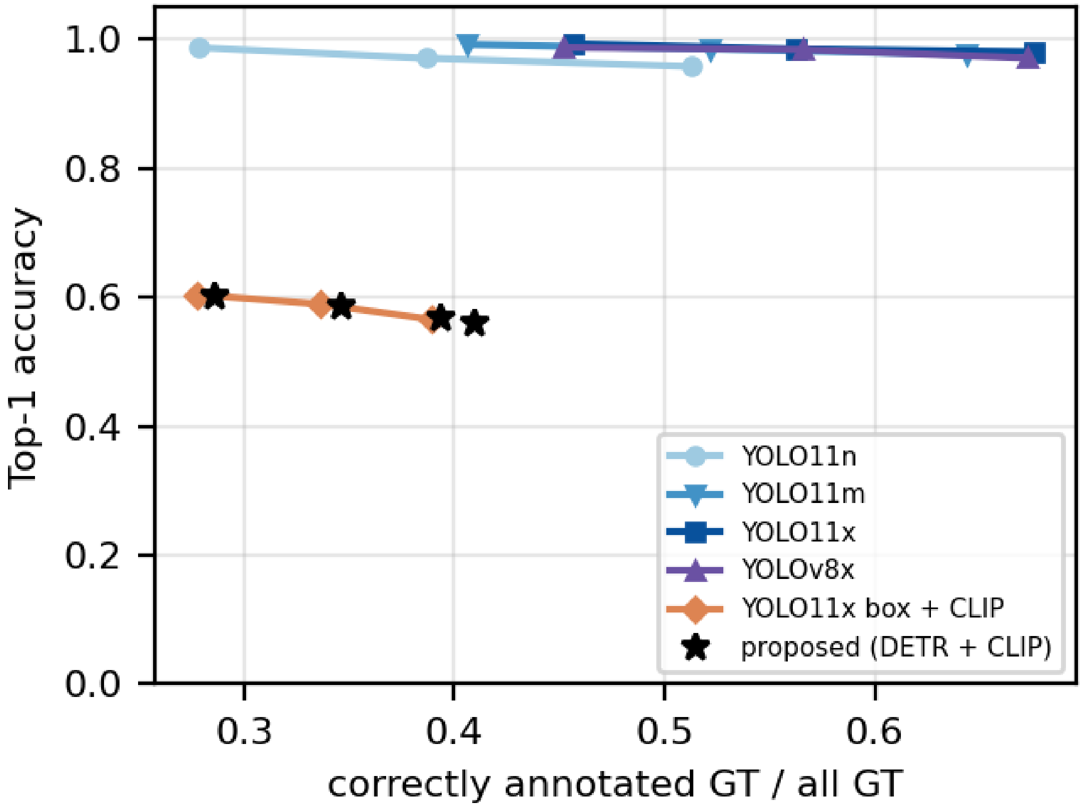

[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

YOLOとの比較②：COCO以外の語

被写体	YOLO11x	提案手法
ペンギン	bird	penguin
ラクダ	dog	camel
カンガルー	bear, sheep	kangaroo
ヘリコプター	airplane	helicopter
灯台	検出なし	検出なし

- YOLOは80クラスの語しか出力できない
- 提案手法は語彙を変えるだけで対応できる

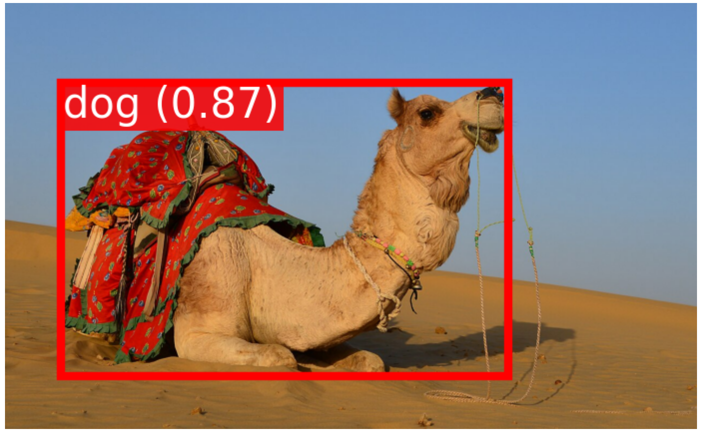

YOLO11x

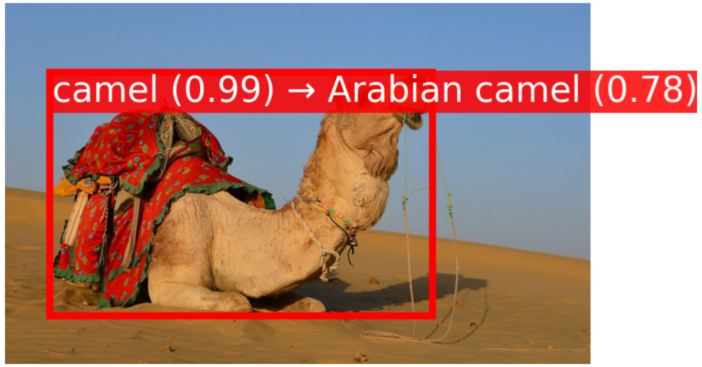
camel (0.99) → Arabian camel (0.78)

提案手法

[8] G. Jocher, J. Qiu, and A. Chaurasia, “Ultralytics YOLO,” https://github.com/ultralytics/ultralytics, 2023.

まとめと今後の課題

まとめ

1. 検出とカテゴリ付与の分離
2. 再学習なしの粒度可変化
3. Top-1 0.604, Top-5 0.894
4. COCO外の語も付与できる
5. 80クラス内はYOLOが優位

今後の課題

1. WordNet階層の選別
2. YOLOとVLMの組み合わせ
3. 語彙外の領域の棄却
4. 検出の学習分布依存の緩和